

Triaie de reclamos financieros con revisión humana

Motivo sugerido, resultados históricos, patrones semánticos y alertas sobre los reclamos públicos de la CFPB

Grupo 1: Piero Palacios Bernuy, Winston Flores, Gianmarco Mejía y Edgard Froylan Inga Quillas
Proyecto Integrador I · Maestría en Ciencia de Datos e IA · UTEC Posgrado · 2026-2

8 de octubre de 2026

Tabla de contenidos

Resumen	2
1 Introducción	2
1.1 El problema y la decisión que mejora	2
1.2 Objetivos	2
1.3 Alcance y estructura del documento	3
2 Datos y preparación	3
2.1 Fuente	3
2.2 Dos rasgos que condicionan el diseño	4
2.3 Preparación	4
3 Metodología	5
3.1 Protocolo de evaluación	5
3.2 Clasificadores T1–T3	6
3.3 Reclamos parecidos y patrones semánticos	6
3.4 Conteo semanal por patrón (M9)	6
3.5 Composición semanal (M10)	7
3.6 Alertas de aumento persistente (M11)	7
3.7 Bloque diario	7
4 Resultados	8
4.1 Clasificadores	8
4.2 Espacio semántico y patrones	9
4.3 Conteo semanal por patrón (M9)	11
4.4 Composición semanal (M10)	12
4.5 Alertas de aumento persistente (M11)	12
4.6 Bloque diario	13
4.7 Tabla comparativa	15
5 Discusión	16
5.1 Qué se eligió y por qué	16
5.2 Qué no funcionó, y qué se aprendió	16
6 Expectativas y limitaciones	17
6.1 Qué se puede esperar del prototipo	17
6.2 Límites declarados	17
7 Conclusiones y trabajo futuro	18
7.1 Conclusiones	18
7.2 Trabajo futuro	18
Declaración de uso de inteligencia artificial	18
Anexo A. Catálogo de los 40 patrones	19
Anexo B. Tabla completa de candidatos	36
Anexo C. Reglas pre-registradas	48

Resumen

Un banco recibe reclamos en texto libre y debe clasificarlos, atenderlos a tiempo y notar cuándo algo nuevo está pasando. Este informe documenta un prototipo reproducible que apoya a la persona que hace ese triaje con cinco salidas: el motivo más probable del reclamo, la probabilidad de que termine con alguna solución y con compensación, los reclamos históricos parecidos, el patrón semántico al que pertenece y, cada semana y cada día, qué patrones reciben más reclamos de lo esperado.

Se usaron 3,837,184 reclamos públicos de la Oficina de Protección Financiera del Consumidor de Estados Unidos (CFPB), con evaluación hacia adelante en el tiempo, una vista que excluye el texto reutilizado (42.8 % de las narrativas comparten texto con otra) y reglas de decisión escritas antes de correr cada modelo. Un clasificador tabular en contexto, TabPFN-3.5, sugiere el motivo entre 90 clases con Macro-F1 0.271 frente a 0.076 de la regla por producto. Modelos lineales sobre TF-IDF estiman solución y compensación con precisión promedio 0.609 y 0.364. Cuarenta patrones semánticos sobre embeddings BGE organizan el flujo. Una binomial negativa jerárquica con memoria corta predice el volumen semanal de cada patrón con 30 % menos error que la referencia Poisson, y un CUSUM sobre sus excesos detecta crecimientos sostenidos de 20 % semanal en 71 % de los casos simulados con una falsa alarma al mes. Un bloque diario, pre-registrado como prueba aparte, dejó un modelo de conteo diario con 25 % menos error que su referencia y una regla de alerta diaria que no se adopta porque detecta menos de la mitad de las ráfagas simuladas.

Se declaran los límites: etiquetas aproximadas, licencias no comerciales, taxonomía sin revisión del negocio y un periodo de validación ya consultado. El método se traslada a un banco; las cifras no.

1 Introducción

1.1 El problema y la decisión que mejora

Un banco regulado recibe cada día reclamos escritos por sus clientes. Una persona del equipo de atención los lee, decide de qué tratan, los deriva al equipo que corresponde y vigila los plazos. Esa persona también es la primera en notar cuándo una campaña, un producto o un fallo operativo empieza a generar reclamos nuevos, pero lo nota tarde, porque el volumen diario no deja ver el conjunto.

El triaje tiene tres decisiones concretas que un sistema puede apoyar sin reemplazar a la persona:

- **Qué es este reclamo.** Sugerir el motivo más probable y los tres más probables reduce el tiempo de lectura y las derivaciones erradas.
- **Qué suele pasar con reclamos así.** Saber si reclamos parecidos terminaron con una solución registrada o con compensación ayuda a priorizar y a anticipar la respuesta.
- **Qué está cambiando.** Agrupar los reclamos en patrones de significado y vigilar cuántos llegan a cada patrón convierte un flujo de texto en una señal que se puede revisar cada semana y, con más ruido, cada día.

El sistema entrega evidencia y la decisión final queda en la persona. No afirma detectar fraude, no mide el plazo interno del banco y no reemplaza la revisión humana de ninguna alerta.

1.2 Objetivos

Objetivo general. Construir y evaluar, de forma reproducible y con reglas fijadas antes de ver los resultados, un prototipo de triaje de reclamos que sugiera el motivo, estime resultados históricos, encuentre reclamos parecidos y detecte patrones semánticos cuyo volumen aumenta.

Objetivos específicos.

1. Preparar una tabla única de reclamos con texto normalizado, taxonomía canónica congelada, objetivos T1–T4 y periodos temporales de ajuste, calibración y validación, documentada con su diccionario.
2. Elegir, con un protocolo de evaluación hacia adelante y una vista sin texto compartido, los clasificadores de motivo (T1), solución (T2) y compensación (T3), y decidir si el de respuesta fuera de plazo (T4) aporta algo.

3. Construir un espacio semántico de reclamos (embeddings, PCA, UMAP, índice de vecinos) y una partición en patrones estable en el tiempo, con una regla de novedad.
4. Modelar el conteo semanal y la composición semanal de los patrones con modelos bayesianos comparados contra referencias simples, y derivar una regla de alerta de aumento persistente con un presupuesto de falsas alarmas.
5. Probar, como bloque aparte y pre-registrado, si la misma arquitectura funciona a resolución diaria y si una regla de alerta diaria aporta sobre la semanal.
6. Registrar cada decisión, su regla y su evidencia en MLflow, DVC y un registro de pre-registro, de modo que otra persona pueda reproducir el resultado.

1.3 Alcance y estructura del documento

El prototipo se construyó sobre datos públicos de Estados Unidos porque un banco peruano no comparte sus reclamos. Las etiquetas disponibles, el motivo asignado por la CFPB y la respuesta de la empresa, son aproximaciones de las categorías internas de un banco. Por eso el entregable es el **método** y la **evidencia de que funciona en datos reales**, no las cifras en sí.

La sección 2 describe los datos y su preparación. La sección 3 explica el protocolo de evaluación y cada componente, con la razón de cada elección. La sección 4 presenta los resultados por componente. La sección 5 discute qué se eligió y qué no funcionó. La sección 6 declara expectativas y límites, y la sección 7 cierra con conclusiones y trabajo futuro. Los anexos traen el catálogo de los 40 patrones, la tabla completa de candidatos y el resumen de las reglas pre-registradas. Toda cifra del documento se lee de los archivos de resultados del repositorio al momento de renderizarlo; ninguna se escribió a mano.

2 Datos y preparación

2.1 Fuente

Los datos son la base pública de reclamos de la CFPB [1], que publica cada reclamo con narrativa cuando el consumidor lo autoriza: fecha de recepción, producto, motivo, empresa, estado, respuesta de la empresa y si la respuesta fue oportuna. La tabla preparada tiene 3,837,184 filas y 44 columnas (1.71 GiB), con hash MD5 d189a3ae6ea7... fijado en DVC; ese hash acompaña cada corrida registrada en MLflow.

Tabla 1: Filas por periodo temporal. Solo 2023–2024 y 2025-H1 entran en el modelado; 2015–2022 es contexto, 2025-H2 quedó bloqueado por un experimento anterior y 2026 es parcial.

Periodo	Filas
Contexto 2015–2022	1,206,176
Ajuste y calibración 2023–2024	1,301,794
Validación 2025-H1	695,184
2025-H2 (bloqueado)	526,872
2026 parcial (sellado)	107,158




Figura 1: Reclamos con narrativa por periodo. El volumen crece con los años: 2025-H1 tiene casi tantos reclamos como los dos años de ajuste.

2.2 Dos rasgos que condicionan el diseño

Reutilización de texto. 42.8 % de las filas comparten su narrativa normalizada con otra; hay 2,476,614 textos distintos en 3,837,184 reclamos. Muchas narrativas son plantillas de gestores de reclamos de crédito. Un modelo que memorice plantillas parece mejor de lo que es, así que toda decisión se toma en la vista **sin texto compartido**, que excluye de calibración y validación las narrativas ya vistas en ajuste.

Deriva temporal. Lo que se reclama y cómo responden las empresas cambia de un año a otro: la fracción de reclamos con alguna solución registrada pasó de 43.2 % en ajuste a 38.7 % en validación. Evaluar con datos del mismo periodo engaña; por eso los periodos se cortan por fecha y se evalúa hacia adelante.

2.3 Preparación

La preparación corre como cinco etapas de DVC con parámetros en `params.yaml`, cada una con su hash de salida, y termina en un diccionario de datos con 44 columnas descritas (cobertura 100 %).

Tabla 2: Etapas de preparación (P1–P5) tal como las registra el informe de limpieza.

Etapa	Qué hace
type_data	P1 · valida el esquema de 16 columnas y tipa las dos fechas
normalize_text	P2 · normaliza la narrativa (text_normalizer_v1) y su SHA-256
apply_taxonomy	P3 · aplica la taxonomía propuesta congelada al 2025-06-30
build_targets	P4 · construye T1–T4, periodos, bloqueos y elegibilidad
finalize_prepared	P5 · valida el contrato y publica la tabla sin transformarla

La taxonomía de productos y motivos cambió de nombres entre periodos: 21 productos y 173 motivos originales se mapean a 18 productos y 140 motivos canónicos con un mapa congelado al 2025-06-30. Ese mapa es una propuesta sin revisión del negocio (proposed_no_business_review). En ajuste aparecen 90 motivos, muchos raros, lo que justifica Macro-F1 como métrica de T1.

Los cuatro objetivos se derivan de columnas de la CFPB: T1 es el motivo canónico; T2 es «alguna solución registrada» (respuesta cerrada con explicación, con alivio no monetario o monetario); T3 es «compensación

monetaria»; T4 es «respuesta no oportuna». Las tasas de positivos en ajuste son 33.3 % para T2, 2.6 % para T3 y 1.1 % para T4. No se remuestrea: la métrica principal de T2–T4 es la precisión promedio, que no depende del umbral.

Tabla 3: Problemas encontrados en los datos y su tratamiento, del informe de limpieza.

Problema	Tratamiento
El archivo cambia con el tiempo: 2025 reúne cerca de un tercio de los reclamos y 2026 es parcial	Periodos temporales en la columna period; ningún reparto al azar entre entrenamiento y evaluación
La taxonomía histórica cambió de nombres entre periodos	Mapa canónico congelado al 2025-06-30 (Product canonical, Issue canonical) y banderas de categorías y pares conocidos
Pocas categorías concentran los casos y hay motivos raros	Sin transformación: la métrica principal de T1 es Macro-F1 y la elegibilidad por objetivo se declara en columnas
T3 y T4 tienen pocos positivos	Sin remuestreo: métrica principal average precision y umbral fijado en calibración
Las narrativas tienen longitudes muy distintas y marcas XXXX	Se conservan íntegras; la normalización no recorta ni elimina filas
Mucha reutilización textual entre reclamos	SHA-256 del texto normalizado para identificar grupos; vista de evaluación sin textos compartidos con los periodos de referencia; no se elimina ninguna fila
Los resultados T2–T4 cambian con el tiempo	Evaluación en periodos posteriores al entrenamiento; las respuestas ambiguas quedan como desconocidas (known_T2, known_T3)
Los 25,000 identificadores revisados antes no se recuperaron	2025-H2 bloqueado como evaluación final; banderas de identificador revisado y de grupo de texto excluido

3 Metodología

3.1 Protocolo de evaluación

Las decisiones de este protocolo se fijaron antes de entrenar y no se cambiaron después; están escritas, con fecha, en el registro de pre-registro del repositorio (docs/registro/models_plan.md). El anexo C las resume.

Tabla 4: Ventanas temporales y filas elegibles por vista. La vista sin texto compartido decide; la completa se reporta.

Ventana	Fechas	Filas (completa)	Filas (sin texto compartido)
Ajuste	desde 2023-01-01 hasta antes de 2024-10-01	1,067,194	1,067,194
Calibración	desde 2024-10-01 hasta antes de 2025-01-01	234,600	167,973
Validación	desde 2025-01-01 hasta antes de 2025-07-01	695,184	564,813

- **Tres periodos por fecha.** El sistema predecirá reclamos futuros, así que se ajusta en el pasado, se decide en calibración y se confirma en validación.

- **Validación se abre una vez.** Los modelos se eligen solo en calibración. Validación (2025-H1) se abrió el 2026-10-01 con todo congelado y confirmó T1–T3, M9 y M10. Las rondas posteriores (bloques A, B, C y el bloque diario) también se decidieron solo con ajuste y calibración, pero sus cifras de validación se reportan como **ya consultadas**: no son evidencia limpia. No queda otro periodo intacto: 2025-H2 se contaminó en un experimento anterior y 2026 es parcial y se reserva sellado.
- **Regla de reemplazo.** Un candidato reemplaza al vigente solo si mejora la métrica principal al menos 5 % y un bootstrap pareado por semanas (2,000 remuestreos, semilla 42) deja el intervalo del 95 % entero a su favor. Con 12 semanas de calibración, una mejora pequeña puede ser azar o una sola semana rara.
- **Orden de complejidad.** Los candidatos se prueban del más simple al más complejo; cada uno reemplaza al anterior solo si cumple la regla.
- **Modelos bayesianos en tres pasos.** Revisión de priors por simulación predictiva, piloto corto y corrida completa, con diagnósticos de convergencia ($R\text{-hat} \leq 1.01$, sin divergencias) y cobertura de intervalos dentro de rangos fijados.
- **Trazabilidad.** Cada corrida registra en MLflow el commit, el hash de datos, la semilla y las métricas; los artefactos grandes van por DVC.

3.2 Clasificadores T1–T3

La métrica principal es Macro-F1 para T1 (90 motivos, muchos raros) y precisión promedio (AP) para T2 y T3, siempre en la vista sin texto compartido. La referencia es la **regla por producto**: el motivo o la tasa de positivos más frecuente de cada producto en ajuste.

Las representaciones compiten en orden de complejidad: TF-IDF del texto, TF-IDF más el producto, embeddings BGE-large [2] del texto y BGE más el producto, cada una con un clasificador lineal calibrado. Para T1 se añadió un bloque posterior con **TabPFN-3.5** [3], un modelo tabular en contexto que no se entrena: recibe 20,000 filas de contexto (76 clases presentes), con los embeddings reducidos a 100 componentes de PCA más el producto, y predice en 8 estimadores promediados. Una ablación pre-registrada probó 256 componentes y los 1,024 valores sin PCA.

T4 (respuesta no oportuna) se evaluó con el mismo protocolo y se descartó al confirmarlo en validación; lo reemplaza una regla de plazo con feriados.

3.3 Reclamos parecidos y patrones semánticos

Cada narrativa se representa con un embedding BGE-large de 1,024 dimensiones (BAAI/bge-large-en-v1.5), normalizado. Un índice exacto de producto interno (FAISS, [4]) sobre 120,000 reclamos de ajuste devuelve los diez más parecidos.

Los **patrones** son una partición del espacio semántico: PCA ajustado solo con filas de ajuste (256 componentes conservan 92.4 % de la varianza), UMAP a 15 dimensiones [5] y k-means. Se compararon 12 configuraciones de k-means, HDBSCAN y CURE con criterios de aceptación fijados antes: tamaño del grupo mayor, fracción de ruido, silhouette, estabilidad entre submuestras ($ARI \geq 0.6$) y cobertura de reclamos futuros ($\geq 70\%$). Un reclamo es **novedoso** si su distancia al centro asignado supera el percentil 99 de las distancias de ajuste. Una ronda de sensibilidad (bloque A) repitió la partición en 9 espacios alternativos (PCA 128/256/512, UMAP 5/10/15/30 y otras semillas) para saber si otro espacio daba grupos mejores.

3.4 Conteo semanal por patrón (M9)

Para saber si un patrón recibe más reclamos de lo normal hace falta cuántos se esperaban. El conteo semanal de cada patrón se modela como *total de la semana* $\times$ *participación esperada* con una **binomial negativa** por patrón, que admite más variación que la Poisson. La participación esperada de la familia ganadora usa una **memoria que decae**: cada semana pesa δ veces la siguiente más reciente (δ elegido en ajuste entre valores fijados). Los candidatos se comparan por el **WIS** (*weighted interval score*, [6]): la media, sobre los intervalos de 50 %, 80 % y 95 % y la mediana, del error absoluto de la mediana más la penalización por intervalos anchos o que no cubren el valor observado. Menor es mejor. Se exige además cobertura de 70–90 % para el intervalo de 80 % y de 88–99 % para el de 95 %.

Los modelos se escriben en PyMC [7] y se muestrean con NUTS en NumPyro sobre el clúster Khipu; la referencia es una Poisson con la participación de las cuatro semanas previas. Además de las variantes bayesianas se probaron dos modelos fundacionales de series de tiempo sin entrenamiento, Chronos-2 [8] y TimesFM [9].

3.5 Composición semanal (M10)

M9 pregunta «¿este patrón trajo más de lo esperado?»; M10 pregunta «¿la mezcla de la semana es rara?». Una **Dirichlet-multinomial** modela el vector de conteos de los 40 patrones condicionado al total de la semana, con participaciones de cuatro semanas y una concentración global κ : cuanto mayor κ , más se parece la composición de cada semana a la esperada. Se evalúa por el **log score conjunto** (logaritmo de la probabilidad asignada a la composición observada, sumado en calibración) contra una multinomial de cuatro semanas. Sobre el modelo aceptado se derivó una señal semanal de **mezcla rara**: un p-valor predictivo posterior del log score de cada semana, con aviso si $p < 0.01$.

3.6 Alertas de aumento persistente (M11)

Cada semana y patrón recibe un **exceso** z : el score normal de la mid-PIT del conteo observado en la predictiva de M9, es decir, la posición del observado dentro de la distribución predicha, transformada para que sea aproximadamente $N(0, 1)$ si el modelo está calibrado. Dos reglas compiten: un **CUSUM** [10] que acumula los excesos ($k = 0.5$) y avisa cuando supera h , y una regla que avisa si el exceso de una sola semana supera z^* . Los umbrales se fijan por simulación de series $N(0, 1)$ para un presupuesto de 1 falsa alarma al mes en total sobre los 40 patrones. La detección se mide inyectando crecimientos sostenidos de 10 % y 20 % semanal y escalones de 50 % y 100 % en los conteos de calibración, con un horizonte de 8 semanas. CUSUM se adopta si detecta al menos 5 % más que la regla semanal en los dos crecimientos.

3.7 Bloque diario

El bloque diario se pre-registró como prueba aparte: el semanal sirve para acciones preventivas y correctivas; el diario, para decisiones rápidas del día a día. El panel tiene 36,480 filas (639 días de ajuste, 92 de calibración y 181 de validación, sin huecos) con un total medio diario de 1,670 reclamos en ajuste y 2,550 en calibración. Los candidatos de conteo (D-A a D-D) son binomiales negativas que condicionan en el total del día con memoria que decae ($\delta = 0.8$, elegido en ajuste) y distintas formas del ciclo semanal; D-B es un espacio de estados y D-E la Dirichlet-multinomial diaria. La regla diaria de alerta D-11 repite el diseño de M11 con un presupuesto, aprobado por el equipo, de 4 falsas alarmas al mes sobre 40 patrones y ráfagas inyectadas de $\times 2$ durante 3 días, $\times 3$ durante 1 día y $\times 1.5$ durante 7 días. Se adopta solo si detecta al menos 50 % de las dos primeras ráfagas con mediana de retraso de a lo más 2 días.

4 Resultados

4.1 Clasificadores

Tabla 5: T1, motivo del reclamo: Macro-F1 en calibración sin texto compartido, en el orden en que compitieron. Cada fila reemplaza a la anterior solo si cumple la regla del 5 % con el bootstrap a favor.

Candidato	Macro-F1	Decisión
Regla por producto	0.076	referencia
TF-IDF, solo texto	0.141	+84.6 % frente a Regla por producto; IC [+0.061, +0.069]; reemplaza
TF-IDF + producto	0.214	+52.4 % frente a TF-IDF, solo texto; IC [+0.071, +0.078]; reemplaza
BGE, solo texto	0.158	-26.2 % frente a TF-IDF + producto; IC [-0.061, -0.053]; no reemplaza
BGE + producto	0.240	+11.9 % frente a TF-IDF + producto; IC [+0.023, +0.029]; reemplaza
TabPFN-3.5 (PCA 100 + producto)	0.271	+12.9 % frente a BGE + producto; IC [+0.027, +0.035]; reemplaza




Figura 2: Macro-F1 de T1 en calibración por representación. El producto y los embeddings aportan; TabPFN-3.5 sobre PCA 100 más producto es el vigente.

TabPFN-3.5 acierta el motivo entre los tres primeros en 95.5 % de los reclamos de calibración. En 2025-H1 (ya consultado) mantiene Macro-F1 0.270 frente a 0.227 de BGE + producto y 0.068 de la regla por producto. La ablación de entrada no cambió la decisión: con 256 componentes de PCA el Macro-F1 fue 0.268 (-1.0 %, IC [-0.006, +0.001], incluye el cero) y con los 1,024 valores sin PCA cayó a 0.192 (-29.0 %), porque cada estimador de TabPFN ve a lo más 768 columnas.

Tabla 6: T2 (alguna solución registrada) y T3 (compensación monetaria): precisión promedio en calibración sin texto compartido y confirmación en 2025-H1. T4 no se confirmó.

Tarea	Modelo elegido	Regla (cal.)	Modelo (cal.)	Regla (2025-H1)	Modelo (2025-H1)	Validación
T2	TF-IDF, solo texto	0.454	0.609	0.451	0.570	confirmado
T3	TF-IDF, solo texto	0.174	0.364	0.127	0.270	confirmado
T4	TF-IDF + producto	0.031	0.055	0.121	0.078	no confirmado

Para T2 y T3 el producto no sumó el 5 % exigido sobre el TF-IDF del texto (0.612 frente a 0.609 en T2), así que quedó el modelo más simple. Los umbrales de decisión se fijaron en calibración maximizando F1: 0.300 para T2 y 0.181 para T3. T4 no supera a la regla por producto en validación (0.078 frente a 0.121): sale del triaje y lo reemplaza una regla de plazo con feriados.

4.2 Espacio semántico y patrones

El vecino más parecido por FAISS tiene similitud coseno mediana 0.924 en calibración; comparte producto en 82.7 % de los casos y motivo en 47.7 %. Es la evidencia de que el espacio captura significado y no solo palabras.

Tabla 7: Las tres familias de agrupamiento sobre UMAP 15 (mejor configuración de cada una, muestra de 20,000 reclamos de ajuste). Solo k-means pasa todos los criterios.

Algoritmo	Grupos	Ruido	Grupo mayor	Silhouette	Estabilidad ARI	Cobertura futura	Resultado
k-means k = 40	40	0 %	14 %	0.138	0.63	99 %	aceptado
HDBSCAN	2	49 %	47 %	0.545	1.00	63 %	rechazado: cluster_count, noise, future_coverage
CURE	20	0 %	99 %	0.409	0.43	96 %	rechazado: largest_cluster, neighbor_lift, stability

Los 40 patrones de k-means cubren 99.0 % de los reclamos futuros con la regla de novedad; en ajuste 0.88 % de los reclamos resultan novedosos, en calibración 1.08 % y en validación 0.77 %. Los patrones tienen entre 1,947 y 176,716 reclamos de ajuste (mediana 9,254); el mayor concentra 16.6 %. La ronda de sensibilidad probó 36 combinaciones de espacio y algoritmo: 6 pasaron los criterios y ninguna ganó a la partición vigente por la regla del 5 % en la coincidencia de vecinos. Cambiar solo la semilla de UMAP da particiones con ARI 0.61 y 0.58 respecto de la vigente: los patrones son una partición útil y estable en su calidad, no categorías naturales. El anexo A describe cada uno.




Figura 4: Patrón 14: redacted, redacted redacted, account, credit




Figura 5: Patrón 8: bank, card, account, redacted




Figura 6: Patrón 13: loan, redacted, mortgage, payment

Figura 3

4.3 Conteo semanal por patrón (M9)

Tabla 8: Candidatos de M9 por WIS en las 12 semanas de calibración (menor es mejor) y cobertura de los intervalos de 80 % y 95 %. Las referencias no compiten.

Candidato	WIS	Cobertura 80 / 95	Resultado
C-A, memoria que decae ($\delta = 0.5$)	30.30	85 % / 97 %	−6.5 % frente a NB-R4-H v3; gana a v3
C-B, paseo aleatorio t de Student	31.95	88 % / 98 %	−1.4 % frente a NB-R4-H v3; no gana a v3
NB-R4-H v3, dispersión por patrón	32.42	85 % / 96 %	−24.7 % frente a b1_rolling_4; accepted
Chronos-2, sin entrenamiento	36.02	77 % / 96 %	+11.1 % frente a NB-R4-H v3; no gana a v3
TimesFM 3.0, sin entrenamiento	40.70	76 % / —	−1.6 % frente a NB-R4-H v3; no gana a v3
B1-R4, Poisson con participaciones de 4 semanas	43.11	29 % / 42 %	referencia
NB-R4, 4 semanas, una dispersión	47.72	89 % / 96 %	+10.8 % frente a b1_rolling_4; rejected_no_practical_gain
B1-R13, ídem con 13 semanas	64.84	21 % / 32 %	referencia
NB-V3, binomial negativa estática	92.57	77 % / 94 %	referencia
B1, Poisson con participaciones fijas	138.75	9 % / 16 %	referencia




Figura 7: WIS de calibración de los candidatos semanales. C-A, la binomial negativa jerárquica con memoria que decae, es la vigente.

C-A reduce el WIS de la referencia Poisson de cuatro semanas de 43.11 a 30.30 (29.6 % menos) y gana a la versión con cuatro semanas de igual peso, NB-R4-H v3 (32.42), por 6.5 % con IC $[-3.36, -0.84]$. Su memoria $\delta = 0.5$ se eligió en ajuste; en la práctica mira las dos últimas semanas. Las coberturas son 85 % y 97 %. En 2025-H1 (ya consultado) C-A da WIS 129.6 frente a 133.6 de v3; la validación es más difícil que la calibración porque contiene la ráfaga del 13 de enero de 2025, en la que un patrón recibió más de la mitad de los reclamos de la semana.

4.4 Composición semanal (M10)

La Dirichlet-multinomial con participaciones de cuatro semanas (DM-R4) mejora el log score de calibración de la multinomial de cuatro semanas de -461 a -210 (diferencia 251, IC $[+205, +296]$), con concentración $\kappa = 826$: mucha más variación entre semanas que una multinomial. La versión con participaciones fijas (DM-V1) se rechazó por una comprobación predictiva. En 2025-H1 el log score fue -252 frente a $-3,338$.

La señal de mezcla rara marcó 0 de 12 semanas de calibración, 7 de 25 de validación (la ráfaga de enero y su eco) y 19 de 87 de ajuste, cuando una señal calibrada marcaría 0.9. Una sola κ no cubre los cambios de composición de 2023; es un límite declarado y el umbral no se recalibró.




Figura 8: p-valor semanal de mezcla rara (escala logarítmica). La línea marca el umbral 0.01 fijado antes de mirar; 2025-H1 ya estaba consultada.

4.5 Alertas de aumento persistente (M11)

Tabla 9: Detección de cada regla en los escenarios inyectados sobre la calibración (fracción detectada en 8 semanas y mediana del retraso en semanas) con el presupuesto de una falsa alarma al mes.

Escenario	CUSUM	Regla de una semana
Crecimiento 10 % semanal	42.3 % (5 sem.)	32.0 % (4 sem.)
Crecimiento 20 % semanal	70.9 % (4 sem.)	54.0 % (3 sem.)
Escalón +50 %	31.6 % (2 sem.)	36.1 % (1 sem.)
Escalón +100 %	51.6 % (2 sem.)	56.9 % (1 sem.)
Sin aumento (falsas alarmas)	6.5 % (5 sem.)	10.5 % (4 sem.)




Figura 9: Fracción detectada por escenario y regla. CUSUM gana en los dos crecimientos sostenidos, que son los que deciden.

Con umbrales $h = 3.37$ y $z^* = 2.53$, CUSUM detecta 10.3 % y 16.9 % más que la regla semanal en los crecimientos de 10 % y 20 %, por encima del 5 % exigido: **CUSUM es la regla vigente**. En los datos reales avisa 2.2 veces al mes en ajuste y 1.4 en calibración. En 2025-H1 (ya consultado) hubo 30 alertas en 25 semanas, buena parte de ellas el eco de la ráfaga de enero: M9 esperó de más para ese patrón y de menos para los otros en las semanas siguientes. Sobre la línea base anterior (v3) CUSUM detectaba 50.8 % y 79.7 % con más alarmas reales (2.2 al mes en calibración); la memoria corta de C-A da menos alertas y menos falsas, pero también menos detección, porque alcanza antes a un patrón que crece.

4.6 Bloque diario

Tabla 10: Candidatos de conteo diario: WIS en los 92 días de calibración (menor es mejor), ganancia frente a la Poisson de 7 días y cobertura. Todos aceptan la regla; gana el de menor WIS.

Candidato	WIS	Ganancia	Cobertura 80 / 95	Resultado
D-D, D-A con inflación de ceros	6.946	-25.0 %	87 % / 96 %	accepted · ganador
D-A, binomial negativa con día de semana	6.959	-24.9 %	86 % / 96 %	accepted
D-C, Fourier y tendencia local	7.173	-22.6 %	86 % / 96 %	accepted
D-B2, sin día de semana	7.696	-16.9 %	87 % / 96 %	accepted
D-B, espacio de estados diario	7.816	(piloto, 7 días)	— —	no evaluado en full: R-hat 1.68, árbol saturado




Figura 10: WIS diario de calibración de los candidatos de conteo y de la referencia Poisson de 7 días.

El efecto de día de semana es la pieza que más aporta (0.75 de WIS entre D-D y la variante sin ese efecto). El ganador por la regla pre-registrada es **D-D, D-A con inflación de ceros**, pero contra D-A la diferencia es -0.013 con IC $[-0.028, +0.001]$: la inflación de ceros no cambia la calibración y D-A queda como alternativa más simple. En 2025-H1 (reporte único, ya consultado) D-D da WIS 14.56 frente a 19.31 de la Poisson de 7 días, con cobertura 83 % y 94 %. El espacio de estados diario (D-B) quedó fuera por una regla fijada antes de verlo: su muestreador satura la profundidad de árbol en las dos parametrizaciones probadas y una corrida completa no cabe en las 8 horas por trabajo del clúster.

La Dirichlet-multinomial diaria (D-E, $\kappa = 261$, IC $[255, 268]$) mejora el log score de calibración de la multinomial de 7 días en 78.0 (IC $[+69.1, +87.0]$) y da la señal diaria de mezcla rara: marca 6 de 92 días de calibración.

Tabla 11: Regla diaria D-11 sobre D-D: fracción de ráfagas inyectadas detectadas en 14 días (mediana del retraso en días) con 4 falsas alarmas al mes; la última columna es el CUSUM semanal de M11 sobre las mismas ráfagas agregadas a semanas.

Escenario	CUSUM diario	Regla de un día	CUSUM semanal
Ráfaga $\times 2$ durante 3 días	28.2 % (2 d)	35.2 % (1 d)	30.4 %
Ráfaga $\times 3$ durante 1 día	24.8 % (1 d)	44.2 % (1 d)	29.1 %
Subida $\times 1.5$ durante 7 días	24.9 % (3 d)	26.7 % (2 d)	30.7 %
Sin aumento (falsas alarmas)	6.5 % (7 d)	10.6 % (7 d)	0.0 %




Figura 11: Fracción de ráfagas detectadas por cada regla diaria y por el CUSUM semanal. Ninguna regla diaria alcanza el 50 % exigido.

Con umbrales $h = 3.90$ y $z^* = 2.72$, la mejor regla diaria detecta 44.2 % de las ráfagas $\times 3$ de un día y 35.2 % de las $\times 2$ de tres días, por debajo del 50 % fijado: **D-11 no se adopta**. Además, con esos umbrales las alarmas reales son 8.3 (CUSUM) y 12.9 (un día) al mes en calibración, frente a las 4 presupuestadas: los excesos diarios tienen colas más pesadas que la normal supuesta por la simulación. M11 sigue siendo la única regla de alerta.

4.7 Tabla comparativa

La tabla comparativa del curso reúne 120 filas: cada candidato, su métrica, su referencia, su ganancia relativa con intervalo y la decisión. El anexo B la reproduce completa; la tabla 12 resume lo vigente.

Tabla 12: Componentes vigentes y su cifra de calibración y de validación (2025-H1 ya consultada salvo T1–T3, M9 y M10, confirmados antes de abrirla por segunda vez).

Componente	Vigente	Calibración	Validación
T1, motivo (90 clases)	TabPFN-3.5, PCA 100 + producto	Macro-F1 0.271	Macro-F1 0.270 (ya consultado)
T2, alguna solución	TF-IDF solo texto, logística calibrada	AP 0.609	AP 0.570
T3, compensación	TF-IDF solo texto	AP 0.364	AP 0.270
Reclamos parecidos	FAISS exacto sobre BGE	similitud mediana 0.924	—
Patrones	PCA 256 $\rightarrow$ UMAP 15 $\rightarrow$ k-means 40	0.88 % novedosos	0.77 %
M9, conteo semanal	C-A, NB jerárquica con memoria que decae	WIS 30.30	WIS 129.6 (ya consultado)
M10, composición semanal	DM-R4, $\kappa = 826$	log score -210	-252
M11, alertas	CUSUM sobre los excesos de C-A	1.4 alertas al mes	30 en 25 semanas (ya consultado)
Conteo diario	D-D, D-A con inflación de ceros	WIS 6.946	WIS 14.56 (ya consultado)
Alerta diaria D-11	no adoptada	detección máxima 44 %	no consultado

5 Discusión

5.1 Qué se eligió y por qué

El motivo se predice mejor con un modelo tabular en contexto que con un clasificador entrenado. TabPFN-3.5 no se ajusta a los datos: recibe 20,000 ejemplos y predice el resto. Aun así gana +12.9 % a la mejor combinación entrenada y mantiene la ventaja en 2025-H1. Que la ablación con 256 componentes empate y la de 1,024 columnas pierda dice que el límite está en cuántas columnas puede ver cada estimador, no en la riqueza del embedding. El costo es una licencia no comercial que un banco tendría que negociar.

Para solución y compensación, lo simple basta. TF-IDF con una regresión logística calibrada supera a la regla por producto y los embeddings no suman el 5 % exigido. La regla de orden de complejidad evitó quedarse con un modelo más caro por una décima.

Los patrones son una partición útil, no categorías. k-means sobre UMAP 15 pasó todos los criterios: grupos de tamaño razonable, estables entre submuestras y que cubren 99 % de los reclamos futuros. HDBSCAN dejaba la mitad de los reclamos como ruido y CURE juntaba casi todo en un grupo. La ronda de sensibilidad confirmó que ningún otro espacio da grupos claramente mejores, y que otra semilla de UMAP da otra partición de calidad parecida. Por eso el catálogo del anexo A describe cada patrón con sus palabras y ejemplos, para que la persona entienda qué agrupa, en lugar de tratarlos como etiquetas del negocio.

En el conteo semanal, la memoria corta gana a la sofisticación. La binomial negativa jerárquica con memoria que decae (C-A) mejora a la de cuatro semanas de igual peso y a tres alternativas más complejas: un espacio de estados con innovaciones t de Student (C-B), que no superó a v3 con claridad, y dos modelos fundacionales de series sin entrenamiento (Chronos-2 y TimesFM), que fueron peores que la referencia bayesiana. Las series de 40 patrones son cortas y ruidosas; un modelo que condiciona en el total de la semana y reparte por participación reciente captura lo esencial.

Las alertas necesitan un presupuesto explícito. Fijar una falsa alarma al mes y derivar los umbrales por simulación hizo comparable a CUSUM con la regla de una semana: CUSUM detecta más crecimiento sostenido con el mismo presupuesto. La elección se tomó con la regla de 5 puntos escrita antes.

A escala diaria, el conteo funciona y la alerta no. D-D predice el conteo diario de cada patrón con 25 % menos error que la Poisson de 7 días, y el efecto de día de semana es lo que más aporta. Pero una ráfaga de $\times 2$ durante tres días queda dentro del ruido de una binomial negativa con dispersión moderada, y los excesos diarios reales tienen colas más pesadas que la normal con la que se simulaban los umbrales: la regla avisa dos o tres veces más de lo presupuestado y detecta menos de la mitad. El bloque diario deja un modelo de expectativa diaria útil y una regla que habría que rediseñar con umbrales empíricos, no un sustituto de M11.

5.2 Qué no funcionó, y qué se aprendió

- **T4.** La respuesta fuera de plazo no se predice del texto: el modelo no supera a la regla por producto en validación y se reemplazó por una regla de plazo con calendario de feriados. Fue correcto fijar de antemano que la confirmación en validación podía rechazar un componente.
- **BGE solo texto para T1.** Perdió frente a TF-IDF + producto: el producto es una columna barata que vale más que la riqueza del embedding en esa tarea.
- **HDBSCAN y CURE.** Son más elegantes que k-means, pero los criterios de aceptación (ruido, cobertura futura, tamaño del grupo mayor) los descartaron. Los criterios estaban escritos antes de correr.
- **Modelos fundacionales de series.** Chronos-2 y TimesFM sin entrenamiento no ganan a una binomial negativa bien especificada en series cortas con total conocido. Su valor está en series largas sin covariables.
- **D-B, el espacio de estados diario.** Con 39 contrastes y 639 días, el muestreador satura la profundidad de árbol tanto en la parametrización centrada (R-hat 1.87) como en la no centrada (R-hat 1.68). Una corrida completa superaría las 8 horas del clúster. Un filtro de Kalman sobre una aproximación gaussiana sería la vía, fuera de esta ronda.
- **El eco de las ráfagas.** Cuando un patrón recibe más de la mitad de los reclamos de una semana, M9 espera de más para ese patrón y de menos para los otros en las semanas siguientes, y M11 avisa por eso. La memoria corta lo atenúa pero no lo corrige; un recorte de semanas atípicas se probó en ajuste y no ganó.

- **La señal de mezcla rara en 2023.** Marcó 19 de 87 semanas de ajuste: una única concentración κ no describe la variación de composición de ese año. La señal sirve como ordenación de semanas, no como prueba.
- **Kumo Tabular y Relational.** No cupieron en la memoria del clúster; quedan como prueba futura, igual que el ajuste fino de TabPFN.

El valor del pre-registro se vio en cada uno de estos casos: el criterio estaba escrito, la decisión fue mecánica y el resultado negativo quedó documentado con la misma calidad que el positivo.

6 Expectativas y limitaciones

6.1 Qué se puede esperar del prototipo

- Una sugerencia de motivo acertada entre las tres primeras en 96 % de los reclamos, que reduce lectura y derivaciones erradas pero no elimina la revisión.
- Probabilidades de solución y compensación útiles para priorizar, con precisión promedio 0.57 y 0.27 en el periodo posterior al ajuste.
- Una expectativa semanal por patrón con intervalos que cubren 97 % de los conteos en calibración, y alrededor de 1.4 alertas al mes para revisión humana en un periodo tranquilo; muchas más en un periodo con ráfagas, como 2025-H1.
- Una expectativa diaria por patrón con intervalos, para el día a día, sin alerta automática asociada.

6.2 Límites declarados

- **Etiquetas aproximadas.** El motivo y las respuestas de la CFPB no son las categorías internas de un banco peruano. T2 y T3 miden lo que la empresa respondió, no lo que el cliente merecía. Ninguna salida detecta fraude.
- **Taxonomía sin revisión del negocio.** El mapa canónico de productos y motivos es una propuesta congelada (proposed_no_business_review); un banco tendría que revisarlo antes de usar T1.
- **Validación consultada.** Todo lo decidido después del 2026-10-01 se eligió con ajuste y calibración, pero su cifra de 2025-H1 se conoció al confirmar los componentes iniciales. Esas cifras son informativas, no evidencia limpia. 2026 queda sellado como prueba final cuando su cobertura esté completa.
- **Licencias.** TabPFN-3.5 y TimesFM 3.0 tienen licencias de uso no comercial; sirven para esta evaluación académica, pero usar TabPFN con un banco requiere una licencia de Prior Labs. Un experto debe validar esa lectura antes de proponerlo.
- **Deriva.** Los modelos se ajustaron con 2023–2024. Cuando la composición de reclamos cambie, habrá que reajustar; el pipeline planificado prevé ajustar una vez y solo predecir mientras la deriva no obligue a repetirlo.
- **Eco de ráfagas.** Una semana muy concentrada en un patrón contamina las expectativas de las semanas siguientes y produce alertas que son eco, no novedad. La persona que revisa debe saberlo.
- **Escala diaria.** En estos datos históricos los días están completos; en producción los últimos días de la CFPB llegan incompletos, así que lo diario solo vale para días maduros o para datos propios sin rezago. No hay calendario de feriados en el modelo: un feriado se ve como un día de bajo volumen. La alerta diaria no se adoptó.
- **Patrones.** Son una partición útil, no categorías: otro espacio u otra semilla da grupos distintos de calidad parecida. El catálogo mitiga eso al describir cada patrón con palabras y ejemplos.
- **Cómputo.** Las corridas bayesianas completas necesitan un clúster (Khipu, cola estándar, hasta 8 horas por trabajo); un espacio de estados diario no cupo. El pipeline de inferencia, en cambio, solo predice y corre en un equipo común.
- **Transferencia.** El método se traslada a un banco; las cifras no. Con datos propios habría que repetir la preparación, el protocolo y las rondas de candidatos con los mismos criterios.

7 Conclusiones y trabajo futuro

7.1 Conclusiones

1. Es posible construir, con datos públicos y reglas fijadas de antemano, un prototipo de triaje que entrega evidencia útil en cada una de sus cinco salidas, y documentar con la misma calidad lo que funcionó y lo que no.
2. El motivo del reclamo se predice mejor con un modelo tabular en contexto sobre embeddings reducidos que con clasificadores entrenados: Macro-F1 0.271 frente a 0.076 de la regla por producto y 0.240 del mejor modelo entrenado, con la ventaja mantenida en 2025-H1.
3. Para solución y compensación bastan modelos lineales sobre TF-IDF; el producto y los embeddings no superan la regla del 5 %. La respuesta fuera de plazo no se predice del texto.
4. Un espacio semántico BGE con PCA y UMAP sostiene tanto la búsqueda de reclamos parecidos como una partición en 40 patrones estable y con cobertura futura de 99 %.
5. Una binomial negativa jerárquica con memoria corta predice el volumen semanal por patrón con 30 % menos error que la referencia Poisson y gana a alternativas más complejas; la Dirichlet-multinomial describe la composición semanal y da una señal de mezcla rara.
6. Un CUSUM sobre los excesos del modelo semanal, con una falsa alarma al mes fijada por simulación, detecta crecimientos sostenidos de 10 % y 20 % semanal en 42 % y 71 % de los casos simulados.
7. El bloque diario confirma la arquitectura a resolución de día para el conteo (25 % menos error que la referencia, con el día de semana como pieza principal) y muestra que una alerta diaria con el diseño de M11 no alcanza la detección exigida.
8. El pre-registro, la vista sin texto compartido y la evaluación hacia adelante costaron tiempo y evitaron resultados optimistas: dos candidatos mejores en apariencia se rechazaron por la regla del bootstrap y un componente se retiró al confirmarlo.

7.2 Trabajo futuro

- **Pipeline de inferencia** (planificado como rama aparte): ajustar una vez los componentes vigentes y, con datos nuevos que respeten las mismas columnas, solo predecir: motivo, probabilidades, vecinos, patrón, conteo semanal y diario, señal de composición y alertas semanales; reajustar solo cuando la deriva lo exija.
- **Alerta diaria, segunda versión pre-registrada**: umbrales empíricos sobre los excesos de ajuste en lugar de la normal simulada, y ráfagas mayores en los escenarios.
- **De sugerencias a acciones de triaje**: requiere definiciones del banco (equipos, mapeo de motivos a equipos, presupuesto de alertas revisables al mes).
- **Prueba final sellada en 2026** cuando la base de la CFPB complete ese año.
- **Licencias y alternativas**: validación experta de la licencia de TabPFN; ajuste fino y ensamble de TabPFN; Kumo Tabular con más memoria.
- **Transferencia a datos propios**: repetir la preparación y el protocolo con reclamos del banco y su taxonomía revisada.

Declaración de uso de inteligencia artificial

Este proyecto usó un asistente de programación basado en modelos de lenguaje (Claude Code, Anthropic) como herramienta de trabajo, de acuerdo con la política de uso aceptable de herramientas de IA de la institución del autor principal. El asistente ayudó a escribir código, pruebas, scripts de clúster y borradores de documentación, incluido este informe, siempre bajo la dirección del equipo y a partir de un registro de pre-registro escrito antes de cada corrida.

Las decisiones de modelado, las reglas de aceptación y la lectura de los resultados fueron revisadas por el equipo; las cifras de este documento se leen de los archivos de resultados del repositorio al renderizarlo, con el commit y el hash de datos de cada corrida registrados en MLflow. Los datos son públicos y no contienen información personal identificable más allá de lo que la CFPB publica con autorización del consumidor. La interpretación de las licencias de los modelos de terceros (TabPFN-3.5, TimesFM 3.0) debe ser validada por una persona experta antes de cualquier uso fuera de este contexto académico.

Anexo A. Catálogo de los 40 patrones

Cada patrón se describe con su producto principal, su tamaño en ajuste, los términos que lo distinguen (TF-IDF del patrón frente al resto) y su serie semanal con las bandas de M9 y las alertas de M11. Los ejemplos completos, con fragmentos de narrativa, están en <reports/modeling/patterns/catalogo.html>.

Patrón 00

Producto principal: Credit reporting or other personal consumer reports (84 % de sus reclamos). **Reclamos en ajuste:** 1,947 (21.4 por semana, 0.19 % del total). **Texto único:** 2 %. **Alertas de M11:** ajuste: 2023-12-25; validación: 2025-06-23.

Términos: disputes, submitting disputes, getting inaccurate, send disputes, bureaus having, disputes getting, tried send, information corrected, corrected credit, difficulties submitting.




Figura 12: Serie semanal del patrón 00

Patrón 01

Producto principal: Credit reporting or other personal consumer reports (86 % de sus reclamos). **Reclamos en ajuste:** 5,995 (65.8 por semana, 0.52 % del total). **Texto único:** 9 %. **Alertas de M11:** ajuste: 2023-05-08; validación: 2025-01-06.

Términos: 100, credit, 100 accurate, reporting 100, credit report, accurate, report, accounts, did, reporting.




Figura 13: Serie semanal del patrón 01

Patrón 02

Producto principal: Credit reporting or other personal consumer reports (98 % de sus reclamos). **Reclamos en ajuste:** 8,520 (93.1 por semana, 0.70 % del total). **Texto único:** 9 %. **Alertas de M11:** ajuste: 2023-07-10, 2024-01-22; validación: 2025-03-17.

Términos: section, information, consumer, 15, reporting, items, agency, reporting agency, 1681, states.




Figura 14: Serie semanal del patrón 02

Patrón 03

Producto principal: Credit reporting or other personal consumer reports (89 % de sus reclamos). **Reclamos en ajuste:** 35,532 (388.5 por semana, 3.17 % del total). **Texto único:** 53 %. **Alertas de M11:** validación: 2025-01-27, 2025-02-10, 2025-03-03.

Términos: redacted, redacted redacted, account, credit, information, consumer, reporting, report, fcra, credit report.




Figura 15: Serie semanal del patrón 03

Patrón 04

Producto principal: Credit reporting or other personal consumer reports (98 % de sus reclamos). **Reclamos en ajuste:** 13,290 (145.7 por semana, 1.24 % del total). **Texto único:** 31 %. **Alertas de M11:** ajuste: 2024-03-11; validación: 2025-02-03.

Términos: redacted redacted, redacted, validate, erroneous, credit, authorized fail, proof period, period allowed, allowed law, file listed.




Figura 16: Serie semanal del patrón 04

Patrón 05

Producto principal: Credit reporting or other personal consumer reports (85 % de sus reclamos). **Reclamos en ajuste:** 9,474 (103.8 por semana, 0.83 % del total). **Texto único:** 6 %. **Alertas de M11:** ajuste: 2023-04-17, 2023-05-22.

Términos: consumer, 15, section, states, reporting, report, reporting agency, 1681, consumer reporting, credit.




Figura 17: Serie semanal del patrón 05

Patrón 06

Producto principal: Credit reporting or other personal consumer reports (100 % de sus reclamos). **Reclamos en ajuste:** 13,745 (150.8 por semana, 1.37 % del total). **Texto único:** 41 %. **Alertas de M11:** validación: 2025-02-24.

Términos: redacted redacted, redacted, redacted balance, 00 redacted, balance, 00, records, complain question, question specific, coming wrongdoing.




Figura 18: Serie semanal del patrón 06

Patrón 07

Producto principal: Credit reporting or other personal consumer reports (93 % de sus reclamos). **Reclamos en ajuste:** 11,531 (126.4 por semana, 1.06 % del total). **Texto único:** 15 %. **Alertas de M11:** ajuste: 2023-03-20, 2023-04-03; validación: 2025-02-17.

Términos: redacted redacted, redacted, report, credit, disputes, accounts, credit report, verify, 3rd party, information.




Figura 19: Serie semanal del patrón 07

Patrón 08

Producto principal: Checking or savings account (39 % de sus reclamos). **Reclamos en ajuste:** 119,770 (1,313.3 por semana, 11.77 % del total). **Texto único:** 95 %. **Alertas de M11:** validación: 2025-01-13.

Términos: bank, card, account, redacted, 00, told, money, called, funds, check.




Figura 20: Serie semanal del patrón 08

Patrón 09

Producto principal: Credit reporting or other personal consumer reports (85 % de sus reclamos). **Reclamos en ajuste:** 2,670 (29.3 por semana, 0.24 % del total). **Texto único:** 5 %. **Alertas de M11:** sin alertas de M11.

Términos: complaint, party, complaint error, party involved, involved, reported, error, involved filing, complaint complaint, redacted party.




Figura 21: Serie semanal del patrón 09

Patrón 10

Producto principal: Credit reporting or other personal consumer reports (97 % de sus reclamos). **Reclamos en ajuste:** 9,158 (100.5 por semana, 0.84 % del total). **Texto único:** 19 %. **Alertas de M11:** ajuste: 2023-02-13; calibración: 2024-12-02.

Términos: redacted redacted, redacted, report, credit, credit report, consent, complaint, erroneous information, reports, written consent.




Figura 22: Serie semanal del patrón 10

Patrón 11

Producto principal: Credit reporting or other personal consumer reports (97 % de sus reclamos). **Reclamos en ajuste:** 97,126 (1,065.3 por semana, 9.38 % del total). **Texto único:** 67 %. **Alertas de M11:** ajuste: 2023-02-27; validación: 2025-01-27, 2025-02-17, 2025-06-02.

Términos: redacted redacted, redacted, 00, 00 redacted, redacted balance, balance, credit, inquiries, items, remove.




Figura 23: Serie semanal del patrón 11

Patrón 12

Producto principal: Debt collection (55 % de sus reclamos). **Reclamos en ajuste:** 86,363 (946.5 por semana, 8.30 % del total). **Texto único:** 88 %. **Alertas de M11:** validación: 2025-01-27.

Términos: debt, collection, redacted, redacted redacted, account, company, alleged, credit, collect, validation.




Figura 24: Serie semanal del patrón 12

Patrón 13

Producto principal: Credit reporting or other personal consumer reports (37 % de sus reclamos). **Reclamos en ajuste:** 97,382 (1,067.1 por semana, 9.56 % del total). **Texto único:** 88 %. **Alertas de M11:** validación: 2025-01-27, 2025-02-10.

Términos: loan, redacted, mortgage, payment, redacted redacted, told, payments, 00, paid, account.




Figura 25: Serie semanal del patrón 13

Patrón 14

Producto principal: Credit reporting or other personal consumer reports (94 % de sus reclamos). **Reclamos en ajuste:** 176,716 (1,936.1 por semana, 16.70 % del total). **Texto único:** 80 %. **Alertas de M11:** calibración: 2024-11-11; validación: 2025-01-20, 2025-02-03, 2025-05-26.

Términos: redacted, redacted redacted, account, credit, report, information, credit report, reporting, fcra, consumer.




Figura 26: Serie semanal del patrón 14

Patrón 15

Producto principal: Credit reporting or other personal consumer reports (98 % de sus reclamos). **Reclamos en ajuste:** 7,597 (83.2 por semana, 0.74 % del total). **Texto único:** 1 %. **Alertas de M11:** ajuste: 2023-05-08.

Términos: letters, bureaus continuously, far gotten, happened mailed, continuously far, really sure, sure happened, involved review, gotten response, mailed letters.




Figura 27: Serie semanal del patrón 15

Patrón 16

Producto principal: Credit reporting or other personal consumer reports (96 % de sus reclamos). **Reclamos en ajuste:** 9,342 (101.7 por semana, 0.74 % del total). **Texto único:** 3 %. **Alertas de M11:** ajuste: 2023-02-20, 2023-07-03, 2024-02-05.

Términos: consumer, 15, section, reporting agency, 1681, reporting, states, consumer reporting, agency, information.




Figura 28: Serie semanal del patrón 16

Patrón 17

Producto principal: Credit reporting or other personal consumer reports (94 % de sus reclamos). **Reclamos en ajuste:** 71,113 (779.1 por semana, 7.12 % del total). **Texto único:** 56 %. **Alertas de M11:** ajuste: 2023-02-27; validación: 2025-02-03.

Términos: redacted account, account, account redacted, section, redacted, redacted redacted, 15, 1681, states, consumer.




Figura 29: Serie semanal del patrón 17

Patrón 18

Producto principal: Credit reporting or other personal consumer reports (88 % de sus reclamos). **Reclamos en ajuste:** 10,792 (118.2 por semana, 0.97 % del total). **Texto único:** 24 %. **Alertas de M11:** ajuste: 2023-02-20, 2024-05-20.

Términos: redacted redacted, redacted, permitted, legitimate activity, report, legitimate, activity, credit report, credit, redacted balance.




Figura 30: Serie semanal del patrón 18

Patrón 19

Producto principal: Credit reporting or other personal consumer reports (91 % de sus reclamos). **Reclamos en ajuste:** 63,214 (692.8 por semana, 5.62 % del total). **Texto único:** 37 %. **Alertas de M11:** ajuste: 2024-01-01; validación: 2025-01-27.

Términos: credit, credit report, report, redacted redacted, redacted, identity, accounts, inquiries, theft, identity theft.




Figura 31: Serie semanal del patrón 19

Patrón 20

Producto principal: Credit reporting or other personal consumer reports (99 % de sus reclamos). **Reclamos en ajuste:** 3,371 (36.9 por semana, 0.29 % del total). **Texto único:** 3 %. **Alertas de M11:** ajuste: 2023-03-27, 2024-01-29.

Términos: consumer reports, consent, reports, consumer, consent fraud, reports consent, reports gave, gave written, consent report, purposes consumer.




Figura 32: Serie semanal del patrón 20

Patrón 21

Producto principal: Credit reporting or other personal consumer reports (57 % de sus reclamos). **Reclamos en ajuste:** 4,109 (45.0 por semana, 0.42 % del total). **Texto único:** 2 %. **Alertas de M11:** ajuste: 2023-02-20; validación: 2025-02-17.

Términos: start investigation, bureau start, documents want, want bureau, start, investigation accounts, accounts late, reporting late, late, attached documents.




Figura 33: Serie semanal del patrón 21

Patrón 22

Producto principal: Credit reporting or other personal consumer reports (96 % de sus reclamos). **Reclamos en ajuste:** 12,879 (141.1 por semana, 1.17 % del total). **Texto único:** 21 %. **Alertas de M11:** validación: 2025-02-10.

Términos: redacted redacted, redacted, law, written requests, violation federal, requests, items, federal law, consumer, accounts.




Figura 34: Serie semanal del patrón 22

Patrón 23

Producto principal: Credit reporting or other personal consumer reports (96 % de sus reclamos). **Reclamos en ajuste:** 6,407 (70.2 por semana, 0.55 % del total). **Texto único:** 5 %. **Alertas de M11:** ajuste: 2023-05-29.

Términos: 15, consumer, agency, section, reporting, reporting agency, 1681, states, consumer reporting, information.




Figura 35: Serie semanal del patrón 23

Patrón 24

Producto principal: Credit reporting or other personal consumer reports (84 % de sus reclamos). **Reclamos en ajuste:** 9,733 (106.2 por semana, 0.80 % del total). **Texto único:** 14 %. **Alertas de M11:** ajuste: 2024-04-22.

Términos: redacted redacted, items, redacted, stress, accounts, unseen, identity, disputed items, remove, stolen.




Figura 36: Serie semanal del patrón 24

Patrón 25

Producto principal: Credit reporting or other personal consumer reports (97 % de sus reclamos). **Reclamos en ajuste:** 14,204 (155.8 por semana, 1.37 % del total). **Texto único:** 33 %. **Alertas de M11:** ajuste: 2024-05-20; validación: 2025-02-03.

Términos: sections 609, sections, 609 611, 609, redacted, 611, redacted redacted, redacted balance, balance, 00.




Figura 37: Serie semanal del patrón 25

Patrón 26

Producto principal: Credit reporting or other personal consumer reports (91 % de sus reclamos). **Reclamos en ajuste:** 11,256 (123.5 por semana, 0.95 % del total). **Texto único:** 16 %. **Alertas de M11:** ajuste: 2023-12-18.

Términos: accounts, credit, report, credit report, information, 15, consumer, accounts credit, reporting, fcra 605b.




Figura 38: Serie semanal del patrón 26

Patrón 27

Producto principal: Credit reporting or other personal consumer reports (99 % de sus reclamos). **Reclamos en ajuste:** 8,018 (87.8 por semana, 0.71 % del total). **Texto único:** 13 %. **Alertas de M11:** ajuste: 2023-02-06.

Términos: redacted redacted, redacted, report, credit report, inquiry credit, fraud inquiry, remove fraud, theft remove, theft, information.




Figura 39: Serie semanal del patrón 27

Patrón 28

Producto principal: Credit reporting or other personal consumer reports (80 % de sus reclamos). **Reclamos en ajuste:** 6,960 (76.1 por semana, 0.55 % del total). **Texto único:** 10 %. **Alertas de M11:** ajuste: 2024-04-15.

Términos: accounts, report, debt, credit, 15, code, credit report, consumer, 15 code, inaccurate.




Figura 40: Serie semanal del patrón 28

Patrón 29

Producto principal: Credit reporting or other personal consumer reports (98 % de sus reclamos). **Reclamos en ajuste:** 9,166 (100.0 por semana, 0.77 % del total). **Texto único:** 19 %. **Alertas de M11:** ajuste: 2023-07-31; calibración: 2024-12-09; validación: 2025-02-24.

Términos: identity, theft, identity theft, redacted redacted, redacted, items, federal, federal trade, trade, report.




Figura 41: Serie semanal del patrón 29

Patrón 30

Producto principal: Credit reporting or other personal consumer reports (87 % de sus reclamos). **Reclamos en ajuste:** 21,597 (236.3 por semana, 1.76 % del total). **Texto único:** 32 %. **Alertas de M11:** ajuste: 2023-05-29, 2024-01-22, 2024-06-17; validación: 2025-02-24.

Términos: payment, late, payments, creditor, mailed delivered, periodic, delivered, periodic statement, 1637, 21 days.




Figura 42: Serie semanal del patrón 30

Patrón 31

Producto principal: Credit reporting or other personal consumer reports (78 % de sus reclamos). **Reclamos en ajuste:** 8,060 (88.0 por semana, 0.59 % del total). **Texto único:** 3 %. **Alertas de M11:** ajuste: 2023-03-27, 2024-03-04.

Términos: need reporting, reporting correction, correction company, identified inaccurate, inaccurate accounts, reviewing credit, report identified, accounts need, reviewing, identified.




Figura 43: Serie semanal del patrón 31

Patrón 32

Producto principal: Credit reporting or other personal consumer reports (95 % de sus reclamos). **Reclamos en ajuste:** 9,040 (99.2 por semana, 0.75 % del total). **Texto único:** 16 %. **Alertas de M11:** ajuste: 2023-06-05, 2024-03-18; calibración: 2024-12-23; validación: 2025-06-23.

Términos: redacted redacted, redacted, credit, late payment, section, consumer, 15, verify, information, 1681.




Figura 44: Serie semanal del patrón 32

Patrón 33

Producto principal: Credit reporting or other personal consumer reports (88 % de sus reclamos). **Reclamos en ajuste:** 7,051 (77.4 por semana, 0.63 % del total). **Texto único:** 2 %. **Alertas de M11:** ajuste: 2023-06-05, 2024-03-11.

Términos: payments, updated records, consistently maintained, precise updated, seeking precise, reflect timely, perplexing discover, maintained time, records accurately, payments perplexing.




Figura 45: Serie semanal del patrón 33

Patrón 34

Producto principal: Credit reporting or other personal consumer reports (99 % de sus reclamos). **Reclamos en ajuste:** 6,530 (71.5 por semana, 0.63 % del total). **Texto único:** 0 %. **Alertas de M11:** validación: 2025-06-16.

Términos: letters, bureaus continuously, happened mailed, really sure, far gotten, continuously far, sure happened, involved review, gotten response, mailed letters.




Figura 46: Serie semanal del patrón 34

Patrón 35

Producto principal: Credit reporting or other personal consumer reports (100 % de sus reclamos). **Reclamos en ajuste:** 2,888 (31.7 por semana, 0.26 % del total). **Texto único:** 0 %. **Alertas de M11:** ajuste: 2023-02-13, 2023-06-26, 2023-07-31.

Términos: dispute incorrect, invalid items, referenced issues, incorrect invalid, letter referenced, assistance creditors, gotten assistance, report gotten, documents letter, matter attached.




Figura 47: Serie semanal del patrón 35

Patrón 36

Producto principal: Credit reporting or other personal consumer reports (96 % de sus reclamos). **Reclamos en ajuste:** 53,587 (587.1 por semana, 5.02 % del total). **Texto único:** 73 %. **Alertas de M11:** ajuste: 2023-12-18; validación: 2025-02-03.

Términos: consumer, information, redacted, reporting, 15, redacted redacted, usc, 15 usc, consumer reporting, account.




Figura 48: Serie semanal del patrón 36

Patrón 37

Producto principal: Credit reporting or other personal consumer reports (85 % de sus reclamos). **Reclamos en ajuste:** 6,255 (68.6 por semana, 0.48 % del total). **Texto único:** 5 %. **Alertas de M11:** ajuste: 2024-01-08; validación: 2025-01-06.

Términos: letters, reporting, inaccurate date, date, written, 15, credit, report, section, 1681.




Figura 49: Serie semanal del patrón 37

Patrón 38

Producto principal: Credit reporting or other personal consumer reports (97 % de sus reclamos). **Reclamos en ajuste:** 6,321 (69.2 por semana, 0.51 % del total). **Texto único:** 8 %. **Alertas de M11:** sin alertas de M11.

Términos: payment, late, complaint, error, creditor, complaint bureaus, payment late, days payment, mailed delivered, payment date.




Figura 50: Serie semanal del patrón 38

Patrón 39

Producto principal: Credit reporting or other personal consumer reports (95 % de sus reclamos). **Reclamos en ajuste:** 8,485 (92.9 por semana, 0.72 % del total). **Texto único:** 12 %. **Alertas de M11:** ajuste: 2023-07-03, 2024-04-29.

Términos: section, consumer, 15, information, 1681, states, reporting agency, consumer reporting, agency, reporting.




Figura 51: Serie semanal del patrón 39

Anexo B. Tabla completa de candidatos

Reproducción de etapa_4_5_modelado_evaluacion/resultados/comparacion_modelos.csv: cada candidato con su métrica principal, su referencia, la ganancia relativa con el intervalo del bootstrap y la decisión. Las filas sin decisión son referencias o cifras informativas.

Etap	Tarea	Modelo	Rol	Con- junto	Métrica	Valor	Ganan- cia	IC 95 %	Deci- sión
M3	T1	baseline global frequency	calibra- cion	2024 q4	macro_f1	0.006	—	—	—
M5B	T1	product_rule	calibra- cion	2024 q4	macro_f1	0.076	—	—	—
M5B	T1	tfidf_product	candi- dato	calibra- cion 2024 q4	macro_f1	0.214	+52.4 %	[+0.071, +0.078]	reem- plaza
M5B	T1	bge_product	candi- dato	calibra- cion 2024 q4	macro_f1	0.240	—	—	—
M5B	T1	tfidf_text	candi- dato	calibra- cion 2024 q4	macro_f1	0.141	+84.6 %	[+0.061, +0.069]	reem- plaza
M5B	T1	bge_text	candi- dato	calibra- cion 2024 q4	macro_f1	0.158	-26.2 %	[-0.061, -0.053]	—

Etapa	Tarea	Modelo	Rol	Con- junto	Métrica	Valor	Ganan- cia	IC 95 %	Deci- sión
M5B	T1	bge_product	ganador M5B	calibra- cion 2024 q4	macro_f1	0.240	+11.9 %	[+0.023, +0.029]	reem- plaza
M3	T2	baseline global	baseline	calibra- cion 2024 q4	average_precision	0.001	—	—	—
M5B	T2	product_rule	baseline	calibra- cion 2024 q4	average_precision	0.004	—	—	—
M5B	T2	tfidf_product	candi- dato	calibra- cion 2024 q4	average_precision	0.012	+0.4 %	[+0.002, +0.003]	—
M5B	T2	tfidf_text	ganador M5B	calibra- cion 2024 q4	average_precision	0.009	+34.4 %	[+0.148, +0.164]	reem- plaza
M5B	T2	bge_text	candi- dato	calibra- cion 2024 q4	average_precision	0.006	−0.6 %	[−0.008, +0.001]	—
M5B	T2	bge_product	candi- dato	calibra- cion 2024 q4	average_precision	0.010	+0.2 %	[−0.003, +0.006]	—
M3	T3	baseline global	baseline	calibra- cion 2024 q4	average_precision	0.002	—	—	—
M5B	T3	product_rule	baseline	calibra- cion 2024 q4	average_precision	0.004	—	—	—
M5B	T3	tfidf_product	candi- dato	calibra- cion 2024 q4	average_precision	0.007	+1.6 %	[+0.001, +0.012]	—
M5B	T3	tfidf_text	ganador M5B	calibra- cion 2024 q4	average_precision	0.004	+109.3 %	[+0.177, +0.203]	reem- plaza
M5B	T3	bge_text	candi- dato	calibra- cion 2024 q4	average_precision	0.005	−8.0 %	[−0.039, −0.017]	—
M5B	T3	bge_product	candi- dato	calibra- cion 2024 q4	average_precision	0.001	−3.5 %	[−0.025, +0.002]	—
M3	T4	baseline global	baseline	calibra- cion 2024 q4	average_precision	0.006	—	—	—

Etapas	Tarea	Modelo	Rol	Con- junto	Métrica	Valor	Ganan- cia	IC 95 %	Deci- sión
M5B	T4	product_rule	baseline	calibra- cion 2024 q4	average_precision	0.011	—	—	—
M5B	T4	tfidf_product	ganador M5B	calibra- cion 2024 q4	average_precision	0.055	+16.8 %	[+0.003, +0.015]	reem- plaza
M5B	T4	tfidf_text	candi- dato	calibra- cion 2024 q4	average_precision	0.047	+50.7 %	[+0.004, +0.025]	reem- plaza
M5B	T4	bge_text	candi- dato	calibra- cion 2024 q4	average_precision	0.011	-44.5 %	[-0.031, -0.019]	—
M5B	T4	bge_product	candi- dato	calibra- cion 2024 q4	average_precision	0.042	-24.3 %	[-0.019, -0.008]	—
M5F bloque B	T1	bge_product	ganador M5B (refe- rencia)	calibra- cion 2024 q4	macro_f1	0.240	—	—	—
M5F bloque B	T1	TabPFN-3.5 (PCA 100 + producto)	ganador bloque B	calibra- cion 2024 q4	macro_f1	0.271	+12.9 %	[+0.027, +0.035]	reem- plaza
M5F bloque B	T1	bge_product	ganador M5B (refe- rencia)	vali- dacion 2025 h1 (ya con- sultada)	macro_f1	0.227	—	—	—
M5F bloque B	T1	TabPFN-3.5 (PCA 100 + producto)	candi- dato	vali- dacion 2025 h1 (ya con- sultada)	macro_f1	0.270	+19.0 %	[+0.039, +0.046]	—
M5F abla- ción §26	T1	TabPFN-3.5 (PCA 100 + producto)	referen- cia (blo- que B)	calibra- cion 2024 q4	macro_f1	0.271	—	—	—
M5F abla- ción §26	T1	TabPFN-3.5 (PCA 256 + producto)	candi- dato	calibra- cion 2024 q4	macro_f1	0.268	-1.0 %	[-0.006, +0.001]	no re- empla- za

Etap	Tarea	Modelo	Rol	Con- junto	Métrica	Valor	Ganan- cia	IC 95 %	Deci- sión
M5F abla- ción §26	T1	TabPFN-3.5x (BGE 1,024 + produc- to)	andi- dato	calibra- cion 2024 q4	macro_f1	0.192	-29.0 %	[-0.085, -0.073]	no re- empla- za
M5B §22	T1	product_rule	baseline	vali- dacion 2025 h1 (ya con- sultada)	macro_f1	0.068	—	—	—
M5B §22	T1	bge_product	ganador M5B	vali- dacion 2025 h1 (ya con- sultada)	macro_f1	0.227	—	[+0.156, +0.163]	confir- mado
M5B §22	T2	product_rule	baseline	vali- dacion 2025 h1 (ya con- sultada)	average_precision	0.1451	—	—	—
M5B §22	T2	tfidf_text	ganador M5B	vali- dacion 2025 h1 (ya con- sultada)	average_precision	0.1570	—	[+0.104, +0.138]	confir- mado
M5B §22	T3	product_rule	baseline	vali- dacion 2025 h1 (ya con- sultada)	average_precision	0.1027	—	—	—
M5B §22	T3	tfidf_text	ganador M5B	vali- dacion 2025 h1 (ya con- sultada)	average_precision	0.1070	—	[+0.116, +0.175]	confir- mado
M5B §22	T4	product_rule	baseline	vali- dacion 2025 h1 (ya con- sultada)	average_precision	0.1021	—	—	—
M5B §22	T4	tfidf_product	ganador M5B	vali- dacion 2025 h1 (ya con- sultada)	average_precision	0.1078	—	[-0.073, -0.018]	no con- firmado

Etapa	Tarea	Modelo	Rol	Con- junto	Métrica	Valor	Ganan- cia	IC 95 %	Deci- sión
M9	conteo sema- nal por patrón	b1_rolling_ baseline		calibra- cion 2024 q4	wis	64.883	—	—	—
M9	conteo sema- nal por patrón	b1_rolling_ baseline		calibra- cion 2024 q4	wis	43.056	—	—	—
M9	conteo sema- nal por patrón	baseline	baseline	calibra- cion 2024 q4	wis	138.950	—	—	—
M9	conteo sema- nal por patrón	Bino- mial ne- gativa jerár- quica con me- moria que de- cae (C- A)	candi- dato	calibra- cion 2024 q4	wis	30.296	+29.6 %	[−15.993, −9.503]	accep- ted
M9	conteo sema- nal por patrón	b1_rolling_ baseline		calibra- cion 2024 q4	wis	64.883	—	—	—
M9	conteo sema- nal por patrón	b1_rolling_ baseline		calibra- cion 2024 q4	wis	43.056	—	—	—
M9	conteo sema- nal por patrón	baseline	baseline	calibra- cion 2024 q4	wis	138.950	—	—	—
M9	conteo sema- nal por patrón	Bino- mial ne- gativa, partici- pacio- nes de 4 se- manas, global	candi- dato	calibra- cion 2024 q4	wis	47.719	−10.8 %	[−0.093, +9.445]	rejected_no_practical_g

Etapa	Tarea	Modelo	Rol	Con- junto	Métrica	Valor	Ganan- cia	IC 95 %	Deci- sión
M9	conteo sema- nal por patrón	b1_rolling_ baseline		calibra- cion 2024 q4	wis	64.883	—	—	—
M9	conteo sema- nal por patrón	b1_rolling_ baseline		calibra- cion 2024 q4	wis	43.056	—	—	—
M9	conteo sema- nal por patrón	baseline	baseline	calibra- cion 2024 q4	wis	138.950	—	—	—
M9	conteo sema- nal por patrón	Bino- mial ne- gativa, 4 sema- nas, je- rárqui- ca v3	candi- dato	calibra- cion 2024 q4	wis	32.418	+24.7 %	[−13.649, −7.624]	accep- ted
M9 §25.5	conteo sema- nal por patrón	Chro- nos-2 zero- -shot	candi- dato	calibra- cion 2024 q4	wis	36.017	−11.1 %	[−0.995, +9.032]	no re- empla- za
M9 §25.5	conteo sema- nal por patrón	Bino- mial ne- gativa jerár- quica con me- moría que de- cae (C- A)	candi- dato	calibra- cion 2024 q4	wis	30.296	+6.5 %	[−3.361, −0.845]	reem- plaza
M9 §25.5	conteo sema- nal por patrón	Bino- mial ne- gativa jerár- quica con me- moría que de- cae (C- A)	candi- dato	vali- dacion 2025 h1 (ya con- sultada)	wis	129.609	+3.0 %	[−21.066, +15.051]	—
M9 §25.5	conteo sema-	Espacio de es- tados,	candi- dato	calibra- cion 2024 q4	wis	31.951	+1.4 %	[−2.580, +1.570]	no re- empla- za

Etapa	Tarea	Modelo	Rol	Con- junto	Métrica	Valor	Ganan- cia	IC 95 %	Deci- sión
	nal por patrón	paseo aleatorio (C-B)							
M9 §25.5	conteo semanal por patrón	Ti-mesFM 3.0 ze-ro-shot	candi-dato	calibra-cion 2024 q4	wis	40.702	+1.6 %	[-4.774, +3.550]	no re-empla-za
M9 §22	conteo semanal por patrón	Bino-mial ne-gativa, 4 sema-nas, je-rárqui-ca v3	ganador M9	vali-dacion 2025 h1 (ya con-sultada)	wis	133.632	—	[-49.943, -17.068]	confir-mado
M9 §22	conteo semanal por patrón	b1_rolling_baseline	baseline	vali-dacion 2025 h1 (ya con-sultada)	wis	164.225	—	—	—
M10	compo-sición sema-nal	b2_rolling_baseline	baseline	calibra-cion 2024 q4	log_score	-460.931	—	—	—
M10	compo-sición sema-nal	b2_static	baseline	calibra-cion 2024 q4	log_score	-1,770.235	—	—	—
M10	compo-sición sema-nal	dirichlet_multinomial	candidate	calibra-cion 2024 q4	log_score	-210.144	—	[+205.134, +295.845]	accep-ted
M10	compo-sición sema-nal	b2_rolling_baseline	baseline	calibra-cion 2024 q4	log_score	-460.931	—	—	—
M10	compo-sición sema-nal	b2_static	baseline	calibra-cion 2024 q4	log_score	-1,770.235	—	—	—
M10	compo-sición sema-nal	dirichlet_multinomial	candidate	calibra-cion 2024 q4	log_score	-246.038	—	[+166.609, +263.190]	rejected_predictive

Etapa	Tarea	Modelo	Rol	Con- junto	Métrica	Valor	Ganan- cia	IC 95 %	Deci- sión
M10 §22	compo- sición sema- nal	dirichlet_multinomial	M10	validation 2025 h1 (ya con- sultada)	log_score	-251.688	—	—	confir- mado
M10 §22	compo- sición sema- nal	b2_rolling_baseline	baseline	validation 2025 h1 (ya con- sultada)	log_score	-3,337.898	—	—	—
M9D	compo- sición diaria	dm_static	baseline	calibra- cion 2024 q4	log_score	-424.804	—	—	—
M9D	compo- sición diaria	mn_rolling_baseline	baseline	calibra- cion 2024 q4	log_score	-229.647	—	—	—
M9D	compo- sición diaria	D-E: Di- richlet- -multi- nomial diaria	candi- dato	calibra- cion 2024 q4	log_score	-151.614	—	[+69.082, +87.043]	accep- ted
M9D	conteo diario	b1_rolling_baseline	baseline	calibra- cion 2024 q4	wis	9.263	—	—	—
M9D	conteo diario	baseline	baseline	calibra- cion 2024 q4	wis	19.617	—	—	—
M9D	conteo diario	D-C: bi- nomo- mial ne- gativa diaria, Fourier y ten- dencia	candi- dato	calibra- cion 2024 q4	wis	7.173	+22.6 %	[-2.505, -1.673]	accep- ted
M9D	conteo diario	b1_rolling_baseline	baseline	calibra- cion 2024 q4	wis	9.263	—	—	—
M9D	conteo diario	baseline	baseline	calibra- cion 2024 q4	wis	19.617	—	—	—
M9D	conteo diario	D-A: bi- nomial negati-	candi- dato	calibra- cion 2024 q4	wis	6.959	+24.9 %	[-2.689, -1.919]	accep- ted

Etap	Tarea	Modelo	Rol	Con- junto	Métrica	Valor	Ganan- cia	IC 95 %	Deci- sión
		va dia- ria con día de semana							
M9D	conteo diario	b1_rolling_baseline		calibra- cion 2024 q4	wis	9.263	—	—	—
M9D	conteo diario	baseline	baseline	calibra- cion 2024 q4	wis	19.617	—	—	—
M9D	conteo diario	D-B2: bino- mial ne- gativa diaria sin día de se- mana	candi- dato	calibra- cion 2024 q4	wis	7.696	+16.9 %	[−1.870, −1.245]	accep- ted
M9D	conteo diario	b1_rolling_baseline		calibra- cion 2024 q4	wis	9.263	—	—	—
M9D	conteo diario	baseline	baseline	calibra- cion 2024 q4	wis	19.617	—	—	—
M9D	conteo diario	D-D: bi- nomial negati- va dia- ria, in- flación de ceros	candi- dato	calibra- cion 2024 q4	wis	6.946	+25.0 %	[−2.702, −1.936]	accep- ted
M9D §28.2	conteo diario	D-D: bi- nomial negati- va dia- ria, in- flación de ceros	ganador M9D	calibra- cion 2024 q4	wis	6.946	+25.0 %	[−2.702, −1.936]	elegido
M9D §28.2	conteo diario	D-D: bi- nomial negati- va dia- ria, in- flación de ceros	ganador M9D	vali- dacion 2025 h1 (ya con- sultada)	wis	14.556	+24.6 %	[−6.745, −3.057]	—

Etapa	Tarea	Modelo	Rol	Con- junto	Métrica	Valor	Ganan- cia	IC 95 %	Deci- sión
M11D	alertas diarias, escena- rio burst_x2_3d	cusum	candi- dato	calibra- cion si- mulada	tasa_de_detec	0.082	—	—	no adapta- da
M11D	alertas diarias, escena- rio burst_x2_3d	daily	candi- dato	calibra- cion si- mulada	tasa_de_detec	0.052	—	—	no adapta- da
M11D	alertas diarias, escena- rio burst_x2_3d	weekly_cusum	referen- cia M11	calibra- cion si- mulada	tasa_de_detec	0.004	—	—	—
M11D	alertas diarias, escena- rio burst_x3_1d	cusum	candi- dato	calibra- cion si- mulada	tasa_de_detec	0.048	—	—	no adapta- da
M11D	alertas diarias, escena- rio burst_x3_1d	daily	candi- dato	calibra- cion si- mulada	tasa_de_detec	0.042	—	—	no adapta- da
M11D	alertas diarias, escena- rio burst_x3_1d	weekly_cusum	referen- cia M11	calibra- cion si- mulada	tasa_de_detec	0.001	—	—	—
M11D	alertas diarias, escena- rio rise_x1_5_7d	cusum	candi- dato	calibra- cion si- mulada	tasa_de_detec	0.049	—	—	no adapta- da
M11D	alertas diarias, escena- rio rise_x1_5_7d	daily	candi- dato	calibra- cion si- mulada	tasa_de_detec	0.067	—	—	no adapta- da
M11D	alertas diarias, escena- rio rise_x1_5_7d	weekly_cusum	referen- cia M11	calibra- cion si- mulada	tasa_de_detec	0.007	—	—	—
M11D	alertas diarias, escena- rio no- ne	cusum	candi- dato	calibra- cion si- mulada	tasa_de_detec	0.065	—	—	no adapta- da
M11D	alertas diarias, escena-	daily	candi- dato	calibra- cion si- mulada	tasa_de_detec	0.006	—	—	no adapta- da

Etapa	Tarea	Modelo	Rol	Con- junto	Métrica	Valor	Ganan- cia	IC 95 %	Deci- sión
	rio no- ne								
M11D	alertas diarias, escena- rio no- ne	weekly_cusum	referen- cia M11	calibra- cion si- mulada	tasa_de_detec	0i000	—	—	—
M11D	alertas diarias reales	cusum	candi- dato	ajuste	alertas_por_m	8i091	—	—	no adapta- da
M11D	alertas diarias reales	daily	candi- dato	ajuste	alertas_por_m	1i244	—	—	no adapta- da
M11D	alertas diarias reales	cusum	candi- dato	calibra- cion 2024 q4	alertas_por_m	8i271	—	—	no adapta- da
M11D	alertas diarias reales	daily	candi- dato	calibra- cion 2024 q4	alertas_por_m	1i293	—	—	no adapta- da
M11	alertas, escena- rio growth_10	cusum	ganador M11	calibra- cion si- mulada	tasa_de_detec	0i423	—	—	elegido
M11	alertas, escena- rio growth_10	weekly	candi- dato	calibra- cion si- mulada	tasa_de_detec	0i320	—	—	—
M11	alertas, escena- rio growth_20	cusum	ganador M11	calibra- cion si- mulada	tasa_de_detec	0i709	—	—	elegido
M11	alertas, escena- rio growth_20	weekly	candi- dato	calibra- cion si- mulada	tasa_de_detec	0i540	—	—	—
M11	alertas, esce- nario step_50	cusum	ganador M11	calibra- cion si- mulada	tasa_de_detec	0i316	—	—	elegido
M11	alertas, esce- nario step_50	weekly	candi- dato	calibra- cion si- mulada	tasa_de_detec	0i361	—	—	—
M11	alertas, escena- rio step_100	cusum	ganador M11	calibra- cion si- mulada	tasa_de_detec	0i516	—	—	elegido

Etapa	Tarea	Modelo	Rol	Con- junto	Métrica	Valor	Ganan- cia	IC 95 %	Deci- sión
M11	alertas, escenario step_100	weekly	candidato	calibracion simulada	tasa_de_detec	0.569	—	—	—
M11	alertas, escenario no-ne	cusum	ganador M11	calibracion simulada	tasa_de_detec	0.665	—	—	elegido
M11	alertas, escenario no-ne	weekly	candidato	calibracion simulada	tasa_de_detec	0.605	—	—	—
M11	alertas reales	cusum	ganador M11	calibracion 2024 q4	alertas_por_mes	1.449	—	—	—
M11	alertas reales	weekly	candidato	calibracion 2024 q4	alertas_por_mes	1.987	—	—	—
M11	alertas reales	cusum	ganador M11	validacion 2025 h1 (ya consultada)	alertas_por_mes	5.218	—	—	—
M11	alertas reales	weekly	candidato	validacion 2025 h1 (ya consultada)	alertas_por_mes	5.566	—	—	—
M7S bloque A	patrones semánticos	umap15_s42% kmeans_k40	ganador M7 (referencia)	muestra de ajuste	neighbour_lift	0.637	—	—	—
M7S bloque A	patrones semánticos	umap5_s42% kmeans_k40	candidato	muestra de ajuste	neighbour_lift	0.627	-1.7 %	[-0.014, -0.007]	no reemplaza
M7S bloque A	patrones semánticos	umap5_s42% gmm_k80_fallo	candidato	muestra de ajuste	neighbour_lift	0.614	-3.7 %	[-0.027, -0.020]	no reemplaza
M7S bloque A	patrones semánticos	umap10_s42% gmm_k80_fallo	candidato	muestra de ajuste	neighbour_lift	0.637	-0.0 %	[-0.003, +0.003]	no reemplaza

Etapas	Tarea	Modelo	Rol	Con- junto	Métrica	Valor	Ganan- cia	IC 95 %	Deci- sión
M7S bloque A	patro- nes se- mánti- cos	umap30_s42/ gmm_k80_fallo	andi- fallo	muestra de ajus- te	neighbour_lift	0.590	-7.5 %	[-0.053, -0.043]	no re- empla- za
M7S bloque A	patro- nes se- mánti- cos	umap15_s43/ gmm_k80_fallo	andi- fallo	muestra de ajus- te	neighbour_lift	0.627	-1.7 %	[-0.015, -0.007]	no re- empla- za

Anexo C. Reglas pre-registradas

Resumen de las reglas escritas en docs/registro/models_plan.md antes de correr cada etapa. El registro completo, con fechas y la evidencia de cada decisión, es un documento de bitácora del repositorio.

Ámbito	Regla	Parámetros
Protocolo	Tres ventanas por fecha; se decide en calibración; validación se abre una vez con todo congelado	ajuste 2023-01-01 a 2025-07-01
Protocolo	La vista sin texto compartido decide; la completa se reporta	42.8 % de filas comparten texto
Reemplazo	Un candidato reemplaza al vigente solo con ≥ 5 % de mejora relativa y el IC 95 % del bootstrap pareado por semanas entero a su favor	2,000 remuestreos, semilla 42
Orden	Los candidatos compiten del más simple al más complejo	T1-T4: regla $\rightarrow$ TF-IDF texto $\rightarrow$ TF-IDF + producto $\rightarrow$ BGE texto $\rightarrow$ BGE + producto
Patrones	Criterios de aceptación de la partición fijados antes de correr	ARI ≥ 0.6 , cobertura futura ≥ 70 %, grupo mayor ≤ 50 %, ruido ≤ 40 %
Novedad	Reclamo novedoso si su distancia al centro supera el percentil fijado de las distancias de ajuste	percentil 99
Bayesianos	Prior predictive, piloto y full; R-hat ≤ 1.01 , sin divergencias; cobertura 80 % en 70-90 % y 95 % en 88-99 %	aplica a M9, M10 y al bloque diario
M9	WIS en calibración contra el mejor baseline Poisson; la misma regla del 5 % con bootstrap	referencia B1-R4, WIS 43.11
M9 bloque C	δ y el recorte de semanas atípicas se eligen solo en ajuste	ganó $\delta = 0.5$ sin recorte
M10	Log score conjunto contra la multinomial de cuatro semanas; p-valor de mezcla rara con umbral fijado	aviso si $p < 0.01$

Ámbito	Regla	Parámetros
M11	Presupuesto de falsas alarmas fijado; umbrales por simulación; CUSUM se adopta si detecta ≥ 5 puntos más que la regla semanal en los dos crecimientos	1 al mes; $h = 3.37$, $z^* = 2.53$
Diario	Prueba aparte; el bloque semanal sigue vigente; si varios candidatos aceptan la regla, gana el de menor WIS	$\delta = 0.8$ elegido en ajuste; ganador D-D, D-A con inflación de ceros
Diario	D-B queda fuera del full si el piloto no converge o el full proyectado supera 8 h (fijado antes de ver el piloto)	R-hat del piloto 1.68
D-11	Se adopta si detecta $\geq 50\%$ de las ráfagas $\times 2/3$ días y $\times 3/1$ día con mediana de retraso ≤ 2 días	4 falsas alarmas al mes; no adoptada
Validación	Todo lo decidido después del 2026-10-01 reporta 2025-H1 como ya consultado; 2026 queda sellado	sin excepciones

Bibliografía

- [1] Consumer Financial Protection Bureau, «Consumer Complaint Database». 2026.
- [2] S. Xiao, Z. Liu, P. Zhang, y N. Muennighoff, «C-Pack: Packaged Resources To Advance General Chinese Embedding». 2023.
- [3] N. Hollmann *et al.*, «Accurate predictions on small data with a tabular foundation model», *Nature*, vol. 637, pp. 319-326, 2025, doi: 10.1038/s41586-024-08328-6.
- [4] M. Douze *et al.*, «The Faiss library». 2024.
- [5] L. McInnes, J. Healy, N. Saul, y L. Großberger, «UMAP: Uniform Manifold Approximation and Projection», *Journal of Open Source Software*, vol. 3, n.º 29, p. 861, 2018, doi: 10.21105/joss.00861.
- [6] J. Bracher, E. L. Ray, T. Gneiting, y N. G. Reich, «Evaluating epidemic forecasts in an interval format», *PLOS Computational Biology*, vol. 17, n.º 2, p. e1008618, 2021, doi: 10.1371/journal.pcbi.1008618.
- [7] O. Abril-Pla *et al.*, «PyMC: a modern, and comprehensive probabilistic programming framework in Python», *PeerJ Computer Science*, vol. 9, p. e1516, 2023, doi: 10.7717/peerj-cs.1516.
- [8] A. F. Ansari *et al.*, «Chronos: Learning the Language of Time Series». 2024.
- [9] A. Das, W. Kong, R. Sen, y Y. Zhou, «A decoder-only foundation model for time-series forecasting», en *Proceedings of the 41st International Conference on Machine Learning*, 2024.
- [10] E. S. Page, «Continuous inspection schemes», *Biometrika*, vol. 41, n.º 1-2, pp. 100-115, 1954, doi: 10.1093/biomet/41.1-2.100.