

Triaje automático de reclamos financieros

Informe de avance I — Exploración y transformación de datos

Equipo capstone

24 de agosto de 2026

Tabla de contenidos

Resumen ejecutivo	1
1 Estado del pipeline	2
2 El dato	4
2.1 Perfil de las 16 columnas	4
2.2 El contrato anti-fuga	4
3 Los objetivos y su definición	5
3.1 Qué puede pagar el dato	5
3.2 La regla de etiquetado, caso por caso	6
4 Cobertura temporal	7
5 Deriva de la taxonomía	8
6 Desbalance de clases	8
7 La narrativa	10
7.1 Cuánto del corpus es texto repetido	10
7.2 Qué hay dentro del texto	12
8 Contra quién se reclama, y desde dónde	14
8.1 Concentración de empresas	14
8.2 Geografía: qué queda del código postal	15
9 Tasas base de los objetivos	17
10 Sesgo por perfil del consumidor	19
11 El quiebre de 2026	22
12 Decisiones de diseño registradas	23
13 Riesgos abiertos	24
14 Próximos pasos	25
15 Reproducibilidad	25
Nota sobre uso de IA generativa	25

Resumen ejecutivo

Este informe documenta la **fase de exploración y transformación** del proyecto de triaje automático de reclamos financieros. No presenta modelos entrenados: presenta el dato, las decisiones

de diseño que condicionan todo lo que viene después, y los cuatro hallazgos que ya cambiaron el alcance del proyecto.

El dato. 3,837,184 reclamos del *Consumer Financial Protection Bureau* (CFPB) con narrativa escrita por el consumidor, 16 columnas, marzo 2015 – julio 2026. Todas las columnas llegan como texto y ocupan **5.12 GB** en memoria, de los cuales el 72% es la narrativa. De las 3,837,184 filas, solo **2,583,683 narrativas son únicas** (67.3%): casi un tercio del corpus son textos repetidos, casi siempre plantillas.

Cuatro hallazgos que cambian el alcance.

1. **El objetivo prometido en la propuesta no existe en el dato.** Las diapositivas ofrecían predecir *riesgo de disputa* usando el campo «Disputa del consumidor». Ese campo no está entre las 16 columnas: el CFPB dejó de publicarlo en 2017. El objetivo se redefine como **¿tuvo la empresa que compensar al cliente?**, declarado explícitamente como *proxy*.
2. **La variable de resultado no es binaria.** Company response to consumer tiene seis valores, no dos, y uno de ellos marca casos aún sin resolver. Tratarlos como «no hubo compensación» habría metido ruido dirigido en la etiqueta. La regla caso por caso está en la Sección 3.
3. **La tasa base se mueve más que cualquier modelo.** La proporción de reclamos con compensación pasa de 20% en 2015 a 11% en 2020, 46% en 2024 y 37% en 2025. Entrenar sobre la historia completa es entrenar sobre un fenómeno que ya no existe: el dataset principal se restringe al régimen **2023-2025**.
4. **2026 es un régimen distinto y hubo que excluirlo del conjunto de prueba.** El volumen cae 61% en un solo mes, la composición por producto se da vuelta y las tres tasas base se invierten a la vez. La explicación fácil —casos aún abiertos— queda descartada por el propio dato. El detalle está en Sección 11 es el hallazgo que más afecta el diseño de la evaluación.

Avance. 11 de 20 etapas del pipeline tienen su artefacto producido y verificado (Sección 1).

1 Estado del pipeline

Cada etapa deja un artefacto en `reports/artefactos/`. Este informe lee esos artefactos, nunca el dato crudo: por eso se genera en segundos y las secciones se completan solas a medida que el pipeline avanza. Una etapa sin artefacto aparece marcada como pendiente en su sección correspondiente.

Tabla 1: Estado de las etapas del pipeline. listo significa que el artefacto existe y fue verificado.

Etapa	Fase	Qué produce	Estado
E1	EDA	Perfil de tipos, nulos, cardinalidad y memoria	listo
D1b	Targets	Regla de etiquetado de T2/T3 caso por caso	listo
E2	EDA	Volumen por mes y cobertura temporal	listo
E3	EDA	Deriva de taxonomía: Product / Issue por año	listo
E9	EDA	Tasa base de los targets por año y por producto	listo
E4	EDA	Desbalance de clases: Pareto de Product e Issue	listo
E5	EDA	Duplicados y plantillas de narrativa	listo
E6	EDA	Narrativa: longitud, densidad de XXXX, PII residual	listo
E7	EDA	Concentración de empresas	listo
E8	EDA	Geografía: ZIP-3 y malformados	listo
E11	EDA	Sesgo por Tags y State, controlando por producto	listo
E12	EDA	Piso de señal: TF-IDF + LogReg	pendiente
E13	EDA	¿Vale un embedding? TF-IDF vs embedding local	pendiente
E14	EDA	Estructura latente: UMAP + HDBSCAN	pendiente
F2	Pipeline	Tipado y contrato de esquema (pandera)	pendiente
F3	Pipeline	Canonicalización de taxonomía	pendiente
F4	Pipeline	Deduplicación y splits temporales por grupo	pendiente
F5	Pipeline	Matriz de features y auditoría de fuga	pendiente
F6	Modelos	Métricas de T1-T4 y evaluación por cortes	pendiente
F7	Negocio	Simulación de la bandeja: FIFO vs riesgo	pendiente

2 El dato

2.1 Perfil de las 16 columnas

Tabla 2: Perfil del dato crudo. tier es el contrato de disponibilidad: F0 se conoce al recibir el reclamo, F1 lo declara el formulario, FX solo existe después de que la empresa respondió.

Columna	Tier	Valores únicos	% nulos	Largo medio	MB
Date received	F0	4,138	0	10	65.9
Consumer complaint narrative	F0	2,583,683	0	1022.4	3770.7
Company	F0	6,831	0	26.5	126.3
ZIP code	F0	6,938	0.01	5	47.6
State	F0	63	0.36	2	37
Tags	F0	3	90.42	14.5	34.8
Product	F1	21	0	45.5	195.9
Issue	F1	173	0	38.5	170
Sub-product	F1	85	1.36	17.8	93.6
Sub-issue	F1	266	8.74	40	163.3
Date sent to company	FX	4,120	0	10	65.9
Company response to consumer	FX	6	0	25.5	122.8
Timely response?	FX	2	0	3	40.2
Company public response	FX	11	46.79	93	210.7
Complaint ID	ID	3,837,184	0	7.4	56.4
Submitted via	FUE- RA	1	0	3	40.3

Tres lecturas de esta tabla:

- **No hay ninguna variable numérica de origen.** Todas las features numéricas habrá que construirlas desde el texto y las fechas.
- **Submitted via tiene un solo valor** (Web) en las 3.8 millones de filas: varianza cero, se elimina.
- **Complaint ID es único en el 100% de las filas**, así que sirve de clave de trazabilidad — y nunca como variable predictora.

2.2 El contrato anti-fuga

La decisión más importante de toda la fase. Las columnas se separan en tres niveles según **cuándo se conocen**:

Tier	Cuándo se conoce	Uso permitido
F0	al recibir el reclamo	variables predictoras de todos los modelos
F1	lo declara el formulario del CFPB	<i>etiqueta</i> del clasificador de motivo. En la bandeja de un banco este campo no existe, así que no puede ser variable predictora del modelo desplegable
FX	solo después de que la empresa respondió	únicamente objetivos y diagnóstico. Nunca variable predictora

Un modelo que use `Timely response?` o `Company response to consumer` para predecir riesgo obtendría métricas excelentes y sería inútil: esas columnas no existen en el momento en que hay que priorizar el reclamo. Una prueba automática (`tests/test_no_leakage.py`) falla si alguna columna FX aparece en la matriz de variables.

3 Los objetivos y su definición

3.1 Qué puede pagar el dato

Necesidad del negocio	Modelo	Objetivo
Clasificar el motivo del reclamo	T1, multiclase	motivo canónico derivado de Issue
Priorizar por riesgo de escalar	T2, binaria	la empresa tuvo que compensar
Costo económico esperado	T3, binaria	la compensación fue monetaria
Semáforo de plazo legal	T4, binaria	la respuesta salió fuera de plazo
Borrador de respuesta	agente, no se entrena	requiere set de evaluación con rúbrica
Causas raíz por producto y mes	agregación, no es un modelo	—

3.2 La regla de etiquetado, caso por caso

Tabla 3: Los seis valores de Company response to consumer y su traducción a los objetivos T2 y T3. Dos casos se excluyen del entrenamiento en lugar de codificarse como cero.

Valor	Filas	%	T2 com- pensó	T3 mone- tario	Lectura
Closed with explanation	2,548,866	66.43	0	0	resuelto sin compensar
Closed with non-mone- tary relief	1,175,215	30.63	1	0	compensación no econó- mica
Closed with monetary relief	98,150	2.56	1	1	compensación económica
Untimely response	11,092	0.29	0	0	la empresa no respondió a tiempo
Closed	3,741	0.1	0	0	categoría heredada, sin detalle
In progress	111	0	excluir	excluir	censura: aún sin resultado
(nulo)	9	0	excluir	excluir	sin etiqueta

El caso que importa es **In progress**: son reclamos cuyo resultado todavía no se conoce. Codifi- carlos como «no hubo compensación» equivale a afirmar algo que el dato no dice, y el error no sería aleatorio — se concentraría en los meses más recientes, que son justamente los del conjunto de prueba. Se excluyen, junto con los nulos.

Untimely response es distinto: sí es un desenlace, pero es *ausencia de respuesta*, no *ausencia de compensación*. Se etiqueta como cero y se marca con un indicador, para poder reportar su métrica por separado.

4 Cobertura temporal



Figura 1: Reclamos con narrativa recibidos por mes. El volumen crece de forma sostenida hasta 2025 y cae un 61% de un mes al siguiente en enero de 2026, quedándose después en una meseta baja durante seis meses. Una meseta no es un rezago de publicación.

La ventana 2023-2025 concentra el **66% de todo el corpus**. Restringir el entrenamiento a ese periodo no sacrifica volumen: sacrifica historia que ya no describe el fenómeno actual. Lo que sí queda fuera, y por otra razón, es 2026 —ver Sección 11.

5 Deriva de la taxonomía




Figura 2: Participación de cada producto en el total del año. Las categorías no son estables: el CFPB renombró la familia de *credit reporting* dos veces, y cada rebautizo aparece aquí como una categoría que nace mientras otra muere.

Esta figura es la razón por la que existe una **etapa de canonicalización**: antes de entrenar nada hay que traducir las 21 etiquetas crudas de producto a un conjunto estable de unas 11, y las 173 de Issue a entre 25 y 40. El mapa se revisa a mano, se versiona en `configs/taxonomia.yaml`, y una prueba de regresión exige que **cada etiqueta canónica exista tanto en entrenamiento como en prueba**.

6 Desbalance de clases

El clasificador de motivo (T1) tiene que elegir entre las etiquetas de Issue. Antes de entrenar nada conviene saber cómo se reparte el volumen entre ellas, porque de eso depende qué métrica tiene sentido y cuántas clases sobreviven a la canonicalización.




Figura 3: Concentración de las etiquetas de Issue en el régimen 2023-2025. Arriba, las doce etiquetas más frecuentes. Abajo, cuántas etiquetas hacen falta para cubrir cada fracción del volumen: seis bastan para el 80%, y las 86 restantes se reparten el 19% que queda.

Tabla 4: Desbalance en los dos niveles de la taxonomía declarada, en el corpus completo y en el régimen que se entrena. clases <1000 cuenta las etiquetas con tan pocas filas que ninguna métrica por clase es estable.

Nivel	Régimen	Clases	Top-1	Top-10	Clases hasta 80%	Clases <1000 filas
Pro-duct	histórico	21	43.6%	97.1%	4	2
Pro-duct	2023-2025	14	66.1%	98.8%	3	0
Issue	histórico	173	31.4%	78.6%	12	84
Issue	2023-2025	92	36.8%	86.9%	6	33

Dos consecuencias, y ninguna es cosmética.

La primera es que la canonicalización tiene menos trabajo del que parecía, pero uno más delicado. De las 173 etiquetas de Issue del corpus histórico, solo **92 existen en 2023-2025**: 81 pertenecen a taxonomías que el CFPB ya retiró. Agrupar las 173 sería construir un mapa para clases que nunca van a llegar. El mapa se construye sobre las 92, y las 81 restantes solo importan para el experimento de deriva.

La segunda es que el desbalance del régimen es peor que el del histórico, no mejor. La clase mayoritaria pasa de 31.4% a 36.8% y bastan seis etiquetas para cubrir el 80% del volumen. Un clasificador que responda siempre «información incorrecta en su reporte» acierta más de un tercio de las veces. Ese es el número que cualquier modelo tiene que superar, y es la razón por la que la métrica de T1 se reporta como **macro-F1** y no como exactitud: la exactitud premia justamente a ese modelo inútil.

7 La narrativa

7.1 Cuánto del corpus es texto repetido




Figura 4: Reparto de los reclamos según cuántas veces se repite su narrativa. En el régimen 2023-2025 solo el 48% de los reclamos tiene un texto que no aparece en ningún otro, y uno de cada cinco pertenece a un grupo de más de 500 copias.

Tabla 5: Las seis narrativas más repetidas del régimen 2023-2025, con su producto dominante. Son cartas modelo de disputa de crédito que circulan en internet; el consumidor las copia, cambia el nombre y las envía.

€Copias	Producto	Extracto
#30,078	Credit reporting or other person...	In accordance with the Fair Credit Reporting act. The List of accounts below has violated my fed...
#22,430	Credit reporting or other person...	My credit reports are inaccurate. These inaccuracies are causing creditors to deny me credit. Yo...
#88,312	Credit reporting or other person...	You have reported inaccurate and unauthorized accounts on my credit report, which is a violation...
#15,802	Credit reporting or other person...	Upon reviewing my credit report, I have identified inaccurate accounts that need reporting and c...
#54,446	Credit reporting or other person...	The Fair Credit Reporting Act (15 U.S. Code 1681) says (1) The banking system is dependent u...
#12,335	Credit reporting or other person...	I have not supplied proof under the doctrine of estoppel by silence, Engelhardt V. Gravens (mo ...

Qué cambia esto. En el corpus completo, el 41.4% de los reclamos comparte su narrativa con al menos otro; dentro del régimen 2023-2025 la cifra sube al **52.5%**. Dentro de esa ventana, la plantilla más copiada aparece 30,078 veces, siempre sobre el mismo producto.

Una división aleatoria de entrenamiento y prueba pondría copias del mismo texto a ambos lados. El modelo memorizaría la plantilla y la métrica de prueba mediría esa memorización, no su capacidad de generalizar. Por eso la división de la decisión D4 es **por grupo de narrativa**: el hash del texto normalizado define el grupo y un grupo nunca se parte.

Un detalle de método que conviene dejar anotado, porque explica una diferencia con las cifras de versiones anteriores del plan. Sobre el texto **tal cual llega**, la proporción de filas repetidas es 39.1% y el grupo mayor tiene 27,496 copias. Al normalizar —colapsar espacios y pasar a minúsculas— esas cifras suben a 41.4% y 30,110. La diferencia son copias de la misma carta con distinto espaciado. Como el agrupamiento sirve para impedir fuga, la definición correcta es la **normalizada**: es la más conservadora de las dos.

7.2 Qué hay dentro del texto




Figura 5: Izquierda: longitud de la narrativa en caracteres. Dos tercios de los reclamos caben en menos de mil caracteres, pero la cola llega hasta 36 mil. Derecha: reclamos con rastros de datos personales que el enmascaramento del CFPB no capturó, por cada cien mil. Las dos magnitudes se grafican por separado porque no comparten unidad ni escala.

Tabla 6: Perfil de la narrativa en el régimen 2023-2025. Los bloques XXXX son el enmascaramento que aplica el CFPB antes de publicar; el porcentaje de caracteres enmascarados mide cuánto del texto es ruido de anonimización.

Indicador	Valor
Longitud media	1,005 caracteres
Mediana / p90 / p99	661 / 2,068 / 5,874
Máximo	35,984
Reclamos con al menos un bloque XXXX	62.8%
Bloques XXXX por reclamo (media)	17.0
Caracteres enmascarados sobre el total	6.6%
Reclamos que mencionan un importe	18.5%
Reclamos con marcas de español	0.0019%

Tres lecturas, cada una con una consecuencia.

El enmascaramento es masivo y hay que tratarlo como una señal, no como ruido. El 63% de los reclamos contiene bloques XXXX y el 6.6% de todos los caracteres del corpus es enmascarado. Un TF-IDF

ingenuo convertiría xxxx en el token más frecuente del vocabulario. La normalización de la Fase 5 lo reemplaza por un marcador único y, en paralelo, **cuenta** los bloques: cuántos datos tuvo que ocultar el CFPB es en sí mismo un indicador de qué tan cargado de identificadores viene el reclamo.

El corpus es monolingüe a efectos prácticos. Las marcas de español aparecen en el 0.0019% de los textos. No hace falta un detector de idioma ni un modelo multilingüe; conviene volver a revisarlo si el CFPB empieza a publicar el canal en español.

Queda PII residual, y eso bloquea el envío de texto a servicios externos. 25,335 reclamos del régimen contienen al menos un patrón que el enmascarado no capturó: direcciones de correo, URL, cadenas de seis o más dígitos. Son pocos en proporción —menos del 1%— pero no son cero, y basta con que no sean cero. La regla 4 de la decisión D6 se mantiene: **ningún texto sale de la red del proyecto sin un segundo enmascarado**, y el nivel R1 local no tiene este problema en absoluto. Conviene tomar la cifra como cota superior: una cadena de seis dígitos puede ser un número de cuenta o puede ser un importe sin enmascarar, y este conteo no los distingue.

8 Contra quién se reclama, y desde dónde

8.1 Concentración de empresas




Figura 6: Arriba: porcentaje acumulado de reclamos a medida que se añaden empresas, ordenadas de mayor a menor volumen (eje horizontal logarítmico). Abajo: las diez empresas con más reclamos en el régimen 2023-2025. Tres burós de crédito reúnen el 72% del volumen del periodo que se entrena.

Tabla 7: Distribución de las empresas por volumen de reclamos en el régimen 2023-2025. Las 2,759 empresas con menos de diez reclamos aportan el 0.3% del volumen: no hay con qué estimarles un efecto propio y van a un bucket común.

Reclamos por empresa	Empresas	Reclamos	% del volumen
0-9	2,759	7,892	0.3%
10-99	1,157	37,605	1.5%
100-999	350	107,692	4.3%
1 000-9 999	87	257,139	10.2%
10 000+	18	2,113,522	83.7%

Dos consecuencias para el modelo. La primera es de codificación: con 4,371 empresas en el régimen y un 75% del volumen en las cinco primeras, un *one-hot* es inviable y una codificación

por frecuencia o por objetivo es obligatoria — calculada solo con datos anteriores al periodo de cada fila, para no filtrar el futuro. La cola larga se agrupa en un bucket OTRA.

La segunda es más incómoda y afecta a la interpretación de todo lo que venga después. Si tres burós de crédito concentran el 72% de los reclamos del régimen —contra el 61% del corpus completo—, un modelo de texto puede alcanzar buenas métricas aprendiendo a reconocer *de qué empresa se habla* en vez de *qué problema se describe*. El agrupamiento no supervisado de la etapa E14 tiene que correrse dos veces, con y sin los nombres de empresa enmascarados; si los grupos cambian mucho, ese hallazgo vale más que el agrupamiento original.

8.2 Geografía: qué queda del código postal




Figura 7: Izquierda: forma del campo ZIP code en el régimen 2023-2025. El CFPB enmascara los dos últimos dígitos de los códigos poco poblados y el código entero en algunos casos. Derecha: los doce estados con más reclamos. Los dos paneles están separados porque uno reparte el 100% entre tres categorías y el otro entre sesenta y una.

Tabla 8: Cardinalidad de los campos geográficos en el régimen 2023-2025. El prefijo de tres dígitos es la única unidad geográfica que sobrevive al enmascarado, y baja la cardinalidad de casi siete mil valores a 876.

Campo	Filas	% del régimen	Valores distintos
Reclamos del régimen	2,523,850	100.00%	—
ZIP code no nulo	2,523,850	100.00%	6,935
Con prefijo ZIP-3 utilizable	2,483,614	98.41%	876
State no nulo	2,515,633	99.67%	61

La decisión que sale de aquí. El código postal completo no sirve como variable: el 20.1% de los reclamos lo trae con los dos últimos dígitos enmascarados y el 1.6% no trae nada. Pero el prefijo de tres dígitos —el que identifica el área postal— sobrevive en el **98.4%** de las filas, y baja la cardinalidad de 6,935 valores a 876. La variable geográfica del proyecto es **ZIP-3, más un indicador booleano de que el código venía enmascarado**, que es informativo por sí mismo: el CFPB enmascara justamente los códigos de áreas poco pobladas.

Una corrección sobre el plan, menor pero conviene dejarla escrita: las 290 filas que el plan describía como «malformadas» no lo son. Son **nulos**, y están todos fuera del régimen 2023-2025 —dentro de la ventana que se entrena, ZIP code no tiene ni un nulo. No existe ningún valor con una forma distinta de las tres de la figura: entre los 2,523,850 reclamos del régimen, el campo o trae cinco dígitos, o trae tres y dos equis, o trae cinco equis. En el corpus completo el enmascarado afecta al 22.4% de las filas.

9 Tasas base de los objetivos




Figura 8: Tasa base anual de los tres objetivos binarios. Se grafican en paneles separados y no superpuestos porque sus escalas difieren en un orden de magnitud; forzarlos a un eje común aplanaría los dos de abajo hasta volverlos ilegibles.

Tabla 9: Tasas base por año. censurados son los reclamos marcados como aún sin resolver, excluidos del cálculo.

Año	Reclamos	Censurados	T2 %	T3 %	T4 %
2015	54,723	0	20.28	7.22	3.44
2016	77,766	0	18.93	7.29	3.96
2017	115,311	0	15.06	4.91	2.98
2018	118,393	1	17.87	4.76	2.02
2019	124,843	0	18.5	4.4	1.75
2020	174,297	0	11.25	3.81	1.39
2021	203,570	0	12.93	3.67	1.52
2022	337,273	0	32.19	2.74	0.8
2023	487,410	1	38.83	2.51	0.64
2024	814,384	7	45.8	1.71	0.47
2025	1,222,056	110	36.8	1.24	0.87
2026	107,158	1	18.27	6.62	3.52

Las tres series se mueven juntas en 2026 y en la dirección contraria a su tendencia. Eso no es ruido de un año incompleto: es el mismo fenómeno visto tres veces, y merece sección propia.

Tabla 10: Tasa base por producto crudo. Las diferencias entre productos son mayores que la señal que cualquier modelo puede extraer del texto, así que toda evaluación se reporta también por producto.

Producto	Reclamos	T2 %	T3 %	T4 %
Credit reporting or other personal consumer re...	1,671,841	47.33	0.06	0.18
Credit reporting, credit repair services, or o...	807,499	29.15	0.25	0.5
Debt collection	441,051	19.06	0.56	3.54
Checking or savings account	186,789	20.36	14.89	0.98
Mortgage	146,301	6.71	3.35	1.69
Credit card	126,827	32.61	17.37	0.58
Money transfer, virtual currency, or money ser...	120,644	8.75	5.47	1.55
Credit card or prepaid card	108,683	30.38	18.19	1.12
Student loan	62,620	6.32	1.53	10.02
Vehicle loan or lease	53,005	9.3	3.17	1.95

10 Sesgo por perfil del consumidor

El dato trae dos campos que describen a quien reclama: Tags, que marca si es *servicemember* o adulto mayor, y State. La pregunta obligatoria antes de poner un modelo a priorizar reclamos es si esos grupos reciben resultados distintos. La respuesta cruda es que sí, y es engañosa.

Un reclamo marcado Older American termina en compensación monetaria mucho más seguido que uno sin etiqueta. Pero los adultos mayores **no reclaman sobre los mismos productos**: solo el 21% de sus reclamos son del producto dominante del régimen, contra el 68% del resto. Y la tasa de compensación depende sobre todo del producto. Sin estratificar, lo que se mide es la mezcla de productos del grupo, no un trato distinto.

La figura pone las dos cifras lado a lado. La **cruda** es la proporción observada. La **ajustada** es la tasa que tendría el grupo si su mezcla de productos fuera la de la población — estandarización directa, calculada por estrato de producto y reagregada con los pesos de la población. La distancia entre ambas es la parte del efecto que explica la composición; lo que sobrevive al ajuste es lo que hay que mirar en serio.




Figura 9: Tasa cruda y tasa ajustada por producto para cada grupo de Tags, régimen 2023-2025. La línea punteada es la tasa de la población. Ajustar por producto reduce la brecha de compensación monetaria de los adultos mayores de siete veces a dos, pero no la elimina; en el objetivo T2 el ajuste apenas mueve la aguja.

Tabla 11: Cortes por Tags en el régimen 2023-2025. % producto dominante es el indicador de mezcla: cuánto pesa en el grupo el producto que domina la población. Es la columna que explica por qué la tasa cruda y la ajustada no coinciden.

Grupo	Reclamos	% prod. dominante	T2 crudo	T2 ajustado	T3 crudo	T3 ajustado
(población)	2,523,850	66%	40.09%	40.09%	1.64%	1.64%
(sin etiqueta)	2,347,041	68%	41.20%	40.55%	1.38%	1.55%
Servicemember	120,281	43%	26.25%	30.98%	3.02%	1.73%
Older American	43,058	21%	23.53%	28.30%	9.85%	3.07%
Older American, Servicemember	13,352	24%	23.07%	28.42%	8.04%	2.84%

El número que no se puede citar solo. En el régimen 2023-2025, un reclamo marcado Older American termina en compensación monetaria el **9.85%** de las veces, contra el **1.38%** de los reclamos sin etiqueta: una razón de 7.1 a 1. Controlando por producto, las tasas pasan a 3.07% y 1.55%, y la razón cae a 2.0 a 1. Es decir: **la composición explica alrededor del 82% de la brecha**, pero no toda.

Eso deja dos obligaciones, no una.

La primera es de comunicación: la cifra cruda no puede aparecer en una diapositiva sin su versión ajustada al lado. Decir que los adultos mayores reciben siete veces más compensación monetaria es describir su cartera de productos, no el trato que reciben.

La segunda es que **el residuo no es cero y no se puede archivar**. Después de ajustar, Older American sigue duplicando la tasa de compensación monetaria y sigue 12 puntos por debajo en T2. El ajuste por producto crudo es un control grueso: quedan afuera el sub-producto, el motivo y la empresa. La evaluación por cortes de la Fase 6 tiene que reportar métricas por estos grupos de forma rutinaria, y un modelo que priorice reclamos no puede usar Tags como variable sin que alguien decida explícitamente que eso es aceptable.




Figura 10: Lo mismo, para los doce estados con más reclamos. Aquí el ajuste sí cierra casi toda la diferencia: la dispersión entre estados en T2 se reduce a menos de tres puntos, y lo que parecía una brecha geográfica en T3 es en su mayor parte una diferencia en qué productos se reclama en cada estado.

Tabla 12: Cortes por State en el régimen 2023-2025, ordenados por volumen. La dispersión que queda después del ajuste es del orden de la décima de punto porcentual: no hay un efecto geográfico grande escondido detrás de la composición.

Estado	Reclamos	% prod. dominante	T2 crudo	T2 ajustado	T3 crudo	T3 ajustado
(población)	2,523,850	66%	40.09%	40.09%	1.64%	1.64%
TX	357,157	71%	42.48%	41.10%	0.98%	1.42%
FL	313,733	70%	42.18%	40.55%	1.18%	1.57%
CA	248,188	63%	39.62%	40.54%	2.60%	1.95%
GA	197,682	71%	41.00%	39.40%	0.81%	1.28%
NY	143,210	65%	40.37%	40.49%	2.27%	1.90%
IL	124,578	66%	40.57%	40.43%	1.21%	1.21%
NC	98,934	69%	41.25%	40.03%	1.28%	1.61%
PA	91,776	64%	40.67%	40.55%	1.67%	1.65%
NJ	79,375	66%	40.74%	40.39%	2.00%	1.86%
MD	61,207	66%	40.09%	40.16%	1.55%	1.59%
SC	60,248	72%	42.41%	40.88%	0.90%	1.37%
MI	59,802	63%	37.77%	38.58%	1.70%	1.65%

El contraste con Tags es lo interesante. Entre los doce estados más grandes, el rango de la tasa T2 pasa de 4.7 puntos porcentuales en crudo a 2.5 después de ajustar, y la razón entre el estado con más y el con menos compensación monetaria baja de 3.2 a 1.6. Dicho de otro modo: **la geografía casi no aporta nada por sí misma**, y lo que parecía un efecto de estado era la mezcla de productos que se reclama en cada uno.

Esto tiene una consecuencia práctica que ahorra trabajo: no hace falta tratar el estado como una variable sensible con manejo especial, pero sí conviene dejar el corte en la evaluación por si el patrón cambia con los datos nuevos. Y refuerza lo del apartado anterior — que el residuo de Tags sobreviva al mismo ajuste que borra el de State es precisamente lo que lo hace digno de atención.

11 El quiebre de 2026

Al empezar el análisis, la explicación de trabajo para las cifras raras de 2026 era la obvia: **censura**, es decir, reclamos recientes cuyo desenlace todavía no se ha registrado. El dato descarta esa explicación y deja algo más incómodo en su lugar.

Evidencia 1 — el campo de censura está vacío. De los 107,158 reclamos de 2026, **exactamente uno** aparece marcado como In progress. Si el problema fuera que los casos siguen abiertos, ese contador sería enorme. No lo es.

Evidencia 2 — el volumen no decae, se quiebra. Diciembre de 2025 cierra con 56,510 reclamos y enero de 2026 con 22,211: una caída del 61% en un mes. Después el volumen se queda en una meseta de entre 10 mil y 22 mil durante seis meses. Un rezago de publicación produce una cola que se desvanece en los últimos uno o dos meses, no un escalón seguido de una meseta estable.

Evidencia 3 — cambia la composición, no solo la cantidad. Es el argumento decisivo. En 2025 la familia *credit reporting* representaba el 75% de los reclamos del año; en 2026 cae al 4%, mientras *debt collection* sube de 8% a 34% y *checking or savings account* de 4% a 18% (Figura 2). Un rezago de publicación retrasa reclamos de todos los tipos por igual y **conserva la mezcla**. Aquí la mezcla se da vuelta por completo.

Conclusión. Las tres piezas apuntan a lo mismo: 2026 no es 2025 con menos datos, es un **proceso generador distinto**. El dato por sí solo no dice por qué —eso exige verificar qué cambió en la operación o en la política de publicación del CFPB durante ese periodo, y es una pregunta abierta que el equipo debe resolver con fuentes externas, no con el parquet.

Consecuencia operativa, que ya se aplicó: el régimen de entrenamiento se cierra en **diciembre de 2025**, y la división temporal se reacomoda íntegramente dentro de él — entrenamiento 2023-01 a 2024-12, validación 2025-01 a 2025-06, prueba 2025-07 a 2025-12. La propuesta original usaba 2026 como periodo de prueba; hacerlo habría significado medir el modelo contra una distribución que no es la que verá en producción, y habría producido un número de evaluación pesimista y sin sentido.

12 Decisiones de diseño registradas

#	Decisión	Consecuencia
D1	El objetivo prometido no existe; se reemplaza por «la empresa compensó», declarado como <i>proxy</i>	cambia la promesa de la propuesta
D1b	Regla de etiquetado caso por caso; In progress y nulos se excluyen	evita ruido dirigido en la etiqueta
D2	Contrato F0 / F1 / FX de disponibilidad temporal	ninguna columna post-respuesta puede ser variable predictora
D3	Ventana de entrenamiento restringida a 2023-2025	descarta historia que ya no describe el fenómeno, y excluye el régimen distinto de 2026
D4	División temporal y por grupo de narrativa, nunca alea-	las plantillas repetidas no pueden cruzar de entrenamiento a prueba, y la evalua-

#	Decisión	Consecuencia
	toria; prueba en 2025-07 a 2025-12	ción ocurre dentro de un régimen estable
D5	Muestra de desarrollo de 300 mil filas estratificada	itera en minutos, no en horas
D6	Tres niveles de representación del texto, cada uno detrás de un criterio de costo-beneficio explícito	no se gasta en modelos de lenguaje sin evidencia de que aportan

La justificación completa de cada una está en docs/plan-eda-y-transformacion.md.

13 Riesgos abiertos

Riesgo	Estado	Mitigación
El objetivo de la propuesta no existe	confirmado	D1: se usa un proxy y se declara como tal
Empresa como atajo del modelo	abierto	tres burós concentran el 72% del régimen; E14 debe repetirse con los nombres enmascarados (Sección 8.1)
PII residual en la narrativa	medido , mitigación obligatoria	menos del 1% de los textos, pero no cero: segundo enmascarado antes de cualquier llamada externa (Sección 7.2)
El quiebre de 2026 no tiene causa identificada	abierto , ya mitigado en el diseño	2026 excluido; la prueba se mueve a 2025-07/2025-12. Falta confirmar la causa con fuentes externas al dataset
Fuga por columnas post-respuesta	controlado	prueba automática que falla si aparece una columna FX
Fuga por plantillas duplicadas	controlado por diseño, y más grave de lo previsto	división por grupo de narrativa; 52% de las filas del régimen 2023-2025 comparte texto con otra (Sección 7.1)
Deriva de etiquetas y de tasa base	cuantificado	régimen 2023+, mapa canónico versionado, prueba de regresión

Riesgo	Estado	Mitigación
Sesgo por perfil del consumidor	medido , con un residuo abierto	la mezcla de productos explica ~4/5 de la brecha de Older American, pero no toda; State se explica casi entero (Sección 10). Cortes obligatorios en la evaluación de la Fase 6

14 Próximos pasos

1. Completar las etapas de exploración que siguen pendientes en Sección 1.
2. Confirmar con fuentes externas qué originó el quiebre de 2026 (Sección 11). El diseño ya no depende de esa respuesta, pero el informe final necesita poder nombrar la causa en lugar de solo describirla.
3. Cerrar el contrato de tipos con validación automática de esquema: baja las 15 columnas no textuales de 1.54 GB a 0.29 GB y hace que iterar deje de ser costoso.
4. Construir el mapa canónico de taxonomía, con el agrupamiento no supervisado como evidencia de respaldo.
5. Establecer el piso de señal con un modelo simple antes de invertir en modelos grandes.

15 Reproducibilidad

Todo el contenido de este informe se regenera desde el dato crudo con:

```
uv sync
dvc pull                                # descarga el dataset versionado
uv run python -m src.data.profile        # E1
uv run python -m src.data.agregados      # D1b, E2, E3, E4, E7, E8, E9
uv run python -m src.data.narrativa      # E5, E6 (dos pasadas por la
narrativa)
uv run python -m src.evaluation.slices   # E11
uv run quarto render reports/informe     # este documento
```

El informe lee exclusivamente los CSV de reports/artefactos/, nunca el parquet de 1.6 GB. Las secciones sin artefacto se marcan como pendientes en lugar de fallar, así que el documento siempre compila.

Nota sobre uso de IA generativa

Se utilizaron herramientas de IA generativa como apoyo en la redacción de código y de este documento. Todas las cifras presentadas se calcularon sobre el dato real mediante el código versionado en src/, y son verificables ejecutando los comandos de Sección 15. Las decisiones de diseño y su justificación fueron revisadas por el equipo.