UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA

ESCUELA DE POSGRADO



UTEC Posgrado

TRIAJE DE RECLAMOS FINANCIEROS CON REVISIÓN HUMANA: MOTIVO SUGERIDO, RESULTADOS HISTÓRICOS, PATRONES SEMÁNTICOS Y ALERTAS SOBRE LOS RECLAMOS PÚBLICOS DE LA CFPB

TRABAJO DE INVESTIGACIÓN

Para optar el grado de Maestro en Ciencia de Datos e Inteligencia Artificial

AUTORES

Piero Palacios Bernuy (ORCID: PENDIENTE)

Winston Flores (ORCID: PENDIENTE)

Gianmarco Mejía (ORCID: PENDIENTE)

Edgard Froylan Inga Quillas (ORCID: PENDIENTE)

ASESOR

PENDIENTE: nombres y apellidos (ORCID: XXXX-XXXX-XXXX-XXXX)

Lima – Perú

2026

DEDICATORIA

PENDIENTE (equipo): texto de la dedicatoria, en cursiva según la plantilla.

AGRADECIMIENTOS

PENDIENTE (equipo): agradecimientos. Sugerencia: al asesor del curso, al equipo del clúster Khipu de UTEC por el cómputo, y a la CFPB por publicar los datos.

TABLA DE CONTENIDO

RESUMEN 9
ABSTRACT 10
CAPÍTULO I. VISIÓN DEL PROYECTO 11
1.1 Problema y oportunidad 11
1.2 Usuarios, clientes y casos de uso 12
1.3 Objetivo general 12
1.4 Objetivos específicos 12
1.5 Propuesta de valor y KPIs de éxito 13
1.6 Hipótesis o tesis del proyecto 15
CAPÍTULO II. ANÁLISIS Y FUNDAMENTOS DEL PROYECTO 15
2.1 Antecedentes y revisión de literatura 15
2.2 Bases teóricas y conceptuales 16
2.3 Análisis del mercado, industria o contexto 17
2.4 Benchmarking y competencia 17
2.5 Datos, recursos y viabilidad 19
2.6 Consideraciones normativas, éticas y de privacidad 20
CAPÍTULO III. PROPUESTA 20
3.1 Descripción de la solución 20
3.2 Arquitectura o diseño funcional 21
3.3 Requisitos funcionales y no funcionales 23
3.4 Evolución de producto o roadmap de solución 24
3.5 Modelo de negocio o sostenibilidad de la solución 24
CAPÍTULO IV. METODOLOGÍA Y DESARROLLO DEL PROYECTO 24
4.1 Tipo y enfoque de investigación 24
4.2 Diseño metodológico 24
4.3 Técnicas e instrumentos de recolección 26
4.4 Alcance del prototipo, MVP o solución 27
4.5 Construcción o implementación 27
CAPÍTULO V. VALIDACIÓN Y RESULTADOS 33
5.1 Framework de validación y experimentos 33
5.2 Validación funcional, técnica u operativa 35
5.3 Resultados y métricas alcanzadas 36
5.4 Tracción o evidencia de adopción (si aplica) 46
5.5 Discusión de resultados 46
CAPÍTULO VI. IMPLEMENTACIÓN, VIABILIDAD Y SIGUIENTE FASE 54
6.1 Viabilidad operativa y tecnológica 54
6.2 Viabilidad financiera 55
6.3 Roadmap y siguientes pasos 56
6.4 Cronograma o diagrama de Gantt 57
6.5 Riesgos y estrategias de mitigación 58
CONCLUSIONES 60
REFERENCIAS BIBLIOGRÁFICAS 60
ANEXOS 62
Anexo A. Catálogo de los 40 patrones 62
Anexo B. Tabla completa de candidatos 81
Anexo C. Reglas pre-registradas 108

ANEXO D. Mapa de la rúbrica del informe de cierre (P4) 110
ANEXO E. Declaración de uso de inteligencia artificial 112
ANEXO F. Repositorio, trazabilidad e historial de versiones 113
Bibliografía 114

ÍNDICE DE TABLAS

Tabla 1. Roles alrededor de la decisión de triaje. Los cargos son los de una entidad financiera tipo y se declaran como supuesto; la participación de cada rol en este proyecto fue documental.

Tabla 2. Indicadores de éxito del proyecto: métrica, referencia a vencer, criterio de éxito fijado antes de correr, resultado alcanzado y plazo. El KPI de negocio queda pendiente de los Product Lead.

Tabla 3. Mapa de alternativas: contra qué compite el prototipo y por qué no alcanzan. Las filas del statu quo y de las herramientas comerciales son evidencia documental declarada, no observación en una entidad.

Tabla 4. Inventario de datos: fuente, unidad de análisis, volumen, periodo, objetivos, acceso y restricción de uso.

Tabla 5. Las cinco salidas del prototipo, el componente que las produce, su cifra vigente en calibración y para qué sirve a la persona que hace el triaje.

Tabla 6. Requisitos del prototipo y cómo se cumplen o verifican.

Tabla 7. Fases de CRISP-DM, qué se hizo en cada una y dónde está la evidencia en el repositorio.

Tabla 8. Filas por periodo temporal. Solo 2023–2024 y 2025-H1 entran en el modelado; 2015–2022 es contexto, 2025-H2 quedó bloqueado por un experimento anterior y 2026 es parcial.

Tabla 9. Etapas de preparación (P1–P5) tal como las registra el informe de limpieza.

Tabla 10. Problemas encontrados en los datos y su tratamiento, del informe de limpieza.

Tabla 11. Ventanas temporales y filas elegibles por vista. La vista sin texto compartido decide; la completa se reporta.

Tabla 12. Hipótesis del proyecto, experimento que las prueba y veredicto. El detalle de cada cifra está en la sección 5.3.

Tabla 13. T1, motivo del reclamo: Macro-F1 en calibración sin texto compartido, en el orden en que compitieron. Cada fila reemplaza a la anterior solo si cumple la regla del 5 % con el bootstrap a favor.

Tabla 14. T2 (alguna solución registrada) y T3 (compensación monetaria): precisión promedio en calibración sin texto compartido y confirmación en 2025-H1. T4 no se confirmó.

Tabla 15. Las tres familias de agrupamiento sobre UMAP 15 (mejor configuración de cada una, muestra de 20,000 reclamos de ajuste). Solo k-means pasa todos los criterios.

Tabla 16. Candidatos de M9 por WIS en las 12 semanas de calibración (menor es mejor) y cobertura de los intervalos de 80 % y 95 %. Las referencias no compiten.

Tabla 17. Detección de cada regla en los escenarios inyectados sobre la calibración (fracción detectada en 8 semanas y mediana del retraso en semanas) con el presupuesto de una falsa alarma al mes.

Tabla 18. Candidatos de conteo diario: WIS en los 92 días de calibración (menor es mejor), ganancia frente a la Poisson de 7 días y cobertura. Todos aceptan la regla; gana el de menor WIS.

Tabla 19. Regla diaria D-11 sobre D-D: fracción de ráfagas inyectadas detectadas en 14 días (mediana del retraso en días) con 4 falsas alarmas al mes; la última columna es el CUSUM semanal de M11 sobre las mismas ráfagas agregadas a semanas.

Tabla 20. Componentes vigentes y su cifra de calibración y de validación (2025-H1 ya consultada salvo T1–T3, M9 y M10, confirmados antes de abrirla por segunda vez).

Tabla 21. D-11 v2 sobre D-D: fracción de ráfagas inyectadas detectadas en 14 días (mediana del retraso en días) con umbrales empíricos y 4 falsas alarmas al mes; la última columna es el CUSUM semanal de M11 sobre las mismas ráfagas.

Tabla 22. Las cuatro preguntas a Theorizer: papers con hallazgos extraídos, teorías formadas y juicios de novedad por grado.

Tabla 23. Qué hace falta para operar el prototipo y cada cuánto reentrenar cada componente, según las señales que el propio pipeline escribe en score.json.

Tabla 24. Partidas de costo y de valor identificadas. Cada cifra se etiqueta como dato o supuesto; las marcadas PENDIENTE las completa el Product Lead.

Tabla 25. Riesgos de implementación y sostenibilidad, con probabilidad, impacto, disparador y mitigación. El plan B de datos es el propio dataset público.

ÍNDICE DE FIGURAS

Figura 1. Arquitectura mínima del prototipo: datos por DVC, componentes congelados con su corrida en MLflow, pipeline de puntuación y las dos salidas (ficha del reclamo y observatorio). Los límites de cómputo son los de la prueba de punta a punta.

Figura 2. Reclamos con narrativa por periodo. El volumen crece con los años: 2025-H1 tiene casi tantos reclamos como los dos años de ajuste.

Figura 3. Macro-F1 de T1 en calibración por representación. El producto y los embeddings aportan; TabPFN-3.5 sobre PCA 100 más producto es el vigente.

Figura 4. Tres patrones y su serie semanal (ajuste, calibración y validación; bandas de M9 y alertas de M11 donde las hubo). El catálogo completo está en el anexo A.

Figura 5. WIS de calibración de los candidatos semanales. C-A, la binomial negativa jerárquica con memoria que decae, es la vigente.

Figura 6. p-valor semanal de mezcla rara (escala logarítmica). La línea marca el umbral 0.01 fijado antes de mirar; 2025-H1 ya estaba consultada.

Figura 7. Fracción detectada por escenario y regla. CUSUM gana en los dos crecimientos sostenidos, que son los que deciden.

Figura 8. WIS diario de calibración de los candidatos de conteo y de la referencia Poisson de 7 días.

Figura 9. Fracción de ráfagas detectadas por cada regla diaria y por el CUSUM semanal. Ninguna regla diaria alcanza el 50 % exigido.

Figura 10. Predicción diaria de D-D en los últimos 120 días de ajuste y calibración para los cuatro patrones más grandes: observados (negro), mediana predictiva (azul) y bandas del 50 %, 80 % y 95 %. El ciclo semanal domina y las bandas se ensanchan en los patrones pequeños.

Figura 11. Masa de frontera por patrón en calibración: fracción de reclamos cuyo segundo centro está a menos del 10 % de distancia relativa del primero. La línea es la mediana entre patrones.

Figura 12. WIS plug-in de la memoria de C-A frente al descuento δ, en ajuste y en calibración. La rejilla original (0.5 a 0.9) no veía el brazo izquierdo.

Figura 13. Cronograma del proyecto por fase (2026), con las fechas de los sprints del curso y del cierre del modelado, y la siguiente fase prevista.

ÍNDICE DE ANEXOS

Anexo A. Catálogo de los 40 patrones

Anexo B. Tabla completa de candidatos

Anexo C. Reglas pre-registradas

Anexo D. Mapa de la rúbrica del informe de cierre (P4)

Anexo E. Declaración de uso de inteligencia artificial

Anexo F. Repositorio, trazabilidad e historial de versiones

RESUMEN

Un banco recibe reclamos en texto libre y debe tipificarlos, atenderlos a tiempo y notar cuándo algo nuevo está pasando. Este trabajo construye y evalúa un prototipo reproducible que apoya a la persona que hace ese triaje con cinco salidas: el motivo más probable, la probabilidad de que el reclamo termine con solución y con compensación, los reclamos históricos parecidos, el patrón semántico al que pertenece y, cada semana y cada día, qué patrones reciben más reclamos de lo esperado. Se siguió CRISP-DM con dos adaptaciones: pre-registro de la regla de decisión antes de cada corrida y evaluación hacia adelante con una validación de un solo uso. Se usaron 3,837,184 reclamos públicos de la CFPB y una vista que excluye el texto reutilizado. Un modelo tabular en contexto (TabPFN-3.5) sugiere el motivo entre 90 clases con Macro-F1 0.271 frente a 0.076 de la regla por producto; modelos lineales estiman solución y compensación; 40 patrones sobre embeddings organizan el flujo; una binomial negativa jerárquica con memoria corta predice el volumen semanal con 30 % menos error que la referencia Poisson, y un CUSUM detecta crecimientos de 20 % semanal en 71 % de los casos con una falsa alarma al mes. El conteo diario funciona; la alerta diaria no alcanzó la detección exigida y se declara como límite. Un pipeline puntúa reclamos nuevos sin reentrenar y el contraste con la literatura respalda las elecciones centrales. El método se traslada a un banco; las cifras no.

PALABRAS CLAVES: triaje de reclamos; clasificación de texto; TabPFN; patrones semánticos; binomial negativa; CUSUM; pre-registro; CFPB.

ABSTRACT

HUMAN-IN-THE-LOOP TRIAGE OF FINANCIAL COMPLAINTS: SUGGESTED ISSUE, HISTORICAL OUTCOMES, SEMANTIC PATTERNS AND ALERTS ON CFPB PUBLIC COMPLAINTS

A bank receives free-text complaints and must classify them, answer them on time and notice when something new is happening. This work builds and evaluates a reproducible triage prototype that supports the person doing that work with five outputs: the most likely issue, the probability that the complaint ends with relief and with monetary relief, similar historical complaints, the semantic pattern it belongs to and, every week and every day, which patterns receive more complaints than expected. CRISP-DM was followed with two adaptations: the decision rule of every run was pre-registered, and evaluation was forward in time with a single-use validation period. 3,837,184 public CFPB complaints were used, with a view that excludes reused text. An in-context tabular model (TabPFN-3.5) suggests the issue among 90 classes with macro-F1 0.271 against 0.076 for the product rule; linear models estimate relief and monetary relief; 40 patterns over embeddings organize the flow; a hierarchical negative binomial with short memory forecasts weekly volume per pattern with 30 % less error than the Poisson reference, and a CUSUM detects 20 % weekly growth in 71 % of simulated cases at one false alarm per month. Daily counts work; the daily alert did not reach the required detection and is declared as a limit. A pipeline scores new complaints without retraining, and a contrast with the literature supports the central choices. The method transfers to a bank; the figures do not.

KEYWORDS: complaint triage; text classification; TabPFN; semantic patterns; negative binomial; CUSUM; pre-registration; CFPB.

CAPÍTULO I. VISIÓN DEL PROYECTO

1.1 Problema y oportunidad

Un banco regulado recibe cada día reclamos escritos por sus clientes. Una persona del equipo de atención los lee uno por uno, decide de qué tratan, los deriva al equipo que corresponde y vigila los plazos. Esa misma persona es la primera que podría notar cuándo una campaña, un producto o un fallo operativo empieza a generar reclamos nuevos, pero lo nota tarde, porque el volumen diario no deja ver el conjunto. La decisión que hoy sale mal es doble: la tipificación de cada reclamo, que depende de quién lo lee, y la detección de un aumento sostenido en un tipo de reclamo, que hoy no tiene una expectativa contra la cual compararse.

Los datos muestran por qué el problema es difícil. En los reclamos públicos de la CFPB [1], 42.8 % de las narrativas comparten texto con otra (plantillas de gestores de reclamos), la taxonomía de motivos cambió de nombres entre periodos (173 motivos originales reducidos a 140 canónicos), el volumen crece año a año y en ajuste aparecen 90 motivos distintos, muchos raros. Un sistema que clasifique por frecuencia o que memorice plantillas parece funcionar y no funciona.

La oportunidad es apoyar las tres decisiones del triaje sin reemplazar a la persona: **qué es este reclamo** (el motivo más probable y los tres más probables), **qué suele pasar con reclamos así** (si casos parecidos terminaron con una solución registrada o con compensación) y **qué está cambiando** (qué patrones de reclamos reciben más de lo esperado esta semana y hoy). El sistema entrega evidencia; la decisión queda en la persona.

Por qué este proyecto y qué cambió desde el pitch. El proyecto se eligió de la cartera del curso por tener un dataset público grande, con texto libre y etiquetas de desenlace, que permite construir y evaluar el método completo sin acceso a datos de una entidad. Desde la formulación inicial cambiaron dos cosas por la evidencia: la respuesta fuera de plazo (T4) salió del triaje porque no se predice del texto, y la alerta diaria pasó de salida prometida a límite declarado porque no alcanzó la detección exigida con el presupuesto de falsas alarmas. Se mantuvo lo central: las tres decisiones, la revisión humana y la evaluación hacia adelante con reglas escritas antes.

PENDIENTE (Product Lead): criterio de elección del proyecto de la cartera (anexo A del P4) y resumen de la retroalimentación recibida en el pitch en vivo, el P1 y el P2, con lo que se cambió y lo que se mantuvo por argumento.

1.2 Usuarios, clientes y casos de uso

Tabla 1: Roles alrededor de la decisión de triaje. Los cargos son los de una entidad financiera tipo y se declaran como supuesto; la participación de cada rol en este proyecto fue documental.

Rol	Cargo	Qué gana	Cómo participó
Dueño del problema	Jefatura de atención al cliente	Que los reclamos se tipifiquen bien y se atiendan a tiempo; que un aumento se note antes	SUPUESTO: no hubo acceso a una entidad
Usuario	Analista de triaje (lee, tipifica, deriva, vigila plazos)	Menos lectura, menos derivaciones erradas, una lista corta de patrones que suben	Diseño de la ficha y de la vista «patrones que suben» a partir de la decisión descrita
Pagador	Gerencia de atención al cliente o de riesgo operativo	Costo evitado en horas y en plazos vencidos; detección temprana	PENDIENTE PL: bloque 10 del one--pager
Afectado	El cliente que reclama	Respuesta más rápida y mejor dirigida; ninguna decisión automática sobre su caso	Ninguna salida decide; revisión humana obligatoria
Equipo de datos	Responsable de los modelos	Señales claras de cuándo reentrenar; trazabilidad	Diseño del pipeline y de las señales

Casos de uso principales: (1) **ficha del reclamo**, al abrir un reclamo la persona ve el motivo sugerido con sus tres opciones y las confirma o corrige, las probabilidades de solución y compensación, el patrón y su fiabilidad, y cinco reclamos parecidos con su desenlace; (2) **patrones que suben**, cada semana y cada día una tabla con lo observado, lo esperado, el intervalo y el estado (alerta, por encima, dentro) por patrón, con filtro de fechas; (3) **revisión de una alerta**, marcarla como revisada, aumento real, eco de una ráfaga o reasignación; (4) **operación**, puntuar el lote diario y atender las señales de reentrenamiento.

1.3 Objetivo general

Construir y evaluar, de forma reproducible y con reglas fijadas antes de ver los resultados, un prototipo de triaje de reclamos que sugiera el motivo, estime resultados históricos, encuentre reclamos parecidos y detecte patrones semánticos cuyo volumen aumenta, de modo que la persona que hace el triaje decida con mejor evidencia.

1.4 Objetivos específicos

1. **OE1.** Preparar una tabla única de reclamos con texto normalizado, taxonomía canónica congelada, objetivos T1–T4 y periodos temporales de ajuste, calibración y validación, documentada con su diccionario.

2. **OE2.** Elegir, con un protocolo de evaluación hacia adelante y una vista sin texto compartido, los clasificadores de motivo (T1), solución (T2) y compensación (T3), y decidir si el de respuesta fuera de plazo (T4) aporta algo.
3. **OE3.** Construir un espacio semántico de reclamos (embeddings, PCA, UMAP, índice de vecinos) y una partición en patrones estable en el tiempo, con una regla de novedad.
4. **OE4.** Modelar el conteo semanal y la composición semanal de los patrones con modelos bayesianos comparados contra referencias simples, y derivar una regla de alerta de aumento persistente con un presupuesto de falsas alarmas.
5. **OE5.** Probar, como bloque aparte y pre-registrado, si la misma arquitectura funciona a resolución diaria y si una regla de alerta diaria aporta sobre la semanal.
6. **OE6.** Registrar cada decisión, su regla y su evidencia en MLflow, DVC y un registro de pre--registro, de modo que otra persona pueda reproducir el resultado.
7. **OE7.** Entregar un pipeline de inferencia que ajuste una vez y puntúe muchas veces, cerrar el modelado probando por regla los candidatos abiertos y contrastar el conjunto con la literatura.

1.5 Propuesta de valor y KPIs de éxito

Propuesta de valor. Para la persona que hace el triaje, una mesa de trabajo que le dice qué es cada reclamo, qué suele pasar con reclamos así y qué está cambiando, con cifras que vienen de modelos evaluados hacia adelante y con un presupuesto declarado de falsas alarmas; frente a la lectura manual y a la vigilancia por totales, convierte un flujo de texto en evidencia revisable cada día.

Tabla 2: Indicadores de éxito del proyecto: métrica, referencia a vencer, criterio de éxito fijado antes de correr, resultado alcanzado y plazo. El KPI de negocio queda pendiente de los Product Lead.

Indicador	Métrica	Referencia	Criterio de éxito	Alcanzado	Plazo
Motivo (T1)	Macro-F1 en calibración sin texto compartido	regla por producto, 0.076	≥ 5 % relativo sobre el vigente con IC del bootstrap a favor	0.271 (+12.9 % sobre el mejor entrenado)	Sprint 3 (31--oct-2026)
Solución (T2) y compensación (T3)	Precisión promedio	0.454 y 0.174	misma regla	0.609 y 0.364	Sprint 3
Patrones	Estabilidad (ARI) y cobertura futura	criterios fijados	ARI ≥ 0.6, cobertura ≥ 70 %	ARI 0.63, cobertura 99 %	Sprint 3
Conteo semanal (M9)	WIS en calibración	Poisson de 4 semanas, 43.1	≥ 5 % menos WIS con IC a favor; cobertura 80 % en 70–90 %	30.3 (30 % menos)	Sprint 3
Alertas (M11)	Detección de crecimientos de 10 % y 20 % con 1 falsa alarma al mes	regla de una semana	CUSUM gana por ≥ 5 puntos en ambos	42 % y 71 %	Sprint 3
Conteo diario (D-D)	WIS diario	Poisson de 7 días, 9.26	misma regla	6.95 (25 % menos)	Sprint 3
Pipeline	Puntuar dos semanas sin reentrenar	—	corre de extremo a extremo y reproduce la alarma congelada	12 min GPU; alarma reproducida	Sprint 3
KPI de negocio	Minutos de lectura por reclamo y derivaciones erradas; aumentos detectados antes	cómo se decide hoy	PENDIENTE PL	se mide en la siguiente fase con el feedback humano	Capstone II

1.6 Hipótesis o tesis del proyecto

La tesis es que, con datos públicos y reglas fijadas de antemano, se puede construir un prototipo de triaje cuyas salidas sean útiles y cuyos límites estén medidos. Se desagrega en ocho hipótesis, probadas en el capítulo V:

- **H1.** El motivo del reclamo se puede sugerir del texto con más acierto que con la regla por producto.
- **H2.** La solución registrada y la compensación se estiman del texto por encima de la regla por producto.
- **H3.** La respuesta fuera de plazo se predice del texto.
- **H4.** Un espacio semántico de embeddings sostiene vecinos útiles y una partición en patrones estable en el tiempo.
- **H5.** El conteo semanal por patrón se predice mejor con un modelo bayesiano de conteo que con una referencia Poisson.
- **H6.** Un CUSUM sobre los excesos del modelo semanal detecta crecimientos sostenidos con una falsa alarma al mes.
- **H7.** La misma arquitectura funciona a resolución diaria, incluida la alerta.
- **H8.** Un pipeline que ajusta una vez puntúa reclamos nuevos sin reentrenar y reproduce los resultados congelados.

CAPÍTULO II. ANÁLISIS Y FUNDAMENTOS DEL PROYECTO

2.1 Antecedentes y revisión de literatura

La revisión se hizo en dos momentos y con dos herramientas, y las dos quedan registradas en el repositorio. Antes del cierre del modelado se usó Asta Paper Finder para cinco búsquedas por componente (clasificación de narrativas de reclamos, agrupamiento de texto, pronóstico de conteos cortos, vigilancia de cambios y modelos fundacionales de series); el veredicto por componente está en `docs/literatura/revision_asta.md` y dio origen a los candidatos del cierre. Después del cierre se usó Asta Theorizer para contrastar cuatro preguntas con unos 30 papers cada una, formar teorías y evaluar su novedad; el resultado se resume en la sección 5.5 y respalda 25 teorías con 299 juicios de novedad.

Clasificación de narrativas de reclamos. Los trabajos sobre la base de la CFPB usan representaciones de bolsa de palabras o embeddings con cabezas lineales y clases gruesas, con fines de tipificación y de predicción de la respuesta de la empresa [2], [3], [4]. No encontramos trabajos que usen un modelo tabular en contexto sobre embeddings reducidos, que es lo que ganó aquí para el motivo (T1). El antecedente directo de esa elección está fuera del dominio: usar TabPFN como cabeza sobre un codificador congelado [5] y la tolerancia de los embeddings a perder dimensiones [6]. Las tendencias que señala la literatura reciente para T1 son el blanqueo de los embeddings, la curación del contexto con mínimos por clase y el ajuste fino ligero [7], [8], [9].

Patrones semánticos. La tubería de referencia para descubrir temas en texto con embeddings es BERTopic: embedding, reducción con UMAP y agrupamiento [10], [11]. Su limitación conocida, y confirmada en este proyecto, es que la proyección no es determinista y que HDBSCAN deja mucho texto como ruido. La literatura propone anclar los patrones a prototipos fijos o a un codificador paramétrico [12]; aquí se midió el problema (sección 5.5) y se dejó esa salida como trabajo futuro.

Pronóstico de conteos cortos. Para series semanales de 40 patrones con dos años de historia, la evidencia favorece modelos de conteo bien especificados con una línea base regularizada sobre estados latentes mal identificados [13], [14], y advierte que la inferencia con NUTS sobre trayectorias latentes de composición se atasca; la salida es marginalizar o muestrear por bloques [15], [16], [17]. La descomposición «total × composición» tiene antecedente formal en el marco Dirichlet-multinomial-Poisson [18]. Los modelos fundacionales de series, Chronos-2 y TimesFM [19], [20], no ganan a esa referencia en series cortas y ruidosas, como reportan los benchmarks recientes [21]. El protocolo de evaluación por WIS y cobertura es el de los concursos de pronóstico epidemiológico [22], [23].

Vigilancia de cambios. Las dos reglas clásicas sobre residuos de un modelo de conteo son el CUSUM y el umbral de un periodo [24], [25], [26]. La corrección de la línea base frente a brotes pasados, reponderar los periodos anómalos [27], [28], funciona con líneas base de años; con una memoria corta se realimenta, como se mostró aquí; la alternativa es la cuarentena discreta de los periodos con alarma [29]. Para ráfagas de pocos días la literatura señala ventanas móviles cortas [30], [31].

Lo que la revisión cambió en el proyecto. La revisión previa al cierre produjo tres candidatos con regla escrita antes de correr (sustituto determinista de la proyección, reponderación de la línea base de M11 y alerta diaria de tres días), y los tres se rechazaron por su regla. El contraste posterior confirmó que las elecciones centrales (memoria corta en el conteo semanal, exclusión del espacio de estados diario, rechazo de la reponderación) coinciden con lo que la literatura predice, y dejó ocho hipótesis para la siguiente fase (capítulo VI).

2.2 Bases teóricas y conceptuales

- **CRISP-DM.** El proyecto siguió las seis fases del proceso estándar de minería de datos [32], con dos adaptaciones: un registro de pre-registro que fija la regla de decisión antes de cada corrida, y una fase de cierre que prueba por regla los candidatos abiertos y contrasta el conjunto con la literatura.
- **Fuga de información y evaluación hacia adelante.** La fuga, usar al entrenar información que no estaría disponible al decidir, es la causa más frecuente de resultados que no se reproducen [33]. Aquí se trata variable por variable y con tres ventanas por fecha; la validación se abre una sola vez.
- **Reproducibilidad computacional.** Cada cifra se traza a un commit, una versión de datos y una corrida [34], con DVC para los artefactos y MLflow para los experimentos; la deuda técnica propia de los sistemas de aprendizaje automático [35] se contiene con un pipeline que ajusta una vez y puntúa muchas veces.
- **Clasificación con muchas clases desbalanceadas.** Macro-F1 pondera por igual los 90 motivos, muchos raros; la precisión promedio (AP) evalúa T2 y T3 sin depender de un umbral. Un modelo tabular en contexto (TabPFN-3.5) predice a partir de un conjunto de ejemplos sin ajustar parámetros [36].
- **Representación semántica.** Embeddings BGE-large [37] normalizados, búsqueda exacta por producto interno con FAISS [38], reducción con PCA y UMAP y partición con k-means.
- **Modelos bayesianos de conteo.** Binomial negativa jerárquica por patrón con memoria que decae, Dirichlet-multinomial para la composición, escritos en PyMC [39] y muestreados con NUTS; revisión de priors por simulación predictiva y diagnósticos de convergencia antes de leer resultados.

- **Puntuación de pronósticos probabilísticos.** WIS (*weighted interval score*) y cobertura de intervalos [22]; log score conjunto para la composición.
- **Detección de cambios con presupuesto de falsas alarmas.** Exceso normalizado por la mid-PIT de la predictiva, CUSUM y regla de un periodo con umbrales fijados por simulación para una falsa alarma al mes; detección medida con escenarios inyectados.

2.3 Análisis del mercado, industria o contexto

El contexto es la atención de reclamos en entidades financieras reguladas. En el Perú, las empresas supervisadas por la SBS deben atender los reclamos de sus usuarios dentro de plazos regulados y reportarlos; la gestión diaria la realiza un equipo de atención que lee, tipifica, deriva y vigila los plazos. El proyecto se diseñó para ese equipo, con una regla de plazo en días hábiles y calendario de feriados peruanos (`configs/peru_holidays.yaml`) como sustituto del indicador de oportunidad de la CFPB, que no se pudo predecir del texto.

Como un banco peruano no comparte sus reclamos, el prototipo se construyó sobre los reclamos públicos de la CFPB de Estados Unidos [1]: 3,837,184 reclamos con narrativa entre 2015 y 2026, de los cuales 1,301,794 corresponden a 2023–2024. Es un mercado distinto, con productos y motivos propios, pero comparte la estructura del problema: texto libre, taxonomía que cambia con el tiempo, desbalance fuerte entre motivos y volumen que crece.

PENDIENTE (Product Lead): cifras del contexto peruano con fuente citable (reclamos recibidos por el sistema financiero según SBS o Indecopi, plazo regulado, tamaño del equipo de atención en una entidad tipo). Cada cifra debe etiquetarse como dato o como supuesto. Hasta tenerlas, esta sección describe el contexto sin dimensionarlo.

2.4 Benchmarking y competencia

La solución compite contra tres cosas: cómo se decide hoy, las herramientas que ya existen y el estado del arte académico.

Tabla 3: Mapa de alternativas: contra qué compite el prototipo y por qué no alcanzan. Las filas del statu quo y de las herramientas comerciales son evidencia documental declarada, no observación en una entidad.

Alternativa	Qué hace	Por qué no alcanza	Tipo de evidencia
Statu quo: lectura y tipificación manual, una por una	La persona lee cada reclamo, elige el motivo y deriva	No ve el conjunto: un aumento de un tipo de reclamo se nota tarde; la tipificación varía entre personas	SUPUESTO declarado
Regla por producto (referencia del proyecto)	Asignar a cada producto su motivo más frecuente	Macro-F1 0.076 en calibración frente a 0.271 del modelo vigente	dato: tabla comparativa
Clasificador lineal entrenado (TF-IDF o embeddings)	Lo que usa la literatura sobre la CFPB	Macro-F1 0.240 con BGE + producto; TabPFN-3.5 lo supera en +12.9 %	dato: tabla comparativa
Gestores de reclamos comerciales con tipificación asistida	Módulos de clasificación de texto dentro de plataformas de atención	No publican su evaluación en datos comparables; no incluyen vigilancia de patrones con presupuesto de falsas alarmas	SUPUESTO declarado; PENDIENTE PL: nombrar dos plataformas con fuente
Vigilancia por totales (sin patrones)	Mirar el volumen total de reclamos por semana	Un patrón que crece queda oculto en el total; aquí se vigila cada patrón con su expectativa	dato: diseño de M9–M11
Estado del arte: BERTopic + HDBSCAN para temas	Tubería estándar de temas con embeddings	En estos datos deja la mitad de los reclamos como ruido; la proyección no es determinista	dato: resultados de M7 y §31.1

El diferenciador del prototipo no es un modelo, sino el conjunto: cinco salidas sobre el mismo reclamo y el mismo flujo, con reglas de decisión escritas antes de correr, un presupuesto explícito de falsas alarmas y un pipeline que puntúa sin reentrenar. El riesgo del entorno es la licencia no comercial del componente que más aporta (TabPFN-3.5), que obliga a negociar o a usar el clasificador lineal de respaldo.

2.5 Datos, recursos y viabilidad

Tabla 4: Inventario de datos: fuente, unidad de análisis, volumen, periodo, objetivos, acceso y restricción de uso.

Fuente	Unidad	Volumen	Periodo	Para qué	Acceso y permiso
Reclamos públicos de la CFPB con narrativa	Un reclamo (`Complaint ID` único)	3,837,184 filas, 44 columnas, 1.71 GiB	2015-03 a 2026-07	Motivo (T1), solución registrada (T2), compensación (T3), respuesta no oportuna (T4), fecha de recepción para los conteos	Público, sin registro; narrativas publicadas con autorización del consumidor y anonimizadas por la CFPB; md5 d189a3ae6ea7… en DVC
Calendario de feriados del Perú	Un día	un archivo YAML por año	2026	Regla de plazo en días hábiles	Fuente pública (gob.pe); se actualiza cada año
Modelo BGE-large (Hugging Face)	—	1.3 GB	versión fija	Embeddings del texto	Licencia MIT; caché local, sin descarga en el clúster
Pesos de TabPFN-3.5 (Prior Labs)	—	~1 GB	versión fija	Clasificador de motivo	Licencia no comercial: válida para esta evaluación académica; uso con un banco requiere licencia

Los datos alcanzan para el objetivo con dos salvedades que se repiten en todo el documento: las etiquetas de la CFPB aproximan, no igualan, las categorías internas de un banco, y las cifras obtenidas no se trasladan a otra entidad; el método sí. La viabilidad técnica quedó demostrada en la construcción: el entrenamiento completo corrió en el clúster Khipu de UTEC (cola estándar, hasta 8 horas por trabajo, GPU para embeddings y TabPFN) y el pipeline de inferencia puntúa dos semanas de reclamos (35,265) en 12 minutos con GPU o 2.9 horas en CPU con el clasificador de respaldo. La viabilidad operativa y financiera se reevalúa en el capítulo VI.

2.6 Consideraciones normativas, éticas y de privacidad

- **Datos personales.** Los datos son públicos y la CFPB publica cada narrativa solo con autorización del consumidor y tras anonimizarla (las marcas «XXXX» del texto). El proyecto no cruza los reclamos con otras fuentes ni intenta reidentificar. Si el prototipo se usara con reclamos de una entidad peruana, aplicaría la Ley 29733 de Protección de Datos Personales y su reglamento [40], [41]: haría falta autorización escrita de uso, anonimización de las narrativas antes de cualquier procesamiento fuera de la entidad y un registro del tratamiento.
- **Sesgo y uso de variables sensibles.** `State`, `ZIP code` y `Tags` (que marca adultos mayores y personal militar) no entran como variables de ningún modelo; se conservan solo para auditoría. El texto puede contener rasgos del reclamante, y por eso ninguna salida decide: la persona revisa.
- **Límites de uso del modelo.** Ninguna salida detecta fraude, mide el plazo interno del banco ni evalúa a un empleado. T2 y T3 describen lo que la empresa respondió históricamente, no lo que el cliente merecía. Las alertas son para revisión humana con un presupuesto de falsas alarmas declarado.
- **Licencias de terceros.** TabPFN-3.5 y TimesFM 3.0 tienen licencia de uso no comercial; su lectura debe validarla una persona experta antes de cualquier uso fuera de este contexto académico. El resto de componentes (BGE, PyMC, FAISS, UMAP) es de código abierto con licencias permisivas.
- **Gobernanza.** El diseño sigue las prácticas del marco de gestión de riesgos de IA del NIST [42]: trazabilidad de cada cifra, documentación de límites, revisión humana de cada decisión y señales de reentrenamiento que avisan cuando el modelo deja de describir los datos.
- **Uso de inteligencia artificial en el trabajo.** Se declara en el anexo E, conforme a la política de la institución del autor principal.

CAPÍTULO III. PROPUESTA

3.1 Descripción de la solución

La solución es una **mesa de triaje asistida**: un sistema que, para cada reclamo escrito que llega, entrega evidencia a la persona que lo atiende y, para el conjunto de reclamos de la semana y del día, muestra qué patrones reciben más de lo esperado. No decide: sugiere, estima y avisa; la decisión queda en la persona, y lo que ella confirma o corrige se guarda.

Tabla 5: Las cinco salidas del prototipo, el componente que las produce, su cifra vigente en calibración y para qué sirve a la persona que hace el triaje.

Salida	Componente	Cifra vigente (calibración)	Para qué
Motivo sugerido (T1)	TabPFN-3.5 sobre PCA 100 de BGE + producto	Macro-F1 0.271; acierta entre los tres primeros en 96 %	Reduce lectura y derivaciones erradas; la persona confirma o corrige
Probabilidad de solución registrada (T2) y de compensación (T3)	Logística calibrada sobre TF-IDF del texto	AP 0.609 y 0.364	Priorizar y anticipar la respuesta
Reclamos parecidos	Índice FAISS sobre embeddings BGE	similitud mediana 0.924	Ver cómo terminaron casos similares
Patrón semántico y novedad	PCA 256 → UMAP 15 → k-means 40; novedad si distancia > p99	1.08 % novedosos en calibración	Organizar el flujo; detectar lo que no se parece a nada conocido
Patrones que suben (semana y día)	M9 (C-A) y D-D para lo esperado e intervalos; M11 (CUSUM) para la alerta semanal; M10 para la mezcla rara	WIS 30.3 semanal y 6.95 diario; 1.4 alertas al mes	Actuar sobre un aumento sostenido antes de que crezca

El producto tiene dos modos de uso: **por lotes**, que puntúa cada día la tabla de reclamos nuevos y alimenta el observatorio (patrones que suben), y **por reclamo**, que devuelve la ficha de un reclamo cuando la persona lo abre. Una capa de lenguaje natural, prevista para la siguiente fase, solo explica y redacta a partir de las salidas de los modelos; no clasifica ni decide (sección 3.4).

3.2 Arquitectura o diseño funcional

El pipeline se divide en dos momentos: **ajustar una vez** y **puntuar muchas veces** (figura figura 1). El ajuste corre en el clúster Khipu y deja cada componente congelado en DVC con su clave de corrida y su hash; la puntuación carga esos archivos y aplica aritmética, sin reentrenar.

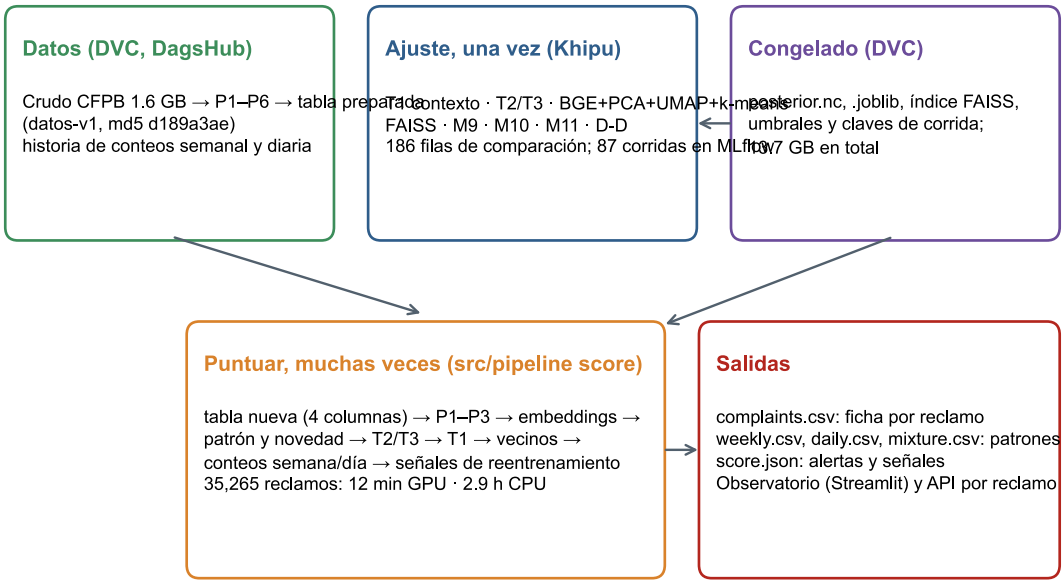


Figura 1: Arquitectura mínima del prototipo: datos por DVC, componentes congelados con su corrida en MLflow, pipeline de puntuación y las dos salidas (ficha del reclamo y observatorio). Los límites de cómputo son los de la prueba de punta a punta.

El flujo de puntuación tiene nueve pasos en orden fijo: preparación (esquema, texto, taxonomía congelada), embeddings BGE-large, patrón y novedad, T2 y T3, T1, vecinos, conteos semanales con M9, M10 y M11, conteos diarios con D-D, y resumen con las señales de reentrenamiento. Cada paso lee un archivo congelado concreto y escribe columnas concretas; la guía de uso y límites está en `docs/pipeline.md` y una animación del flujo diario en `etapa_6_despliegue/flujo_diario.html`.

3.3 Requisitos funcionales y no funcionales

Tabla 6: Requisitos del prototipo y cómo se cumplen o verifican.

Id	Requisito	Cómo se cumple o verifica
RF1	Recibir una tabla de reclamos con cuatro columnas obligatorias (id, fecha, producto, narrativa) y rechazar filas inválidas	Contrato de entrada `src/pipeline/contract.py`; pruebas unitarias
RF2	Entregar por reclamo el motivo top-3 con probabilidad, T2/T3, patrón, novedad y cinco vecinos	`complaints.csv` y `.parquet` del pipeline
RF3	Entregar por semana y día lo esperado, el intervalo y el estado (alerta, por encima, dentro)	`weekly.csv`, `daily.csv`; vista «patrones que suben» del prototipo de pantallas
RF4	Registrar lo que la persona confirma o corrige y marcar cada alerta (revisada, real, eco, reasignación)	Diseño de la ficha del reclamo; implementación en la siguiente fase
RF5	Avisar cuándo reentrenar	`signals` en `score.json`: novedad > 3 %, cobertura 80 % < 70 %, mezcla rara, caída de Macro-F1 > 5 %
RNF1	Reproducible por un tercero desde un clon limpio	`uv sync --frozen`, `dvc pull`, `python -m src.pipeline fit`; CI del repositorio en verde
RNF2	Trazable: cada cifra apunta a un commit, una versión de datos y una corrida	Etiquetas de MLflow (`git_commit`, `datos_md5`, `run_key`); manifiesto de hashes en `score.json`
RNF3	Latencia de lote: dos semanas de reclamos en menos de una hora con GPU	12 minutos en la prueba de punta a punta
RNF4	Sin datos ni credenciales en Git; artefactos grandes por DVC	Guard de datos del repositorio del curso en cada push
RNF5	Revisión humana obligatoria: ninguna salida ejecuta una acción	Diseño del producto; límites declarados en el README del prototipo

3.4 Evolución de producto o roadmap de solución

- **Fase actual (MVP, noviembre de 2026).** Pipeline de puntuación por lotes probado de punta a punta; observatorio en Streamlit con el motivo sugerido, la expectativa semanal con bandas, las alertas de M11 y el catálogo de patrones; prototipo de pantallas con la ficha del reclamo y la vista fusionada «patrones que suben» (semana y día con filtro de fechas).
- **Siguiente fase (Capstone II).** Ficha completa en el observatorio (T2/T3, vecinos con desenlace, novedad y fiabilidad del patrón); registro del feedback humano; API por reclamo; capa de lenguaje natural con LangGraph que resume precedentes, explica una alerta y redacta un borrador de respuesta a partir de las salidas, con revisión humana obligatoria; alerta multiescala (semanal más suma móvil de cuatro semanas) y cuarentena de las semanas con alarma.
- **Escalamiento.** Transferencia a reclamos propios de una entidad: repetir preparación, protocolo y rondas de candidatos con la taxonomía revisada por el negocio; reentrenamiento trimestral de los modelos de conteo y por señal de los clasificadores y patrones.

3.5 Modelo de negocio o sostenibilidad de la solución

El valor de la solución está en tres efectos sobre el equipo de atención: menos tiempo de lectura y menos derivaciones erradas por reclamo (T1 y vecinos), mejor priorización (T2 y T3) y detección temprana de aumentos sostenidos por patrón (M9–M11), que hoy se notan tarde. Operativamente se sostiene con un pipeline que no reentrena en producción, corre en un equipo común para lotes moderados y tiene reglas claras de cuándo volver a entrenar.

PENDIENTE (Product Lead): modelo de negocio y pagador. Hace falta el bloque 10 del one-pager: quién paga (gerencia de atención al cliente o de riesgo operativo, por ejemplo), qué costo evita (horas de lectura y derivaciones erradas por reclamo, multas por plazos vencidos) y bajo qué modalidad se sostiene (licencia interna, servicio). Cada cifra debe ir etiquetada como dato o supuesto con su fuente; la viabilidad financiera se trata en la sección 6.2.

CAPÍTULO IV. METODOLOGÍA Y DESARROLLO DEL PROYECTO

4.1 Tipo y enfoque de investigación

Es una investigación **aplicada y tecnológica**, de enfoque **cuantitativo**: construye un artefacto (el prototipo de triaje) y lo evalúa con métricas definidas antes de correr, sobre datos reales y con validación hacia adelante en el tiempo. Tiene además un componente **exploratorio**: las rondas de candidatos preguntan qué familia de modelos funciona en cada componente, y el contraste con la literatura pregunta qué habría hecho distinto el estado del arte. No es experimental con usuarios: no hubo acceso a un equipo de atención real, y la evidencia de negocio es documental y se declara así.

4.2 Diseño metodológico

El proyecto siguió CRISP-DM [32] en seis fases y tres sprints del curso, con dos adaptaciones que dan rigor al método:

1. **Pre-registro.** Antes de correr cada modelo se escribió en `docs/registro/models_plan.md`, con fecha, la regla con la que se decidiría: métrica, referencia, umbral de mejora y qué pasa si falla. El anexo C resume esas reglas. La decisión posterior fue mecánica.

2. **Evaluación hacia adelante con validación de un solo uso.** Tres ventanas por fecha (ajuste 2023-01 a 2024-09, calibración 2024-Q4, validación 2025-H1); se decide en calibración y la validación se abrió una sola vez (2026-10-01). Lo decidido después reporta su cifra de validación como «ya consultada».
3. **Regla común de reemplazo.** Un candidato reemplaza al vigente solo si mejora la métrica principal al menos 5 % y el intervalo del 95 % de un bootstrap pareado por semanas queda entero a su favor; los candidatos compiten del más simple al más complejo.
4. **Trazabilidad.** DVC para datos y artefactos, MLflow para corridas (un experimento, 87 corridas con commit, hash de datos y semilla), y un registro de decisiones (`docs/decisiones/`).
5. **Cierre y contraste.** Una fase final que construyó el pipeline, probó por regla los candidatos abiertos y contrastó el conjunto con la literatura mediante Asta Theorizer.

Tabla 7: Fases de CRISP-DM, qué se hizo en cada una y dónde está la evidencia en el repositorio.

Fase	Qué se hizo	Evidencia
1. Comprensión del negocio	Decisión de triaje, cuatro objetivos T1–T4 con sus límites de interpretación, alcance y fugas	`docs/decisiones/0001-alcance-y-fugas.md`, `etapa_1_2_comprension/`
2. Comprensión de los datos	EDA E0–E10: volumen, periodos, texto compartido, deriva de la taxonomía, faltantes y fugas variable por variable	`notebooks/01_eda.ipynb`, `docs/resumen-eda.md`
3. Preparación	Seis etapas de DVC (P1–P6): tipado, normalización del texto, taxonomía congelada, objetivos y periodos, tabla final, diccionario e informe de limpieza	`dvc.yaml`, `params.yaml`, `docs/diccionario/`, `reports/preparation/`
4. Modelado	Clasificadores T1–T4, espacio semántico y patrones, conteo y composición semanal, alertas, bloque diario; 18 etapas comparadas	`docs/modelos.md`, `reports/modeling/`, MLflow
5. Evaluación	Protocolo pre-registrado, tabla comparativa de 186 filas, confirmación única en validación, cierre y contraste con la literatura	`etapa_4_5_modelado_evaluacion/`, `docs/registro/models_plan.md` §22–§32
6. Despliegue	Pipeline ajustar-una-vez / puntuar-muchas-veces, prueba de punta a punta, observatorio, prototipo de pantallas, animación del flujo diario	`src/pipeline/`, `docs/pipeline.md`, `etapa_6_despliegue/`, `prototipo/`

4.3 Técnicas e instrumentos de recolección

- **Dataset público.** Reclamos con narrativa de la CFPB [1], entregado por el curso y conservado sin modificar en DVC; es la única fuente de datos del proyecto.
- **Análisis exploratorio reproducible.** Un notebook con 46 celdas ejecutadas (E0–E10) que fija los hallazgos que guiaron la preparación: texto compartido, desbalance, deriva de taxonomía y volumen por periodo.
- **Experimentos registrados.** Cada corrida de modelado escribe un `run.json` con parámetros, métricas y etiquetas, publicado en MLflow; los resultados tabulares van por DVC y la tabla comparativa se regenera con un comando.

- **Simulación.** Los umbrales de alerta se fijan simulando series sin cambio para un presupuesto de falsas alarmas, y la detección se mide inyectando crecimientos y ráfagas en los conteos de calibración.
- **Revisión de literatura asistida.** Asta Paper Finder (cinco búsquedas por componente) y Asta Theorizer (cuatro preguntas, unos 30 papers cada una, teorías y juicios de novedad), con validación del equipo en cada etapa.
- **Evidencia de usuarios.** No hubo entrevistas ni pruebas con usuarios; el diseño de las pantallas se basó en la decisión de triaje descrita en el capítulo I y se declara como evidencia documental.

PENDIENTE (Product Lead): si existen entrevistas o fichas anonimizadas de stakeholders del one-pager, incorporarlas aquí y en el anexo C de la rúbrica del P4 (evidencia de stakeholders). Hasta entonces, la evidencia es documental y se declara así.

4.4 Alcance del prototipo, MVP o solución

Incluye. Preparación reproducible de la tabla; cinco salidas por reclamo y por periodo (motivo, T2/T3, vecinos, patrón y novedad, patrones que suben por semana y por día); pipeline que puntúa tablas nuevas sin reentrenar; observatorio y prototipo de pantallas; señales de reentrenamiento; registro de decisiones y de experimentos.

No incluye. Detección de fraude; medición del plazo interno del banco (T4 se descartó y lo reemplaza una regla de plazo con feriados); una alerta diaria con presupuesto garantizado (dos versiones probadas, ninguna alcanzó la detección exigida); la capa de lenguaje natural y el registro del feedback humano (diseñados, previstos para Capstone II); la transferencia a datos de una entidad peruana; una interfaz con usuarios reales.

4.5 Construcción o implementación

La construcción se describe en dos partes: los datos y su preparación (4.5.1) y los componentes del modelo con su protocolo de evaluación (4.5.2). Las herramientas fueron Python 3.12 con `uv` para el entorno, DVC con DagsHub como remoto, MLflow, PyMC con NumPyro para los modelos bayesianos, scikit-learn, FAISS, UMAP, TabPFN-3.5 y el clúster Khipu de UTEC (SLURM, GPU) para el entrenamiento; Quarto para los informes.

4.5.1 Datos y preparación

Fuente

Los datos son la base pública de reclamos de la CFPB [1], que publica cada reclamo con narrativa cuando el consumidor lo autoriza: fecha de recepción, producto, motivo, empresa, estado, respuesta de la empresa y si la respuesta fue oportuna. La tabla preparada tiene 3,837,184 filas y 44 columnas (1.71 GiB), con hash MD5 d189a3ae6ea7… fijado en DVC; ese hash acompaña cada corrida registrada en MLflow.

Tabla 8: Filas por periodo temporal. Solo 2023–2024 y 2025-H1 entran en el modelado; 2015–2022 es contexto, 2025-H2 quedó bloqueado por un experimento anterior y 2026 es parcial.

Periodo	Filas
Contexto 2015–2022	1,206,176
Ajuste y calibración 2023–2024	1,301,794
Validación 2025-H1	695,184
2025-H2 (bloqueado)	526,872
2026 parcial (sellado)	107,158

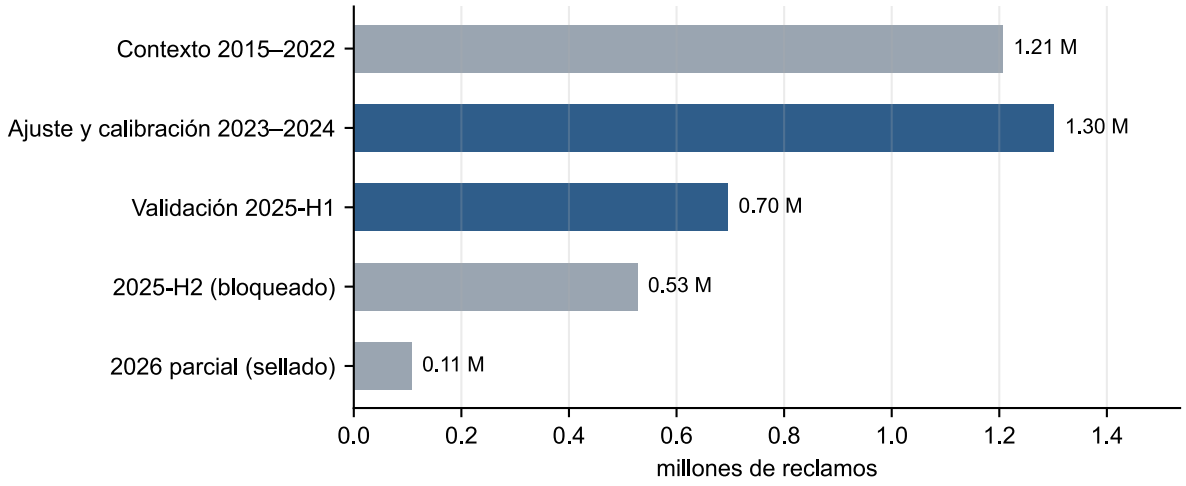


Figura 2: Reclamos con narrativa por periodo. El volumen crece con los años: 2025-H1 tiene casi tantos reclamos como los dos años de ajuste.

Dos rasgos que condicionan el diseño

Reutilización de texto. 42.8 % de las filas comparten su narrativa normalizada con otra; hay 2,476,614 textos distintos en 3,837,184 reclamos. Muchas narrativas son plantillas de gestores de reclamos de crédito. Un modelo que memorice plantillas parece mejor de lo que es, así que toda decisión se toma en la vista **sin texto compartido**, que excluye de calibración y validación las narrativas ya vistas en ajuste.

Deriva temporal. Lo que se reclama y cómo responden las empresas cambia de un año a otro: la fracción de reclamos con alguna solución registrada pasó de 43.2 % en ajuste a 38.7 % en validación. Evaluar con datos del mismo periodo engaña; por eso los periodos se cortan por fecha y se evalúa hacia adelante.

Preparación

La preparación corre como cinco etapas de DVC con parámetros en `params.yaml`, cada una con su hash de salida, y termina en un diccionario de datos con 44 columnas descritas (cobertura 100 %).

Tabla 9: Etapas de preparación (P1–P5) tal como las registra el informe de limpieza.

Etapa	Qué hace
type_data	P1 · valida el esquema de 16 columnas y tipa las dos fechas
normalize_text	P2 · normaliza la narrativa (text_normalizer_v1) y su SHA-256
apply_taxonomy	P3 · aplica la taxonomía propuesta congelada al 2025-06-30
build_targets	P4 · construye T1–T4, periodos, bloqueos y elegibilidad
finalize_prepared	P5 · valida el contrato y publica la tabla sin transformarla

La taxonomía de productos y motivos cambió de nombres entre periodos: 21 productos y 173 motivos originales se mapean a 18 productos y 140 motivos canónicos con un mapa congelado al 2025-06-30. Ese mapa es una propuesta sin revisión del negocio (proposed_no_business_review). En ajuste aparecen 90 motivos, muchos raros, lo que justifica Macro-F1 como métrica de T1.

Los cuatro objetivos se derivan de columnas de la CFPB: T1 es el motivo canónico; T2 es «alguna solución registrada» (respuesta cerrada con explicación, con alivio no monetario o monetario); T3 es «compensación monetaria»; T4 es «respuesta no oportuna». Las tasas de positivos en ajuste son 33.3 % para T2, 2.6 % para T3 y 1.1 % para T4. No se remuestrea: la métrica principal de T2–T4 es la precisión promedio, que no depende del umbral.

Tabla 10: Problemas encontrados en los datos y su tratamiento, del informe de limpieza.

Problema	Tratamiento
El archivo cambia con el tiempo: 2025 reúne cerca de un tercio de los reclamos y 2026 es parcial	Periodos temporales en la columna period; ningún reparto al azar entre entrenamiento y evaluación
La taxonomía histórica cambió de nombres entre periodos	Mapa canónico congelado al 2025-06-30 (Product canonical, Issue canonical) y banderas de categorías y pares conocidos
Pocas categorías concentran los casos y hay motivos raros	Sin transformación: la métrica principal de T1 es Macro-F1 y la elegibilidad por objetivo se declara en columnas
T3 y T4 tienen pocos positivos	Sin remuestreo: métrica principal average precision y umbral fijado en calibración
Las narrativas tienen longitudes muy distintas y marcas XXXX	Se conservan íntegras; la normalización no recorta ni elimina filas
Mucha reutilización textual entre reclamos	SHA-256 del texto normalizado para identificar grupos; vista de evaluación sin textos compartidos con los periodos de referencia; no se elimina ninguna fila
Los resultados T2–T4 cambian con el tiempo	Evaluación en periodos posteriores al entrenamiento; las respuestas ambiguas quedan como desconocidas (known_T2, known_T3)
Los 25,000 identificadores revisados antes no se recuperaron	2025-H2 bloqueado como evaluación final; banderas de identificador revisado y de grupo de texto excluido

4.5.2 Componentes del modelo y protocolo de evaluación

Protocolo de evaluación

Las decisiones de este protocolo se fijaron antes de entrenar y no se cambiaron después; están escritas, con fecha, en el registro de pre-registro del repositorio (`docs/registro/models_plan.md`). El anexo C las resume.

Tabla 11: Ventanas temporales y filas elegibles por vista. La vista sin texto compartido decide; la completa se reporta.

Ventana	Fechas	Filas (completa)	Filas (sin texto compartido)
Ajuste	desde 2023-01-01 hasta antes de 2024-10-01	1,067,194	1,067,194
Calibración	desde 2024-10-01 hasta antes de 2025-01-01	234,600	167,973
Validación	desde 2025-01-01 hasta antes de 2025-07-01	695,184	564,813

- **Tres periodos por fecha.** El sistema predecirá reclamos futuros, así que se ajusta en el pasado, se decide en calibración y se confirma en validación.
- **Validación se abre una vez.** Los modelos se eligen solo en calibración. Validación (2025-H1) se abrió el 2026-10-01 con todo congelado y confirmó T1–T3, M9 y M10. Las rondas posteriores (bloques A, B, C y el bloque diario) también se decidieron solo con ajuste y calibración, pero sus cifras de validación se reportan como **ya consultadas**: no son evidencia limpia. No queda otro periodo intacto: 2025-H2 se contaminó en un experimento anterior y 2026 es parcial y se reserva sellado.
- **Regla de reemplazo.** Un candidato reemplaza al vigente solo si mejora la métrica principal al menos 5 % y un bootstrap pareado por semanas (2,000 remuestreos, semilla 42) deja el intervalo del 95 % entero a su favor. Con 12 semanas de calibración, una mejora pequeña puede ser azar o una sola semana rara.
- **Orden de complejidad.** Los candidatos se prueban del más simple al más complejo; cada uno reemplaza al anterior solo si cumple la regla.
- **Modelos bayesianos en tres pasos.** Revisión de priors por simulación predictiva, piloto corto y corrida completa, con diagnósticos de convergencia (R-hat ≤ 1.01, sin divergencias) y cobertura de intervalos dentro de rangos fijados.
- **Trazabilidad.** Cada corrida registra en MLflow el commit, el hash de datos, la semilla y las métricas; los artefactos grandes van por DVC.

Clasificadores T1–T3

La métrica principal es Macro-F1 para T1 (90 motivos, muchos raros) y precisión promedio (AP) para T2 y T3, siempre en la vista sin texto compartido. La referencia es la **regla por producto**: el motivo o la tasa de positivos más frecuente de cada producto en ajuste.

Las representaciones compiten en orden de complejidad: TF-IDF del texto, TF-IDF más el producto, embeddings BGE-large [37] del texto y BGE más el producto, cada una con un clasificador lineal calibrado. Para T1 se añadió un bloque posterior con **TabPFN-3.5** [36], un modelo tabular en contexto que no se entrena: recibe 20,000 filas de contexto (76 clases presentes), con los embeddings reducidos a 100 componentes de PCA más el producto, y predice en 8 estimadores promediados. Una ablación pre-registrada probó 256 componentes y los 1,024 valores sin PCA. Usar TabPFN como cabeza sobre un codificador congelado tiene respaldo

reciente fuera de este dominio [5], y la tolerancia de los embeddings a perder dimensiones explica por qué una PCA corta basta [6]. Sobre narrativas de la CFPB la literatura usa TF-IDF o embeddings con cabezas lineales y clases gruesas [2], [3]; no encontramos trabajos con TabPFN en este dato.

T4 (respuesta no oportuna) se evaluó con el mismo protocolo y se descartó al confirmarlo en validación; lo reemplaza una regla de plazo con feriados.

Reclamos parecidos y patrones semánticos

Cada narrativa se representa con un embedding BGE-large de 1,024 dimensiones (BAAI/bge--large-en-v1.5), normalizado. Un índice exacto de producto interno (FAISS, [38]) sobre 120,000 reclamos de ajuste devuelve los diez más parecidos.

Los **patrones** son una partición del espacio semántico: PCA ajustado solo con filas de ajuste (256 componentes conservan 92.4 % de la varianza), UMAP a 15 dimensiones [11] y k--means. Se compararon 12 configuraciones de k-means, HDBSCAN y CURE con criterios de aceptación fijados antes: tamaño del grupo mayor, fracción de ruido, silhouette, estabilidad entre submuestras (ARI ≥ 0.6) y cobertura de reclamos futuros (≥ 70 %). La tubería es la de BERTopic [10] con k-means en el último paso: HDBSCAN, la opción habitual, dejó la mitad de los reclamos como ruido en nuestros datos. Un reclamo es **novedoso** si su distancia al centro asignado supera el percentil 99 de las distancias de ajuste. Una ronda de sensibilidad (bloque A) repitió la partición en 9 espacios alternativos (PCA 128/256/512, UMAP 5/10/15/30 y otras semillas) para saber si otro espacio daba grupos mejores.

Conteo semanal por patrón (M9)

Para saber si un patrón recibe más reclamos de lo normal hace falta cuántos se esperaban. El conteo semanal de cada patrón se modela como *total de la semana* × *participación esperada* con una **binomial negativa** por patrón, que admite más variación que la Poisson. La participación esperada de la familia ganadora usa una **memoria que decae**: cada semana pesa δ veces la siguiente más reciente (δ elegido en ajuste entre valores fijados). Los candidatos se comparan por el **WIS** (*weighted interval score*, [22]): la media, sobre los intervalos de 50 %, 80 % y 95 % y la mediana, del error absoluto de la mediana más la penalización por intervalos anchos o que no cubren el valor observado. Menor es mejor. Se exige además cobertura de 70–90 % para el intervalo de 80 % y de 88–99 % para el de 95 %.

La descomposición «total de la semana × composición» tiene un antecedente formal en el marco Dirichlet-multinomial-Poisson para conteos por causa [18], y el protocolo de evaluación es el de los concursos de pronóstico epidemiológico [23]. Los modelos se escriben en PyMC [39] y se muestrean con NUTS en NumPyro sobre el clúster Khipu; la referencia es una Poisson con la participación de las cuatro semanas previas. Además de las variantes bayesianas se probaron dos modelos fundacionales de series de tiempo sin entrenamiento, Chronos-2 [19] y TimesFM [20].

Composición semanal (M10)

M9 pregunta «¿este patrón trajo más de lo esperado?»; M10 pregunta «¿la mezcla de la semana es rara?». Una **Dirichlet-multinomial** modela el vector de conteos de los 40 patrones condicionado al total de la semana, con participaciones de cuatro semanas y una concentración global κ: cuanto mayor κ, más se parece la composición de cada semana a la esperada. Se evalúa por el **log score conjunto** (logaritmo de la probabilidad asignada a la

composición observada, sumado en calibración) contra una multinomial de cuatro semanas. Sobre el modelo aceptado se derivó una señal semanal de **mezcla rara**: un p-valor predictivo posterior del log score de cada semana, con aviso si $p < 0.01$.

Alertas de aumento persistente (M11)

Cada semana y patrón recibe un **exceso** z: el score normal de la mid-PIT del conteo observado en la predictiva de M9, es decir, la posición del observado dentro de la distribución predicha, transformada para que sea aproximadamente N(0, 1) si el modelo está calibrado. Dos reglas compiten: un **CUSUM** [24] que acumula los excesos ($k = 0.5$) y avisa cuando supera h, y una regla que avisa si el exceso de una sola semana supera z^*, las dos reglas clásicas de la vigilancia de conteos [25], [26]. Los umbrales se fijan por simulación de series N(0, 1) para un presupuesto de 1 falsa alarma al mes en total sobre los 40 patrones. La detección se mide inyectando crecimientos sostenidos de 10 % y 20 % semanal y escalones de 50 % y 100 % en los conteos de calibración, con un horizonte de 8 semanas. CUSUM se adopta si detecta al menos 5 % más que la regla semanal en los dos crecimientos.

Bloque diario

El bloque diario se pre-registró como prueba aparte: el semanal sirve para acciones preventivas y correctivas; el diario, para decisiones rápidas del día a día. El panel tiene 36,480 filas (639 días de ajuste, 92 de calibración y 181 de validación, sin huecos) con un total medio diario de 1,670 reclamos en ajuste y 2,550 en calibración. Los candidatos de conteo (D-A a D-D) son binomiales negativas que condicionan en el total del día con memoria que decae ($\delta = 0.8$, elegido en ajuste) y distintas formas del ciclo semanal; D-B es un espacio de estados y D-E la Dirichlet-multinomial diaria. La regla diaria de alerta D-11 repite el diseño de M11 con un presupuesto, aprobado por el equipo, de 4 falsas alarmas al mes sobre 40 patrones y ráfagas inyectadas de ×2 durante 3 días, ×3 durante 1 día y ×1.5 durante 7 días. Se adopta solo si detecta al menos 50 % de las dos primeras ráfagas con mediana de retraso de a lo más 2 días.

Cierre: pipeline y candidatos posteriores

El pipeline de inferencia fija la cadena de componentes vigentes (hashes de DVC y claves de corrida) y puntúa tablas nuevas sin reajustar; su prueba de punta a punta usa dos semanas de calibración ya consultadas. Los candidatos probados después del cierre se decidieron con reglas escritas antes de correrlos: un sustituto de la proyección UMAP por voto de vecinos (criterio: acuerdo con las etiquetas congeladas al menos igual al de la proyección consigo misma), la reponderación de las semanas con exceso en la memoria de M11 (misma simulación de M11: detección que no baje más de 5 puntos y menos alarmas reales) y una alerta diaria con ventana de tres días y umbrales empíricos (la regla de D-11 más el presupuesto comprobado en calibración). Dos comprobaciones sin cambio de modelo, la curva del WIS frente al descuento de C-A y la masa de frontera de cada patrón, completan el cierre. El contraste con la literatura se hizo con Asta Theorizer por etapas, validando el equipo la lista de papers y las teorías antes de cada paso.

CAPÍTULO V. VALIDACIÓN Y RESULTADOS

5.1 Framework de validación y experimentos

Las hipótesis del proyecto (sección 1.6) se validaron con experimentos cuya regla de decisión se escribió antes de correrlos. El marco tiene cuatro piezas:

1. **Tres ventanas por fecha y vista sin texto compartido.** Ajuste 2023-01 a 2024-09, calibración 2024-Q4 (167,973 reclamos sin texto compartido), validación 2025-H1 abierta una sola vez. 42.8 % de las narrativas comparten texto con otra; esa vista evita que las plantillas inflen las métricas.
2. **Una referencia y una métrica principal por tarea.** Regla por producto y Macro-F1 (T1) o AP (T2–T4); Poisson de cuatro semanas y WIS (M9); multinomial de cuatro semanas y log score (M10); regla de una semana y tasa de detección con presupuesto de una falsa alarma al mes (M11); Poisson de siete días y WIS (conteo diario).
3. **Regla de reemplazo y orden de complejidad.** Mejora relativa de al menos 5 % con el intervalo del bootstrap pareado por semanas a favor; del modelo más simple al más complejo.
4. **Escenarios inyectados para las alertas.** Crecimientos de 10 % y 20 % semanal y escalones de 50 % y 100 % para M11; ráfagas ×2 de tres días, ×3 de un día y ×1.5 de siete días para la regla diaria; 1,000 ráfagas por escenario.

Tabla 12: Hipótesis del proyecto, experimento que las prueba y veredicto. El detalle de cada cifra está en la sección 5.3.

Hipótesis	Experimento	Veredicto
H1. El motivo se puede sugerir del texto mejor que con la regla por producto	Escalera T1: regla → TF-IDF → BGE → TabPFN-3.5, con bootstrap	Se sostuvo: Macro-F1 0.271 frente a 0.076; se mantiene en 2025-H1
H2. La solución y la compensación se estiman del texto	T2 y T3 con la misma escalera	Se sostuvo con modelos simples: AP 0.570 y 0.270 en 2025-H1 frente a la regla
H3. La respuesta fuera de plazo se predice del texto	T4, confirmación en validación	Se refutó: AP 0.078 frente a 0.121 de la regla; lo reemplaza una regla de plazo
H4. Un espacio semántico sostiene vecinos útiles y patrones estables	FAISS; 12 configuraciones de agrupamiento con criterios fijados; 9 espacios alternativos	Se sostuvo con matiz: k-means 40 pasa los criterios; la proyección cambia el patrón de ~9 % de los reclamos según el lote
H5. El conteo semanal por patrón se predice mejor con un modelo bayesiano que con Poisson	Nueve candidatos por WIS en calibración	Se sostuvo: C-A, 30 % menos WIS que la referencia; gana a tres alternativas más complejas
H6. Un CUSUM sobre los excesos detecta crecimientos sostenidos con una falsa alarma al mes	Simulación de umbrales y escenarios inyectados	Se sostuvo: 71 % de los crecimientos de 20 %; límite declarado: eco de las ráfagas
H7. La misma arquitectura funciona a resolución diaria, incluida la alerta	Bloque diario pre-registrado: cinco candidatos y dos versiones de la alerta	Parcial: el conteo sí (25 % menos WIS); la alerta no (detección < 50 % con el presupuesto)
H8. El pipeline puntúa reclamos nuevos sin reentrenar y reproduce los resultados congelados	Prueba de punta a punta sobre dos semanas	Se sostuvo: cobertura 80 % de M9 79 %; reproduce la alarma de M11

5.2 Validación funcional, técnica u operativa

- **Funcional.** El pipeline corre de extremo a extremo sobre una tabla con las cuatro columnas obligatorias y devuelve las cinco salidas; la prueba de punta a punta usó 35,265 reclamos de dos semanas de calibración y reprodujo la alarma que la corrida congelada de M11 había dado en esas semanas.
- **Técnica.** Pruebas unitarias del contrato de entrada, de los conteos y de cada modelo (`tests/`); integración continua del repositorio del curso con un guard que rechaza datos y credenciales en Git; diagnósticos de convergencia en todos los modelos bayesianos aceptados (R-hat ≤ 1.01, sin divergencias); cobertura de intervalos dentro de los rangos fijados.

- **Operativa.** Tiempos medidos: 12 minutos con GPU y 2.9 horas en CPU para dos semanas; `fit` comprueba la cadena congelada y escribe un manifiesto con el hash de cada archivo usado; señales de reentrenamiento calculadas en cada puntuación.
- **Reproducibilidad.** Todo el modelado se repite desde un clon limpio con `uv sync --frozen`, `dvc pull` y los jobs de `scripts/hpc/`; la tabla comparativa y esta memoria se regeneran con un comando cada una.

5.3 Resultados y métricas alcanzadas

Los resultados se presentan por componente, en el orden en que compitieron, con la cifra de calibración que decidió y la de validación cuando existe.

5.3.1 Resultados por componente

Clasificadores

Tabla 13: T1, motivo del reclamo: Macro-F1 en calibración sin texto compartido, en el orden en que compitieron. Cada fila reemplaza a la anterior solo si cumple la regla del 5 % con el bootstrap a favor.

Candidato	Macro-F1	Decisión
Regla por producto	0.076	referencia
TF-IDF, solo texto	0.141	+84.6 % frente a Regla por producto; IC [+0.061, +0.069]; reemplaza
TF-IDF + producto	0.214	+52.4 % frente a TF-IDF, solo texto; IC [+0.071, +0.078]; reemplaza
BGE, solo texto	0.158	−26.2 % frente a TF-IDF + producto; IC [−0.061, −0.053]; no reemplaza
BGE + producto	0.240	+11.9 % frente a TF-IDF + producto; IC [+0.023, +0.029]; reemplaza
TabPFN-3.5 (PCA 100 + producto)	0.271	+12.9 % frente a BGE + producto; IC [+0.027, +0.035]; reemplaza

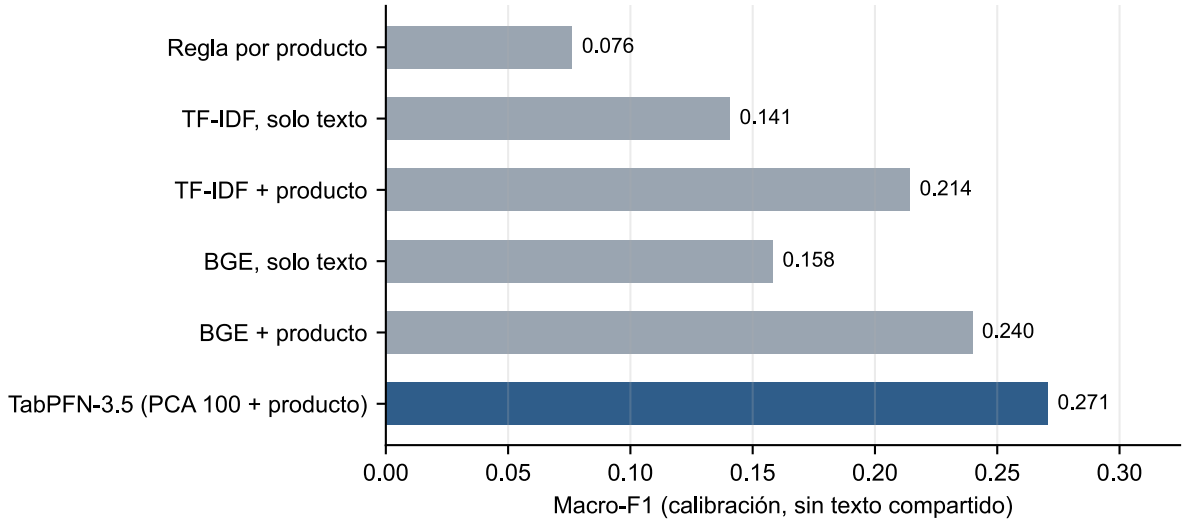


Figura 3: Macro-F1 de T1 en calibración por representación. El producto y los embeddings aportan; TabPFN-3.5 sobre PCA 100 más producto es el vigente.

TabPFN-3.5 acierta el motivo entre los tres primeros en 95.5 % de los reclamos de calibración. En 2025-H1 (ya consultado) mantiene Macro-F1 0.270 frente a 0.227 de BGE + producto y 0.068 de la regla por producto. La ablación de entrada no cambió la decisión: con 256 componentes de PCA el Macro-F1 fue 0.268 (-1.0 %, IC [−0.006, +0.001], incluye el cero) y con los 1,024 valores sin PCA cayó a 0.192 (-29.0 %), porque cada estimador de TabPFN ve a lo más 768 columnas.

Tabla 14: T2 (alguna solución registrada) y T3 (compensación monetaria): precisión promedio en calibración sin texto compartido y confirmación en 2025-H1. T4 no se confirmó.

Tarea	Modelo elegido	Regla (cal.)	Modelo (cal.)	Regla (2025-H1)	Modelo (2025-H1)	Validación
T2	TF-IDF, solo texto	0.454	0.609	0.451	0.570	confirmado
T3	TF-IDF, solo texto	0.174	0.364	0.127	0.270	confirmado
T4	TF-IDF + producto	0.031	0.055	0.121	0.078	no confirmado

Para T2 y T3 el producto no sumó el 5 % exigido sobre el TF-IDF del texto (0.612 frente a 0.609 en T2), así que quedó el modelo más simple. Los umbrales de decisión se fijaron en calibración maximizando F1: 0.300 para T2 y 0.181 para T3. T4 no supera a la regla por producto en validación (0.078 frente a 0.121): sale del triaje y lo reemplaza una regla de plazo con feriados.

Espacio semántico y patrones

El vecino más parecido por FAISS tiene similitud coseno mediana 0.924 en calibración; comparte producto en 82.7 % de los casos y motivo en 47.7 %. Es la evidencia de que el espacio captura significado y no solo palabras.

Tabla 15: Las tres familias de agrupamiento sobre UMAP 15 (mejor configuración de cada una, muestra de 20,000 reclamos de ajuste). Solo k-means pasa todos los criterios.

Algoritmo	Grupos	Ruido	Grupo mayor	Silhouette	Estabilidad ARI	Cobertura futura	Resultado
k-means k = 40	40	0 %	14 %	0.138	0.63	99 %	aceptado
HDBSCAN	2	49 %	47 %	0.545	1.00	63 %	rechazado: cluster_count, noise, future_coverage
CURE	20	0 %	99 %	0.409	0.43	96 %	rechazado: largest_cluster, neighbor_lift, stability

Los 40 patrones de k-means cubren 99.0 % de los reclamos futuros con la regla de novedad; en ajuste 0.88 % de los reclamos resultan novedosos, en calibración 1.08 % y en validación 0.77 %. Los patrones tienen entre 1,947 y 176,716 reclamos de ajuste (mediana 9,254); el mayor concentra 16.6 %. La ronda de sensibilidad probó 36 combinaciones de espacio y algoritmo: 6 pasaron los criterios y ninguna ganó a la partición vigente por la regla del 5 % en la coincidencia de vecinos. Cambiar solo la semilla de UMAP da particiones con ARI 0.61 y 0.58 respecto de la vigente: los patrones son una partición útil y estable en su calidad, no categorías naturales. El anexo A describe cada uno.

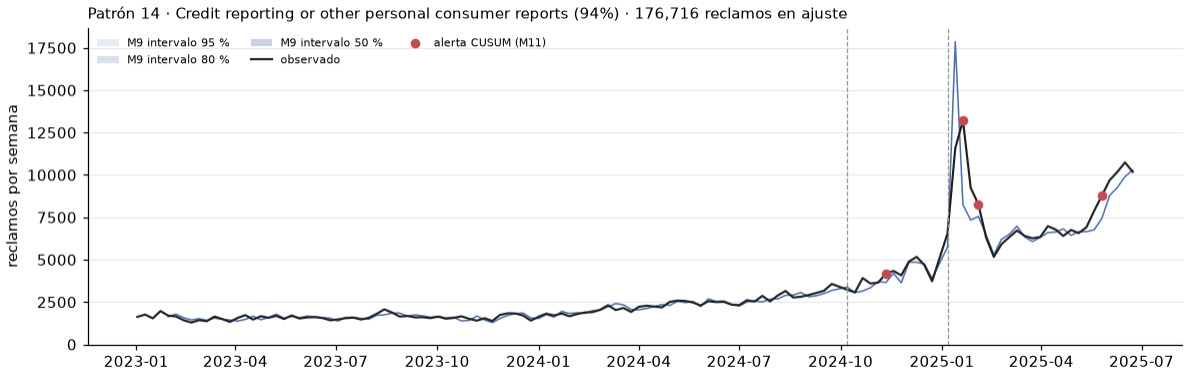


Figura 5: Patrón 14: redacted, redacted redacted, account, credit

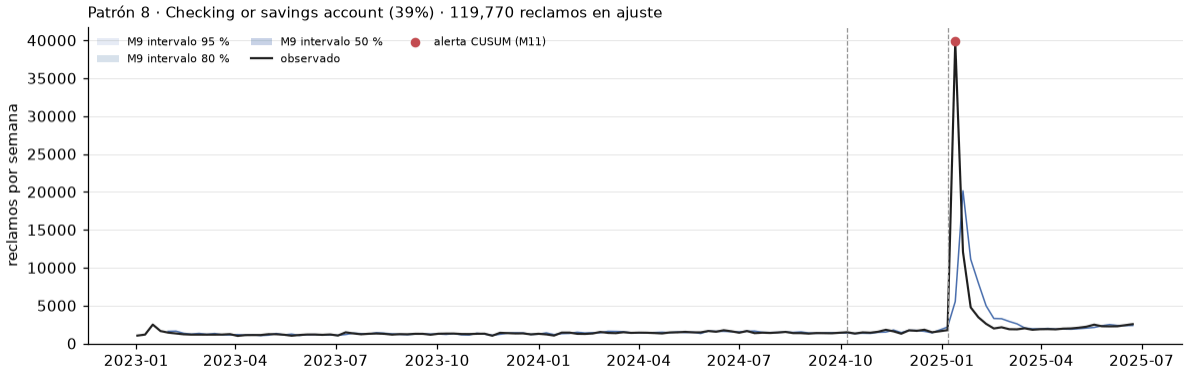


Figura 6: Patrón 8: bank, card, account, redacted

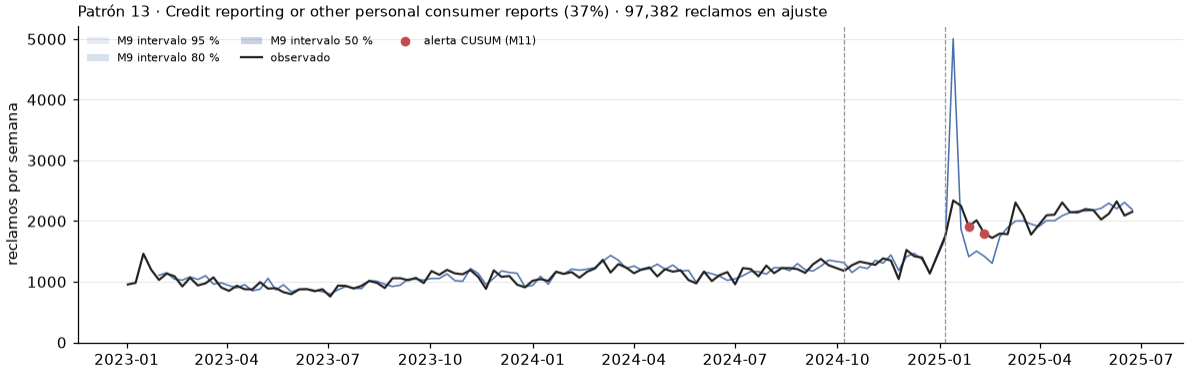


Figura 7: Patrón 13: loan, redacted, mortgage, payment
Figura 4

Conteo semanal por patrón (M9)

Tabla 16: Candidatos de M9 por WIS en las 12 semanas de calibración (menor es mejor) y cobertura de los intervalos de 80 % y 95 %. Las referencias no compiten.

Candidato	WIS	Cobertura 80 / 95	Resultado
C-A, memoria que decae (δ = 0.5)	30.30	85 % / 97 %	−6.5 % frente a NB-R4-H v3; gana a v3
C-B, paseo aleatorio t de Student	31.95	88 % / 98 %	−1.4 % frente a NB-R4-H v3; no gana a v3
NB-R4-H v3, dispersión por patrón	32.42	85 % / 96 %	−24.7 % frente a b1_rolling_4; accepted
Chronos-2, sin entrenamiento	36.02	77 % / 96 %	+11.1 % frente a NB-R4-H v3; no gana a v3
TimesFM 3.0, sin entrenamiento	40.70	76 % / —	−1.6 % frente a NB-R4-H v3; no gana a v3
B1-R4, Poisson con participaciones de 4 semanas	43.11	29 % / 42 %	referencia
NB-R4, 4 semanas, una dispersión	47.72	89 % / 96 %	+10.8 % frente a b1_rolling_4; rejected_no_practical_g
B1-R13, ídem con 13 semanas	64.84	21 % / 32 %	referencia
NB-V3, binomial negativa estática	92.57	77 % / 94 %	referencia
B1, Poisson con participaciones fijas	138.75	9 % / 16 %	referencia

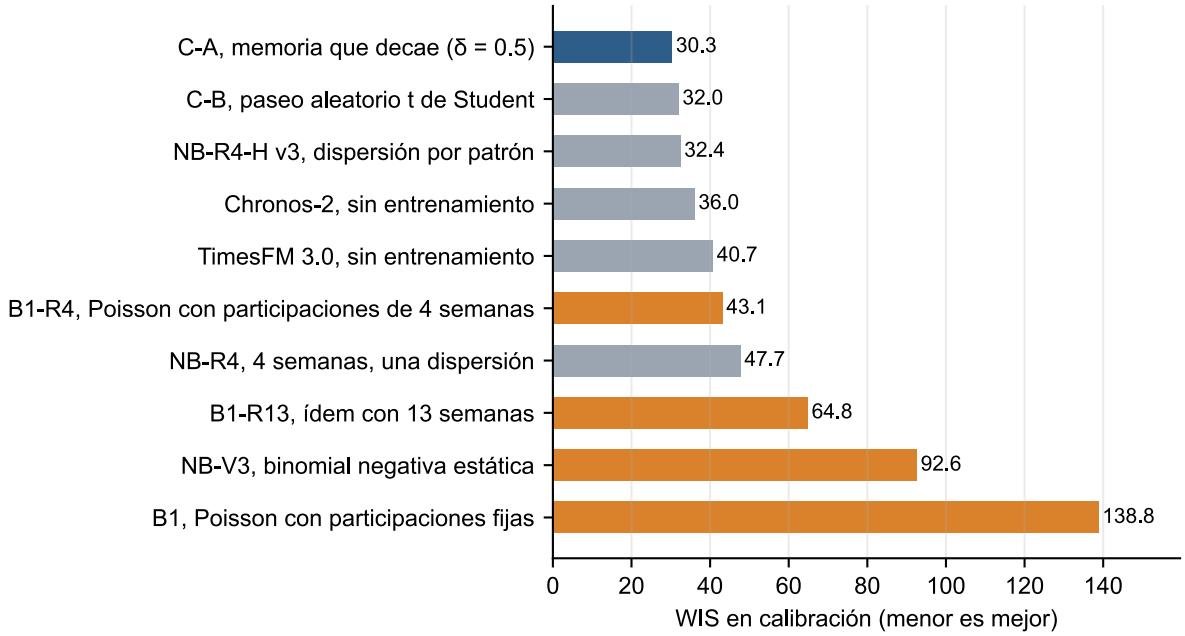


Figura 8: WIS de calibración de los candidatos semanales. C-A, la binomial negativa jerárquica con memoria que decae, es la vigente.

C-A reduce el WIS de la referencia Poisson de cuatro semanas de 43.11 a 30.30 (29.6 % menos) y gana a la versión con cuatro semanas de igual peso, NB-R4-H v3 (32.42), por 6.5 % con IC [−3.36, −0.84]. Su memoria δ = 0.5 se eligió en ajuste; en la práctica mira las dos últimas semanas. Las coberturas son 85 % y 97 %. En 2025-H1 (ya consultado) C-A da WIS 129.6 frente a 133.6 de v3; la validación es más difícil que la calibración porque contiene la ráfaga del 13 de enero de 2025, en la que un patrón recibió más de la mitad de los reclamos de la semana.

Composición semanal (M10)

La Dirichlet-multinomial con participaciones de cuatro semanas (DM-R4) mejora el log score de calibración de la multinomial de cuatro semanas de −461 a −210 (diferencia 251, IC [+205, +296]), con concentración κ = 826: mucha más variación entre semanas que una multinomial. La versión con participaciones fijas (DM-V1) se rechazó por una comprobación predictiva. En 2025-H1 el log score fue −252 frente a −3,338.

La señal de mezcla rara marcó 0 de 12 semanas de calibración, 7 de 25 de validación (la ráfaga de enero y su eco) y 19 de 87 de ajuste, cuando una señal calibrada marcaría 0.9. Una sola κ no cubre los cambios de composición de 2023; es un límite declarado y el umbral no se recalibró.

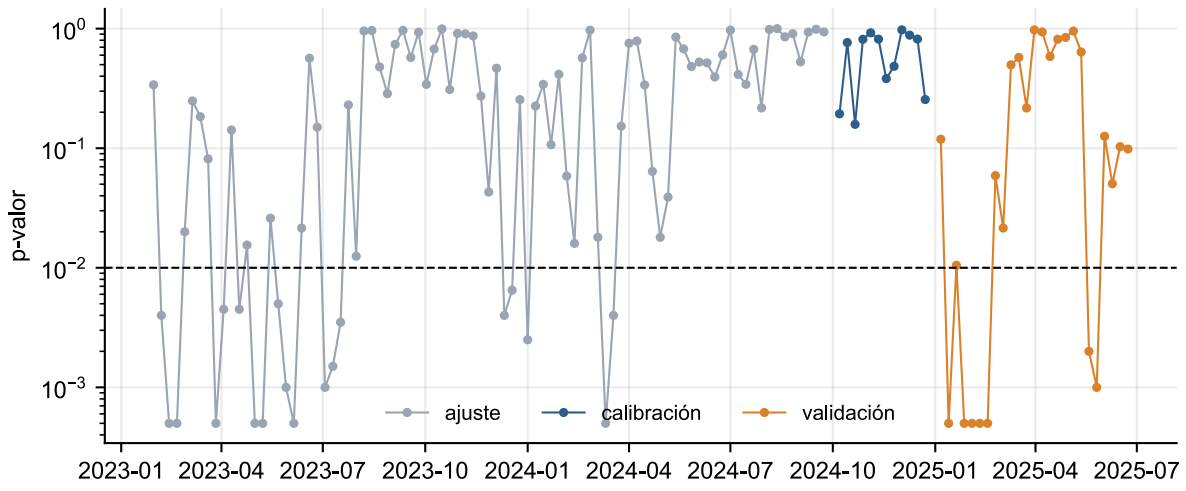


Figura 9: p-valor semanal de mezcla rara (escala logarítmica). La línea marca el umbral 0.01 fijado antes de mirar; 2025-H1 ya estaba consultada.

Alertas de aumento persistente (M11)

Tabla 17: Detección de cada regla en los escenarios inyectados sobre la calibración (fracción detectada en 8 semanas y mediana del retraso en semanas) con el presupuesto de una falsa alarma al mes.

Escenario	CUSUM	Regla de una semana
Crecimiento 10 % semanal	42.3 % (5 sem.)	32.0 % (4 sem.)
Crecimiento 20 % semanal	70.9 % (4 sem.)	54.0 % (3 sem.)
Escalón +50 %	31.6 % (2 sem.)	36.1 % (1 sem.)
Escalón +100 %	51.6 % (2 sem.)	56.9 % (1 sem.)
Sin aumento (falsas alarmas)	6.5 % (5 sem.)	10.5 % (4 sem.)

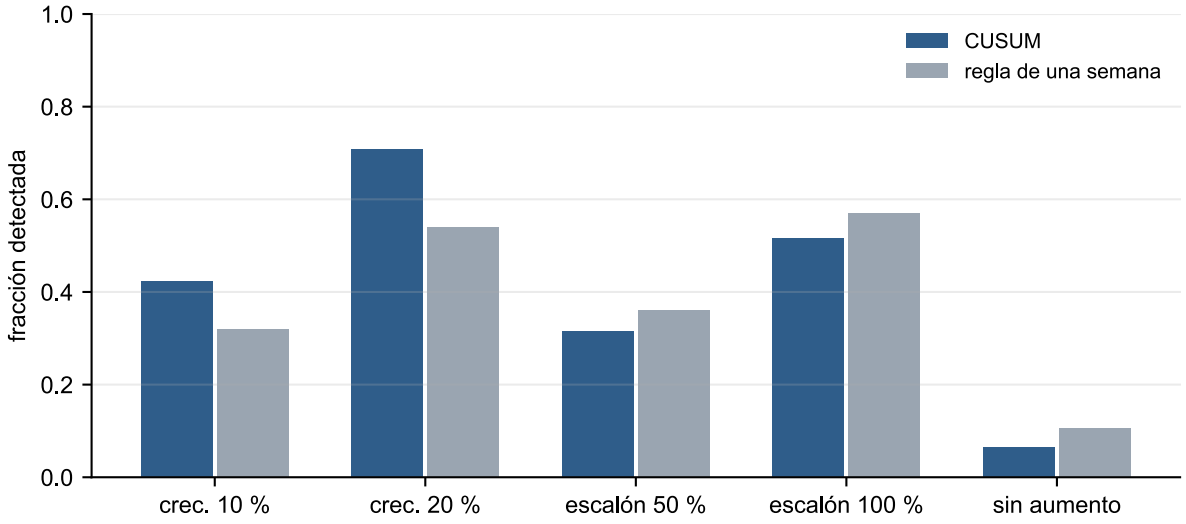


Figura 10: Fracción detectada por escenario y regla. CUSUM gana en los dos crecimientos sostenidos, que son los que deciden.

Con umbrales h = 3.37 y z* = 2.53, CUSUM detecta 10.3 % y 16.9 % más que la regla semanal en los crecimientos de 10 % y 20 %, por encima del 5 % exigido: **CUSUM es la regla vigente**. En los datos reales avisa 2.2 veces al mes en ajuste y 1.4 en calibración. En 2025-H1 (ya consultado) hubo 30 alertas en 25 semanas, buena parte de ellas el eco de la ráfaga de enero: M9 esperó de más para ese patrón y de menos para los otros en las semanas siguientes. Sobre la línea base anterior (v3) CUSUM detectaba 50.8 % y 79.7 % con más alarmas reales (2.2 al mes en calibración): la memoria corta de C-A da menos alertas y menos falsas, pero también menos detección, porque alcanza antes a un patrón que crece.

Bloque diario

Tabla 18: Candidatos de conteo diario: WIS en los 92 días de calibración (menor es mejor), ganancia frente a la Poisson de 7 días y cobertura. Todos aceptan la regla; gana el de menor WIS.

Candidato	WIS	Ganancia	Cobertura 80 / 95	Resultado
D-D, D-A con inflación de ceros	6.946	−25.0 %	87 % / 96 %	accepted · **ganador**
D-A, binomial negativa con día de semana	6.959	−24.9 %	86 % / 96 %	accepted
D-C, Fourier y tendencia local	7.173	−22.6 %	86 % / 96 %	accepted
D-B2, sin día de semana	7.696	−16.9 %	87 % / 96 %	accepted
D-B, espacio de estados diario	7.816 (piloto, 7 días)	—	—	no evaluado en full: R-hat 1.68, árbol saturado

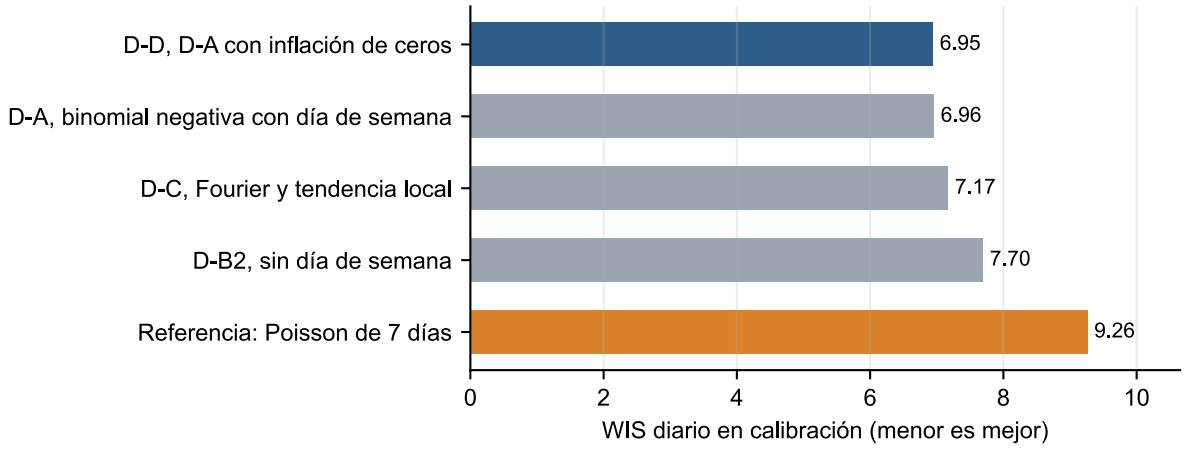


Figura 11: WIS diario de calibración de los candidatos de conteo y de la referencia Poisson de 7 días.

El efecto de día de semana es la pieza que más aporta (0.75 de WIS entre D-D y la variante sin ese efecto). El ganador por la regla pre-registrada es **D-D, D-A con inflación de ceros**,

pero contra D-A la diferencia es −0.013 con IC [−0.028, +0.001]: la inflación de ceros no cambia la calibración y D-A queda como alternativa más simple. En 2025-H1 (reporte único, ya consultado) D-D da WIS 14.56 frente a 19.31 de la Poisson de 7 días, con cobertura 83 % y 94 %. El espacio de estados diario (D-B) quedó fuera por una regla fijada antes de verlo: su muestreador satura la profundidad de árbol en las dos parametrizaciones probadas y una corrida completa no cabe en las 8 horas por trabajo del clúster.

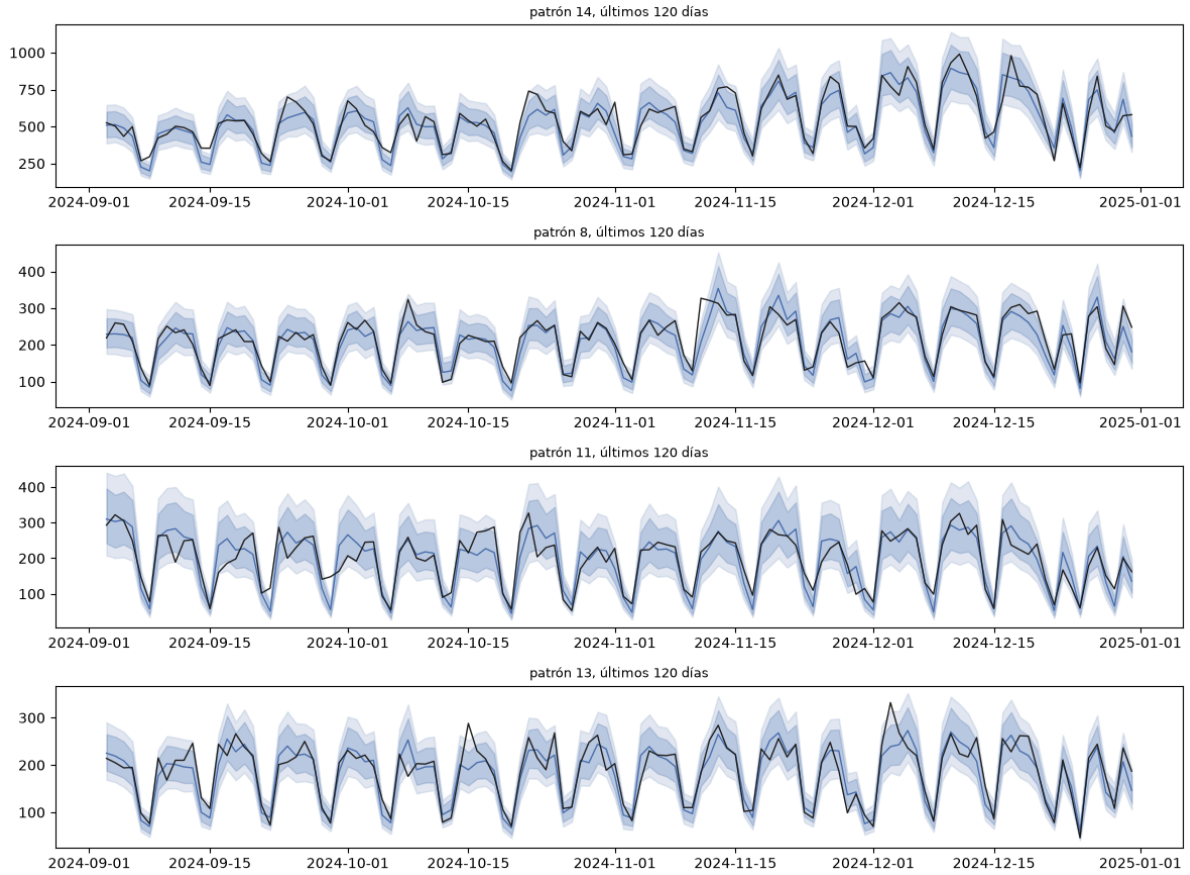


Figura 12: Predicción diaria de D-D en los últimos 120 días de ajuste y calibración para los cuatro patrones más grandes: observados (negro), mediana predictiva (azul) y bandas del 50 %, 80 % y 95 %. El ciclo semanal domina y las bandas se ensanchan en los patrones pequeños.

La Dirichlet-multinomial diaria (D-E, $\kappa = 261$, IC [255, 268]) mejora el log score de calibración de la multinomial de 7 días en 78.0 (IC [+69.1, +87.0]) y da la señal diaria de mezcla rara: marca 6 de 92 días de calibración.

Tabla 19: Regla diaria D-11 sobre D-D: fracción de ráfagas inyectadas detectadas en 14 días (mediana del retraso en días) con 4 falsas alarmas al mes; la última columna es el CUSUM semanal de M11 sobre las mismas ráfagas agregadas a semanas.

Escenario	CUSUM diario	Regla de un día	CUSUM semanal
Ráfaga ×2 durante 3 días	28.2 % (2 d)	35.2 % (1 d)	30.4 %
Ráfaga ×3 durante 1 día	24.8 % (1 d)	44.2 % (1 d)	29.1 %
Subida ×1.5 durante 7 días	24.9 % (3 d)	26.7 % (2 d)	30.7 %
Sin aumento (falsas alarmas)	6.5 % (7 d)	10.6 % (7 d)	0.0 %

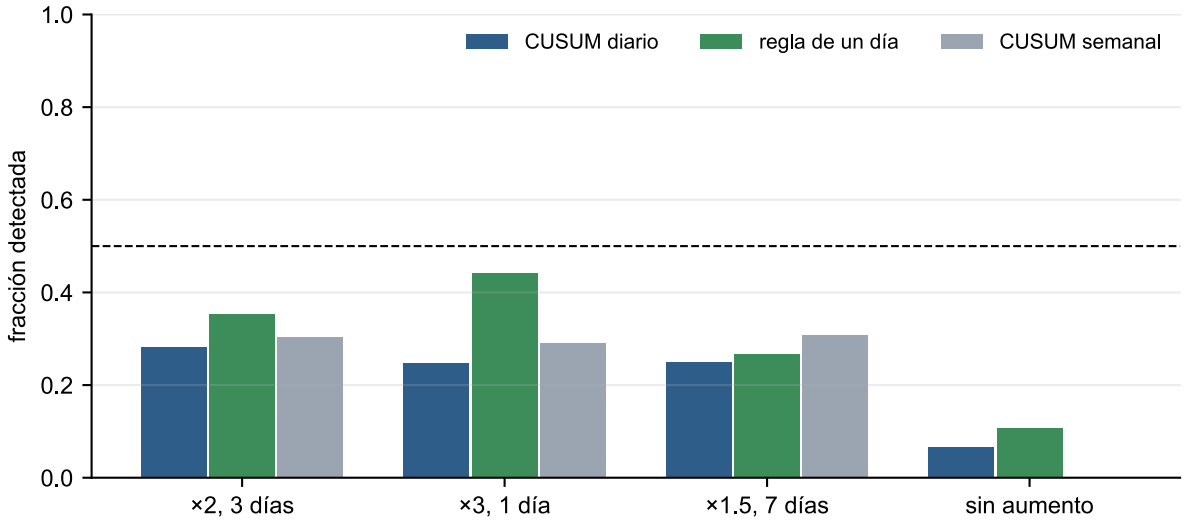


Figura 13: Fracción de ráfagas detectadas por cada regla diaria y por el CUSUM semanal. Ninguna regla diaria alcanza el 50 % exigido.

Con umbrales h = 3.90 y z* = 2.72, la mejor regla diaria detecta 44.2 % de las ráfagas ×3 de un día y 35.2 % de las ×2 de tres días, por debajo del 50 % fijado: **D-11 no se adopta**. Además, con esos umbrales las alarmas reales son 8.3 (CUSUM) y 12.9 (un día) al mes en calibración, frente a las 4 presupuestadas: los excesos diarios tienen colas más pesadas que la normal supuesta por la simulación. M11 sigue siendo la única regla de alerta.

Tabla comparativa

La tabla comparativa del curso reúne 186 filas: cada candidato, su métrica, su referencia, su ganancia relativa con intervalo y la decisión. El anexo B la reproduce completa; la tabla 20 resume lo vigente.

Tabla 20: Componentes vigentes y su cifra de calibración y de validación (2025-H1 ya consultada salvo T1–T3, M9 y M10, confirmados antes de abrirla por segunda vez).

Componente	Vigente	Calibración	Validación
T1, motivo (90 clases)	TabPFN-3.5, PCA 100 + producto	Macro-F1 0.271	Macro-F1 0.270 (ya consultado)
T2, alguna solución	TF-IDF solo texto, logística calibrada	AP 0.609	AP 0.570
T3, compensación	TF-IDF solo texto	AP 0.364	AP 0.270
Reclamos parecidos	FAISS exacto sobre BGE	similitud mediana 0.924	—
Patrones	PCA 256 → UMAP 15 → k-means 40	0.88 % novedosos	0.77 %
M9, conteo semanal	C-A, NB jerárquica con memoria que decae	WIS 30.30	WIS 129.6 (ya consultado)
M10, composición semanal	DM-R4, $\kappa = 826$	log score −210	−252
M11, alertas	CUSUM sobre los excesos de C-A	1.4 alertas al mes	30 en 25 semanas (ya consultado)
Conteo diario	D-D, D-A con inflación de ceros	WIS 6.946	WIS 14.56 (ya consultado)
Alerta diaria D-11	no adoptada	detección máxima 44 %	no consultado

5.4 Tracción o evidencia de adopción (si aplica)

No aplica en el sentido de usuarios o pilotos: el prototipo no se ha puesto frente a un equipo de atención real. La evidencia de interés disponible es interna y documental: la revisión del informe por los cuatro integrantes del equipo (registrada en el issue de conformidad del repositorio del curso), la reproducción del pipeline por un segundo integrante desde su propia rama, y el observatorio levantado por el ML Engineer sobre las salidas congeladas. La adopción se medirá en la siguiente fase con el registro del feedback humano (motivos confirmados o corregidos, alertas marcadas como revisadas, reales, eco o reasignación).

5.5 Discusión de resultados

La discusión tiene tres partes: el cierre del modelado, con el pipeline, los tres candidatos rechazados por regla y el contraste con la literatura (5.5.1); qué se eligió, qué no funcionó y qué se aprendió (5.5.2); y las expectativas y límites que un usuario del prototipo debe conocer (5.5.3).

5.5.1 Cierre del modelado: pipeline, candidatos rechazados y contraste con la literatura

Con los componentes elegidos y confirmados, la última ronda hizo tres cosas: construyó el pipeline que los usa sin reentrenar, probó por regla los candidatos que quedaban abiertos y

contrastó el conjunto con la literatura. Todo se decidió con las mismas reglas de la sección 4.5; ninguna cifra de validación se usó para decidir.

Pipeline de inferencia: ajustar una vez, puntuar muchas veces

El pipeline recibe una tabla de reclamos con las columnas públicas de la CFPB y devuelve, por reclamo, el motivo más probable y los dos siguientes, las probabilidades de solución y compensación, el patrón y su novedad y los cinco reclamos de ajuste más parecidos; y por semana y por día, el conteo de cada patrón con la expectativa e intervalos de M9 y del modelo diario, el exceso, el CUSUM de M11 y el p-valor de mezcla rara de M10. Comprueba antes que la cadena congelada esté completa (hashes de DVC y claves de corrida) y no reajusta nada. La prueba de punta a punta corrió sobre dos semanas de calibración (35,265 reclamos, 2 semanas, 14 días): en una GPU del clúster tomó 12 minutos con TabPFN; en CPU, sin TabPFN y con el clasificador lineal de respaldo, 2.9 horas. El intervalo de 80 % de M9 cubrió 79 % de los conteos, la fracción de reclamos novedosos fue 1.1 % y el CUSUM reprodujo la alarma que la corrida congelada de M11 había dado en esas semanas.

El patrón es una etiqueta blanda

La prueba de punta a punta mostró algo que la evaluación por bloques no podía ver: la proyección UMAP asigna un patrón distinto al mismo reclamo según con qué otros reclamos se procesa. Con los embeddings congelados, la proyección coincide consigo misma en 90.6 % de los reclamos de calibración cuando se cambia el orden de los lotes; los embeddings, en cambio, se reproducen exactamente. El ruido está en la proyección, no en el texto ni en k--means, y mueve los conteos semanales por patrón hasta en 8 %.

Se pre-registró un sustituto determinista: el voto, ponderado por similitud, de los cinco reclamos de ajuste más parecidos en el índice FAISS (120,000 reclamos), con la regla de adoptarlo si coincidía con las etiquetas congeladas al menos tanto como la proyección consigo misma. Coincidió en 83.2 % (con 20 vecinos, 85.1 %) frente a 90.6 %: los vecinos en el espacio de 1,024 dimensiones definen una partición parecida, no la misma. **No se adopta**; el patrón queda declarado como etiqueta blanda cerca de las fronteras.

Para leer las alarmas con ese dato a la vista se midió la masa de frontera de cada patrón: la fracción de reclamos cuyo segundo centro de k-means está a menos del 10 % de distancia relativa del primero. En calibración es 21.0 % en total, con mediana por patrón de 20 % y extremos de 0 % (patrón 34) a 76 % (patrón 4). Una alarma de M11 en un patrón con mucha masa de frontera puede ser reasignación; en uno con poca, no. Una mezcla gaussiana ajustada sobre las mismas coordenadas UMAP no sirvió como margen de la partición vigente: coincide con k-means en 42 % de los reclamos, es decir, define otra partición.

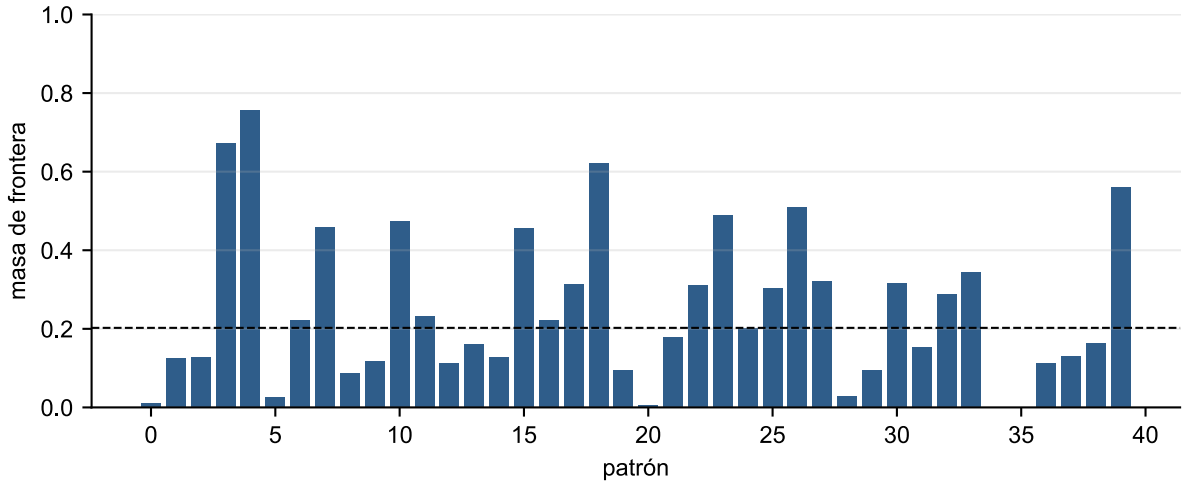


Figura 14: Masa de frontera por patrón en calibración: fracción de reclamos cuyo segundo centro está a menos del 10 % de distancia relativa del primero. La línea es la mediana entre patrones.

El eco de las ráfagas no se corrige con reponderación

M11 espera de más en un patrón durante las semanas que siguen a una ráfaga, porque la memoria de C-A la absorbe entera. La corrección clásica de la vigilancia epidemiológica, reducir el peso de los periodos anómalos al estimar la línea base [27], [28], se pre-registró con peso $(z_0/z)^2$ para los excesos por encima de $z_0 = 2.58$ y se evaluó con la misma simulación de M11. Salió al revés de lo buscado: la detección del CUSUM en los crecimientos de 10 % y 20 % bajó de 42.3 % y 70.9 % a 22.9 % y 56.0 %, las alarmas reales subieron de 1.45 a 4.35 al mes en calibración y el WIS de la expectativa pasó de 30.3 a 56.7. Con una memoria de unas dos semanas la reponderación se realimenta: al restar peso a una semana alta baja la participación, la semana siguiente vuelve a quedar «en exceso» y se descuenta otra vez, y un aumento real sostenido nunca entra a la memoria (143 filas reponderadas frente a 58 con exceso en M11). Farrington y Noufaily reponderan contra una línea base de años ajustada por regresión; la idea no se traslada a una memoria recursiva corta. **No se adopta**; el eco queda como límite declarado y la literatura señala otra salida, la cuarentena discreta de las semanas con alarma [29], que queda como trabajo futuro.

Por qué un día no basta y por qué se miran tres

La alerta diaria se volvió a probar con lo que la literatura de vigilancia señala para ráfagas cortas [30], [31]: una regla sobre la ventana de los últimos tres días, $S = (z_d + z_{d-1} + z_{d-2}) / \sqrt{3}$, junto a la regla de un día y el CUSUM diario, y umbrales empíricos fijados sobre los excesos reales de ajuste en lugar de la normal simulada ($z^* = 3.64$ frente a 2.72 en D-11; $s^* = 3.40$; $h = 4.68$).

Tabla 21: D-11 v2 sobre D-D: fracción de ráfagas inyectadas detectadas en 14 días (mediana del retraso en días) con umbrales empíricos y 4 falsas alarmas al mes; la última columna es el CUSUM semanal de M11 sobre las mismas ráfagas.

Escenario	Un día	Ventana de 3 días	CUSUM diario	CUSUM semanal
Ráfaga ×2 durante 3 días	20.8 % (1 d)	24.1 % (2 d)	21.6 % (2 d)	30.4 %
Ráfaga ×3 durante 1 día	28.7 % (1 d)	10.0 % (1 d)	2.0 % (6 d)	29.1 %
Ráfaga ×3 durante 3 días	34.8 % (1 d)	38.3 % (2 d)	35.2 % (2 d)	36.9 %
Subida ×1.5 durante 7 días	10.2 % (2 d)	16.8 % (3 d)	18.8 % (3 d)	30.7 %
Sin aumento (falsas alarmas)	3.3 % (7 d)	2.5 % (7 d)	2.8 % (7 d)	0.0 %

Con los umbrales empíricos el presupuesto sí se cumple: 4.0, 3.0 y 4.0 alarmas al mes en calibración frente a las 4 presupuestadas (D-11 daba entre 8 y 13 porque sus umbrales suponían colas normales). El costo es la detección: la ventana de tres días es la mejor regla diaria para ráfagas de varios días (24 % en ×2 de tres días frente a 21 % de un día) y la peor para un pico de un día, como predice la escala temporal; pero ninguna llega al 50 % exigido. La razón es aritmética: un patrón de 15 reclamos diarios tiene un ruido de unos ±6; una ráfaga ×2 da 30, que está a 2.5 desviaciones, justo donde no se distingue de un día raro. La suma de tres días de ráfaga (90 frente a 45, ruido ±10) sí se distingue, y por eso la ventana gana; pero con 40 patrones vigilados cada día y 4 falsas alarmas al mes, el umbral tiene que ser tan alto que la mitad de las ráfagas ×2 queda debajo. **D-11 v2 no se adopta.** La salida diaria sigue siendo la expectativa de D-D con sus intervalos y la lista de patrones ordenada por exceso, sin presupuesto de falsas alarmas garantizado.

El descuento de C-A está donde la teoría lo predice

La rejilla que eligió δ = 0.5 en ajuste empezaba en ese valor, así que nunca midió qué pasa con memorias más cortas. Al ampliarla, el WIS en función del descuento dibuja la U que predice la teoría: en ajuste baja de 21.66 (δ = 0.1) a 20.87 en δ = 0.4 y sube a 30.73 en δ = 0.95; en calibración, de 31.54 a un mínimo de 30.45 y 57.09. El valor elegido queda a menos de 0.3 % del mínimo; C-A no cambia.

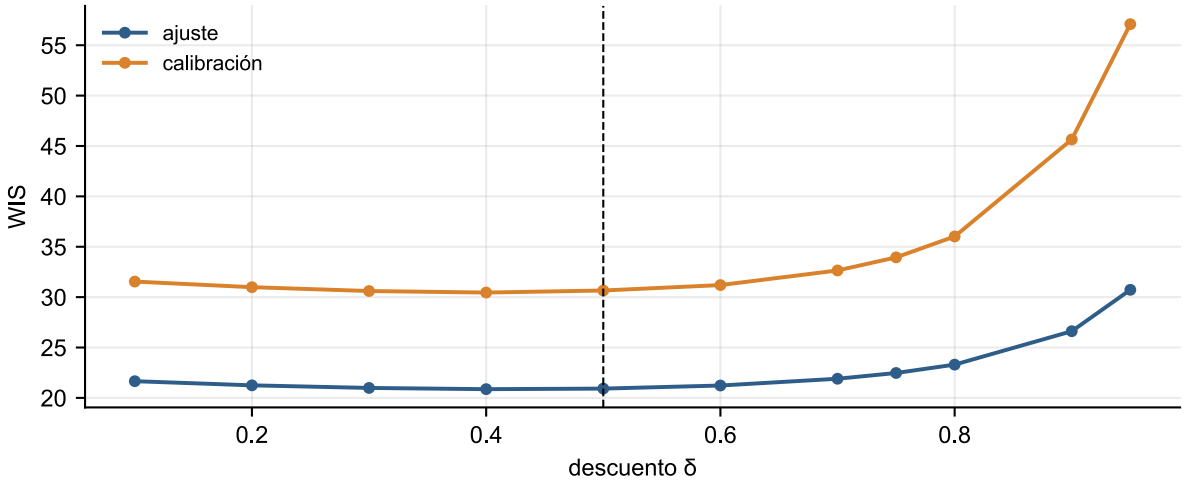


Figura 15: WIS plug-in de la memoria de C-A frente al descuento δ, en ajuste y en calibración. La rejilla original (0.5 a 0.9) no veía el brazo izquierdo.

Contraste con la literatura

Con el modelado cerrado se usó Asta Theorizer para contrastar cuatro preguntas con la literatura: el diseño de la línea base de M11, la estabilidad del patrón, el cabezal tabular en contexto frente al ajuste fino en T1, y la memoria corta frente al espacio de estados en los modelos de conteo. Cada pregunta buscó y extrajo hallazgos de unos 30 papers, formó teorías y evaluó su novedad, validando el equipo cada etapa. Resultaron 25 teorías y 299 juicios de novedad: 231 derivables de la literatura pero no enunciados, 35 ya establecidos y 16 genuinamente nuevos. Tres conclusiones pesan sobre este informe:

- Lo que hicimos coincide con lo que la literatura predice en C-A (una memoria regularizada gana a un estado latente mal identificado en paneles cortos [13], [14]), en la exclusión de D-B (NUTS sobre trayectorias latentes de composición se atasca; la salida es marginalizar o muestrear por bloques [15], [16], [17]) y en el rechazo de la reponderación (el efecto cambia de signo con memoria corta).
- Lo que la literatura habría hecho distinto: anclar el patrón a prototipos fijos en un espacio fijo o a un codificador paramétrico [12] en lugar de la proyección UMAP; dos escalas de alerta en vez de una; blanquear los embeddings y curar el contexto de TabPFN con mínimos por clase [7], [8], [9].
- Lo genuinamente nuevo de este trabajo, según esa evaluación: la inversión del efecto de la robustificación según la memoria efectiva, y los conteos por patrón como canal de error de medida cuya matriz de confusión depende del lote.

Tabla 22: Las cuatro preguntas a Theorizer: papers con hallazgos extraídos, teorías formadas y juicios de novedad por grado.

Pregunta	Papers con hallazgos	Teorías	Derivable	Establecido	Nuevo
P1. Línea base de M11	21 de 38	6	28	11	3
P2. Estabilidad del patrón	27 de 37	6	86	5	6
P3. T1, TabPFN frente a ajuste fino	23 de 40	6	53	20	3
P4. Conteos bayesianos	27 de 33	7	64	16	4

Los trabajos cuyos hallazgos sostienen las teorías de cada pregunta, y que por tanto respaldan la lectura anterior, son los siguientes; la lista completa de papers revisados, con sus extracciones, queda en el registro del proyecto.

- **Línea base de M11** (17 trabajos): [25], [29], [30], [31], [43], [44], [45], [46], [47], [48], [49], [50], [51], [52], [53], [54], [55].
- **Estabilidad del patrón** (22 trabajos): [11], [12], [56], [57], [58], [59], [60], [61], [62], [63], [64], [65], [66], [67], [68], [69], [70], [71], [72], [73], [74], [75].
- **T1, TabPFN frente a ajuste fino** (14 trabajos): [5], [7], [8], [9], [36], [76], [77], [78], [79], [80], [81], [82], [83], [84].
- **Conteos bayesianos** (14 trabajos): [13], [15], [16], [17], [85], [86], [87], [88], [89], [90], [91], [92], [93], [94].

5.5.2 Qué se eligió, qué no funcionó y qué se aprendió

Qué se eligió y por qué

El motivo se predice mejor con un modelo tabular en contexto que con un clasificador entrenado. TabPFN-3.5 no se ajusta a los datos: recibe 20,000 ejemplos y predice el resto. Aun así gana +12.9 % a la mejor combinación entrenada y mantiene la ventaja en 2025-H1. Que la ablación con 256 componentes empate y la de 1,024 columnas pierda dice que el límite está en cuántas columnas puede ver cada estimador, no en la riqueza del embedding. El costo es una licencia no comercial que un banco tendría que negociar.

Para solución y compensación, lo simple basta. TF-IDF con una regresión logística calibrada supera a la regla por producto y los embeddings no suman el 5 % exigido. La regla de orden de complejidad evitó quedarse con un modelo más caro por una décima.

Los patrones son una partición útil, no categorías. k-means sobre UMAP 15 pasó todos los criterios: grupos de tamaño razonable, estables entre submuestras y que cubren 99 % de los reclamos futuros. HDBSCAN dejaba la mitad de los reclamos como ruido y CURE juntaba casi todo en un grupo. La ronda de sensibilidad confirmó que ningún otro espacio da grupos claramente mejores, y que otra semilla de UMAP da otra partición de calidad parecida. Por

eso el catálogo del anexo A describe cada patrón con sus palabras y ejemplos, para que la persona entienda qué agrupa, en lugar de tratarlos como etiquetas del negocio.

En el conteo semanal, la memoria corta gana a la sofisticación. La binomial negativa jerárquica con memoria que decae (C-A) mejora a la de cuatro semanas de igual peso y a tres alternativas más complejas: un espacio de estados con innovaciones t de Student (C-B), que no superó a v3 con claridad, y dos modelos fundacionales de series sin entrenamiento (Chronos-2 y TimesFM), que fueron peores que la referencia bayesiana. Las series de 40 patrones son cortas y ruidosas; un modelo que condiciona en el total de la semana y reparte por participación reciente captura lo esencial.

Las alertas necesitan un presupuesto explícito. Fijar una falsa alarma al mes y derivar los umbrales por simulación hizo comparable a CUSUM con la regla de una semana: CUSUM detecta más crecimiento sostenido con el mismo presupuesto. La elección se tomó con la regla de 5 puntos escrita antes.

A escala diaria, el conteo funciona y la alerta no. D-D predice el conteo diario de cada patrón con 25 % menos error que la Poisson de 7 días, y el efecto de día de semana es lo que más aporta. Pero una ráfaga de ×2 durante tres días queda dentro del ruido de una binomial negativa con dispersión moderada, y los excesos diarios reales tienen colas más pesadas que la normal con la que se simularon los umbrales: la regla avisa dos o tres veces más de lo presupuestado y detecta menos de la mitad. El bloque diario deja un modelo de expectativa diaria útil y una regla que, rediseñada con umbrales empíricos y ventana de tres días, tampoco alcanzó la detección exigida (la sección 5.5); no es un sustituto de M11.

Qué no funcionó, y qué se aprendió

- **T4.** La respuesta fuera de plazo no se predice del texto: el modelo no supera a la regla por producto en validación y se reemplazó por una regla de plazo con calendario de feriados. Fue correcto fijar de antemano que la confirmación en validación podía rechazar un componente.
- **BGE solo texto para T1.** Perdió frente a TF-IDF + producto: el producto es una columna barata que vale más que la riqueza del embedding en esa tarea.
- **HDBSCAN y CURE.** Son más elegantes que k-means, pero los criterios de aceptación (ruido, cobertura futura, tamaño del grupo mayor) los descartaron. Los criterios estaban escritos antes de correr.
- **Modelos fundacionales de series.** Chronos-2 y TimesFM sin entrenamiento no ganan a una binomial negativa bien especificada en series cortas con total conocido. Es lo que reportan los benchmarks recientes en series cortas y ruidosas [21]; su valor está en series largas sin covariables.
- **D-B, el espacio de estados diario.** Con 39 contrastes y 639 días, el muestreador satura la profundidad de árbol tanto en la parametrización centrada (R-hat 1.87) como en la no centrada (R-hat 1.68). Una corrida completa superaría las 8 horas del clúster. Un filtro de Kalman sobre una aproximación gaussiana sería la vía, fuera de esta ronda.
- **El eco de las ráfagas.** Cuando un patrón recibe más de la mitad de los reclamos de una semana, M9 espera de más para ese patrón y de menos para los otros en las semanas siguientes, y M11 avisa por eso. La memoria corta lo atenúa pero no lo corrige; un recorte de semanas atípicas se probó en ajuste y no ganó. La reponderación de las semanas con

brote, que la vigilancia epidemiológica usa con líneas base de años [27], [28], se probó en el cierre y empeoró el eco (la sección 5.5): con memoria corta se realimenta.

- **La señal de mezcla rara en 2023.** Marcó 19 de 87 semanas de ajuste: una única concentración κ no describe la variación de composición de ese año. La señal sirve como ordenación de semanas, no como prueba.
- **Kumo Tabular y Relational.** No cupieron en la memoria del clúster; quedan como prueba futura, igual que el ajuste fino de TabPFN.
- **Los tres candidatos del cierre.** El voto de vecinos, la reponderación de M11 y la alerta diaria de tres días fallaron sus reglas (la sección 5.5). Los tres dejaron una explicación: la proyección UMAP no es reproducible y los vecinos definen otra partición; una memoria de dos semanas se realimenta si se reponderan sus propias anomalías; y a resolución diaria, honrar el presupuesto de falsas alarmas deja la señal por patrón debajo del ruido. El contraste con la literatura confirmó las tres lecturas.

El valor del pre-registro se vio en cada uno de estos casos: el criterio estaba escrito, la decisión fue mecánica y el resultado negativo quedó documentado con la misma calidad que el positivo.

5.5.3 Expectativas y limitaciones

Qué se puede esperar del prototipo

- Una sugerencia de motivo acertada entre las tres primeras en 96 % de los reclamos, que reduce lectura y derivaciones erradas pero no elimina la revisión.
- Probabilidades de solución y compensación útiles para priorizar, con precisión promedio 0.57 y 0.27 en el periodo posterior al ajuste.
- Una expectativa semanal por patrón con intervalos que cubren 97 % de los conteos en calibración, y alrededor de 1.4 alertas al mes para revisión humana en un periodo tranquilo; muchas más en un periodo con ráfagas, como 2025-H1.
- Una expectativa diaria por patrón con intervalos, para el día a día, sin alerta automática asociada.

Límites declarados

- **Etiquetas aproximadas.** El motivo y las respuestas de la CFPB no son las categorías internas de un banco peruano. T2 y T3 miden lo que la empresa respondió, no lo que el cliente merecía. Ninguna salida detecta fraude.
- **Taxonomía sin revisión del negocio.** El mapa canónico de productos y motivos es una propuesta congelada (proposed_no_business_review); un banco tendría que revisarlo antes de usar T1.
- **Validación consultada.** Todo lo decidido después del 2026-10-01 se eligió con ajuste y calibración, pero su cifra de 2025-H1 se conoció al confirmar los componentes iniciales. Esas cifras son informativas, no evidencia limpia. 2026 queda sellado como prueba final cuando su cobertura esté completa.
- **Licencias.** TabPFN-3.5 y TimesFM 3.0 tienen licencias de uso no comercial; sirven para esta evaluación académica, pero usar TabPFN con un banco requiere una licencia de Prior Labs. Un experto debe validar esa lectura antes de proponerlo.
- **Deriva.** Los modelos se ajustaron con 2023–2024. Cuando la composición de reclamos cambie, habrá que reajustar; el pipeline ajusta una vez y solo predice, con cuatro señales

de reentrenamiento (novedad, cobertura de M9, mezcla rara y caída de T1 cuando la tabla trae el motivo real).

- **Eco de ráfagas.** Una semana muy concentrada en un patrón contamina las expectativas de las semanas siguientes y produce alertas que son eco, no novedad. La reponderación de esas semanas se probó y empeoró las dos cosas que debía mejorar (la sección 5.5); la persona que revisa debe saberlo.
- **Escala diaria.** En estos datos históricos los días están completos; en producción los últimos días de la CFPB llegan incompletos, así que lo diario solo vale para días maduros o para datos propios sin rezago. No hay calendario de feriados en el modelo: un feriado se ve como un día de bajo volumen. La alerta diaria no se adoptó en ninguna de sus dos versiones: con el presupuesto de falsas alarmas respetado, ni la regla de un día ni la ventana de tres días detectan la mitad de una ráfaga ×2.
- **Patrones.** Son una partición útil, no categorías: otro espacio u otra semilla da grupos distintos de calidad parecida, y la proyección de un reclamo nuevo cambia de patrón en alrededor del 9 % de los casos según el lote en que se procesa. El catálogo mitiga lo primero; la masa de frontera por patrón (la sección 5.5) acompaña a cada alarma para leer lo segundo.
- **Cómputo.** Las corridas bayesianas completas necesitan un clúster (Khipu, cola estándar, hasta 8 horas por trabajo); un espacio de estados diario no cupo. El pipeline de inferencia, en cambio, solo predice y corre en un equipo común.
- **Transferencia.** El método se traslada a un banco; las cifras no. Con datos propios habría que repetir la preparación, el protocolo y las rondas de candidatos con los mismos criterios.

CAPÍTULO VI. IMPLEMENTACIÓN, VIABILIDAD Y SIGUIENTE FASE

6.1 Viabilidad operativa y tecnológica

El prototipo separa el cómputo caro del cómputo diario. El **ajuste** de todos los componentes corrió en el clúster Khipu de UTEC (SLURM, cola estándar de hasta 8 horas por trabajo, GPU para embeddings y TabPFN); la corrida más larga de los modelos vigentes fue de 71 minutos (conteo diario) y la prueba de punta a punta del pipeline de 12 minutos con GPU. La **puntuación** no reentrena: carga los archivos congelados y aplica aritmética; en CPU solo el paso de embeddings es costoso (3 horas para dos semanas con 16 núcleos), y el clasificador de motivo cae al lineal de respaldo si no hay pesos de TabPFN.

Tabla 23: Qué hace falta para operar el prototipo y cada cuánto reentrenar cada componente, según las señales que el propio pipeline escribe en score.json.

Pieza	Qué implica	Cada cuánto
Artefactos congelados (DVC)	13.7 GB en total; para puntuar bastan ~2.5 GB: espacio semántico, patrones, clasificadores, corridas vigentes de M9, M10 y D-D, historia de conteos	Una vez; se reemplazan al reentrenar
Fuera de DVC	Modelo BGE-large (1.3 GB, público) y pesos de TabPFN-3.5 (~1 GB, licencia no comercial)	Una vez
M9, M10, M11 y D-D	Reentrenar con ventana móvil	Cada trimestre, o antes si la cobertura del 80 % en las últimas 12 semanas baja de 70 %
Patrones y novedad	Rehacer M6 → M7 → M8B; cambia el catálogo	Solo si los novedosos superan 3 %; como máximo una vez al año
T1 (contexto de TabPFN)	Renovar las 20,000 filas de contexto con reclamos recientes	Si Macro-F1 cae más de 5 % relativo (requiere motivo real en la tabla)
T2 y T3	Reentrenar y reelegir umbrales en calibración	Cada 6 meses
Índice de vecinos	Reconstruir con el último año	Cada trimestre
Calendario de feriados	Actualizar el YAML	Cada año

Para una entidad, la infraestructura mínima es un servidor con GPU para el lote nocturno (o CPU con el clasificador de respaldo), almacenamiento para los artefactos y un servicio ligero para la ficha por reclamo; el observatorio ya corre en Streamlit sobre los archivos del pipeline. Las capacidades requeridas son un responsable de datos que vigile las señales de reentrenamiento y un equipo de atención que use las salidas y registre su feedback.

6.2 Viabilidad financiera

Los costos conocidos del proyecto son de cómputo y de licencias. El entrenamiento usó horas del clúster académico sin costo para el equipo; una estimación de mercado del cómputo equivalente, de las licencias y del servicio en producción requiere cifras que el equipo de Product Lead debe aportar.

Tabla 24: Partidas de costo y de valor identificadas. Cada cifra se etiqueta como dato o supuesto; las marcadas PENDIENTE las completa el Product Lead.

Partida	Descripción	Tipo de evidencia
Cómputo de entrenamiento	Khipu (UTEC): ~20 horas-GPU y ~40 horas-CPU en total para los modelos vigentes y sus candidatos	dato aproximado del registro de jobs; costo monetario en nube: PENDIENTE PL
Cómputo de puntuación	Lote diario de ~2,500 reclamos: minutos de GPU o ~15 minutos de CPU	supuesto derivado de la prueba de punta a punta (35,265 reclamos en 12 min GPU)
Licencia de TabPFN-3.5	Uso no comercial gratuito; uso con un banco requiere licencia de Prior Labs	dato (licencia); precio: PENDIENTE PL
Operación y mantenimiento	Un responsable de datos a tiempo parcial; reentrenamientos trimestrales	supuesto
Valor: tiempo de lectura y derivaciones erradas evitadas	Frecuencia × costo del error × población	PENDIENTE PL: dimensionamiento del one-pager (bloque 2 y pitch)
Valor: detección temprana de aumentos	Alertas revisables al mes y acción preventiva	PENDIENTE PL: costo de un aumento no detectado

PENDIENTE (Product Lead): completar la viabilidad financiera con las cifras del one-pager (bloque 10) y del pitch: inversión inicial, costo anual, ahorro esperado y escenarios. Un supuesto declarado es aceptable; una cifra sin fuente, no.

6.3 Roadmap y siguientes pasos

La siguiente fase prioriza por costo y por lo que el contraste con la literatura señaló como más probable de funcionar:

1. **Producto (Capstone II, primera prioridad).** Ficha completa del reclamo en el observatorio con T2/T3, vecinos con desenlace, novedad y fiabilidad del patrón; vista «patrones que suben» por semana y día con filtro de fechas; registro del feedback humano desde el primer día; API por reclamo; capa de lenguaje natural con LangGraph que explica y redacta a partir de las salidas, con revisión humana obligatoria.
2. **Alertas.** Alerta multiescala con un solo presupuesto (regla semanal más suma móvil de cuatro semanas) y cuarentena discreta de las semanas con alarma [29], que no se realimenta como la reponderación.
3. **Patrón anclado.** Mezcla gaussiana o prototipos fijos en el espacio PCA, o un codificador paramétrico [12], para que la asignación de un reclamo nuevo sea determinista y traiga su probabilidad; obliga a rehacer los paneles y a reevaluar M9–M11.
4. **T1.** Blanquear los embeddings antes de PCA y TabPFN, y construir el contexto con mínimos por clase y vecinos recuperados; validación experta de la licencia; ajuste fino y ensamble como alternativas.

5. **Conteos.** Participaciones dinámicas con inferencia por bloques (FFBS con Pólya-gamma) solo si el panel crece; ensamble de cuantiles de los candidatos semanales [23].
6. **Datos.** Prueba final sellada en 2026 cuando la base de la CFPB complete ese año; transferencia a reclamos propios de una entidad con la taxonomía revisada por el negocio y los mismos criterios.

6.4 Cronograma o diagrama de Gantt

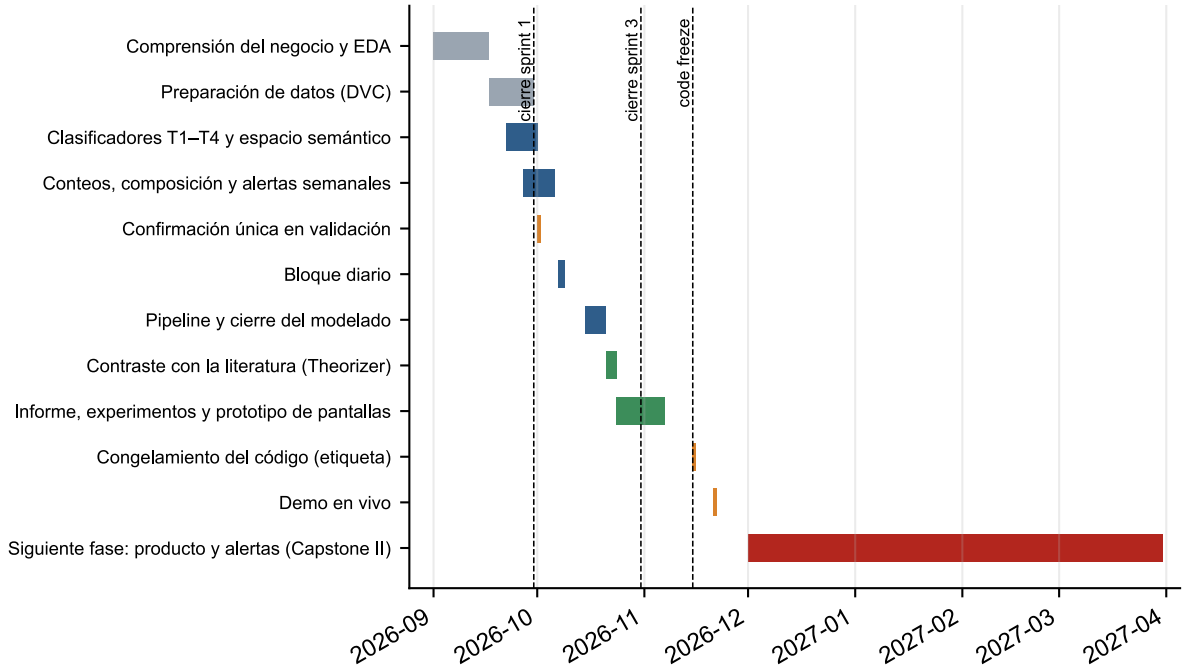


Figura 16: Cronograma del proyecto por fase (2026), con las fechas de los sprints del curso y del cierre del modelado, y la siguiente fase prevista.

6.5 Riesgos y estrategias de mitigación

Tabla 25: Riesgos de implementación y sostenibilidad, con probabilidad, impacto, disparador y mitigación. El plan B de datos es el propio dataset público.

Riesgo	Probabilidad	Impacto	Disparador	Mitigación
Deriva de los datos: la mezcla de reclamos cambia y los modelos de conteo dejan de cubrir	Alta	Medio	Cobertura del 80 % de M9 en las últimas 12 semanas por debajo de 70 %, o novedosos por encima de 3 %	Reentrenamiento trimestral con ventana móvil; las señales están en cada puntuación
Patrón blando: un reclamo cerca de una frontera cambia de patrón según el lote (≈ 9 %)	Cierta	Medio	Alarma de M11 en un patrón con masa de frontera alta	Mostrar la fiabilidad del patrón junto a cada alarma; patrón anclado en la siguiente fase
Licencia de TabPFN-3.5 no disponible para uso comercial	Media	Alto para T1	Negativa o costo inasumible de la licencia	Clasificador lineal de respaldo ya integrado (`t1_model = linear`, Macro-F1 0.240); validación experta de la licencia antes de proponerlo
Eco de las ráfagas: alertas que son eco y no novedad	Alta en periodos con ráfagas	Medio	Varias alertas seguidas en el mismo patrón tras una semana muy concentrada	Marcar la alerta como «eco» en la revisión; cuarentena de semanas con alarma en la siguiente fase
Transferencia: las etiquetas de la CFPB no son las de un banco	Cierta	Alto	Uso con datos propios	Repetir preparación, protocolo y rondas con la taxonomía revisada; el método se traslada, las cifras no
Datos: sin acceso a reclamos de una entidad	Cierta hoy	Medio	No se consigue autorización de uso	Plan B: seguir con el dataset público de la CFPB, declarado como tal; prueba sellada en 2026

CONCLUSIONES

Las conclusiones responden, en orden, al objetivo general y a los siete objetivos específicos del capítulo I.

1. **Objetivo general.** Se construyó y evaluó, de forma reproducible y con reglas fijadas antes de ver los resultados, un prototipo de triaje que entrega evidencia útil en cada una de sus cinco salidas, y se documentó con la misma calidad lo que funcionó y lo que no. El pipeline puntúa una tabla nueva de dos semanas en 12 minutos con GPU sin reentrenar nada.
2. **Tabla preparada (OE1).** Seis etapas de DVC dejan una tabla de 3,837,184 reclamos con texto normalizado, taxonomía congelada, objetivos T1–T4 y tres ventanas por fecha, con diccionario e informe de limpieza generados por el pipeline; la vista sin texto compartido (42.8 % de narrativas repetidas) fue decisiva para evitar métricas optimistas.
3. **Clasificadores (OE2).** El motivo se predice mejor con un modelo tabular en contexto sobre embeddings reducidos que con clasificadores entrenados: Macro-F1 0.271 frente a 0.076 de la regla por producto y 0.240 del mejor modelo entrenado, con la ventaja mantenida en 2025-H1. Para solución y compensación bastan modelos lineales sobre TF-IDF; la respuesta fuera de plazo no se predice del texto y la reemplaza una regla de plazo.
4. **Espacio semántico y patrones (OE3).** Un espacio BGE con PCA y UMAP sostiene la búsqueda de reclamos parecidos (similitud mediana 0.924) y una partición en 40 patrones con cobertura futura de 99 % y una regla de novedad. El patrón es una etiqueta blanda cerca de las fronteras: la proyección cambia la asignación de alrededor del 9 % de los reclamos según el lote, y el sustituto determinista probado no alcanzó su regla.
5. **Conteo, composición y alertas semanales (OE4).** Una binomial negativa jerárquica con memoria corta predice el volumen semanal por patrón con 30 % menos error que la referencia Poisson y gana a alternativas más complejas, incluidos dos modelos fundacionales de series; la Dirichlet-multinomial describe la composición y da una señal de mezcla rara; un CUSUM sobre los excesos, con una falsa alarma al mes fijada por simulación, detecta crecimientos de 10 % y 20 % semanal en 42 % y 71 % de los casos.
6. **Bloque diario (OE5).** La arquitectura funciona a resolución de día para el conteo (25 % menos error que la referencia, con el día de semana como pieza principal), pero ninguna de las dos versiones de la alerta diaria alcanzó la detección exigida con el presupuesto de falsas alarmas: la alerta vive en la semana.
7. **Trazabilidad (OE6).** Cada decisión tiene su regla escrita antes y su evidencia después: 186 filas en la tabla comparativa, 87 corridas en MLflow con commit y hash de datos, artefactos por DVC y un registro de pre-registro. Dos candidatos mejores en apariencia se rechazaron por la regla del bootstrap, un componente se retiró al confirmarlo y los tres candidatos del cierre se rechazaron por reglas escritas antes de correrlos.
8. **Pipeline, cierre y literatura (OE7).** El pipeline de inferencia ajusta una vez y puntúa muchas veces; el contraste con la literatura respalda las elecciones centrales (memoria corta en el conteo semanal, exclusión del espacio de estados diario, rechazo de la reponderación) y señala qué habría hecho distinto, que es el roadmap del capítulo VI.
9. **Alcance de la evidencia.** Las etiquetas de la CFPB aproximan las de un banco y las cifras no se trasladan; el método sí. La evidencia de negocio (stakeholders, dimensionamiento, viabilidad financiera) es documental y está marcada como pendiente de los Product Lead en este documento.

REFERENCIAS BIBLIOGRÁFICAS

ANEXOS

Anexo A. Catálogo de los 40 patrones

Cada patrón se describe con su producto principal, su tamaño en ajuste, los términos que lo distinguen (TF-IDF del patrón frente al resto) y su serie semanal con las bandas de M9 y las alertas de M11. Los ejemplos completos, con fragmentos de narrativa, están en `reports/modeling/patterns/catalogo.html`.

Patrón 00

Producto principal: Credit reporting or other personal consumer reports (84 % de sus reclamos). **Reclamos en ajuste:** 1,947 (21.4 por semana, 0.19 % del total). **Texto único:** 2 %. **Alertas de M11:** ajuste: 2023-12-25; validación: 2025-06-23.

Términos: disputes, submitting disputes, getting inaccurate, send disputes, bureaus having, disputes getting, tried send, information corrected, corrected credit, difficulties submitting.

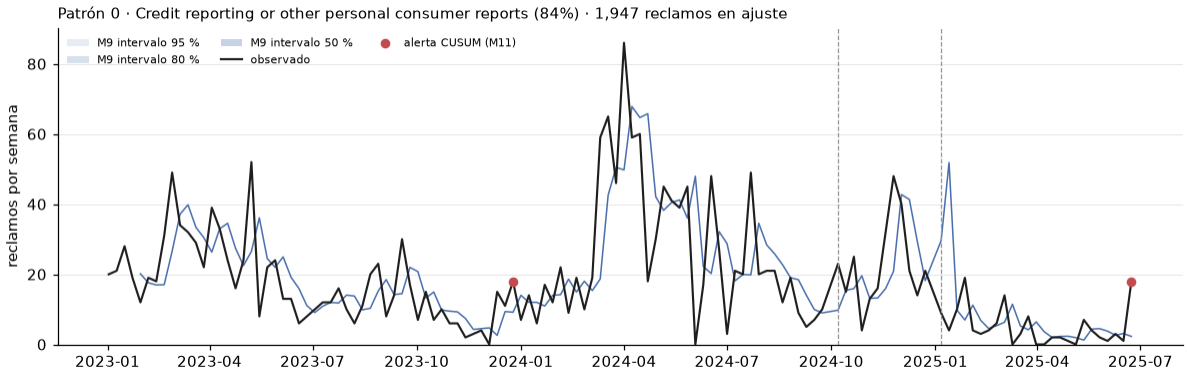


Figura 17: Serie semanal del patrón 00

Patrón 01

Producto principal: Credit reporting or other personal consumer reports (86 % de sus reclamos). **Reclamos en ajuste:** 5,995 (65.8 por semana, 0.52 % del total). **Texto único:** 9 %. **Alertas de M11:** ajuste: 2023-05-08; validación: 2025-01-06.

Términos: 100, credit, 100 accurate, reporting 100, credit report, accurate, report, accounts, did, reporting.

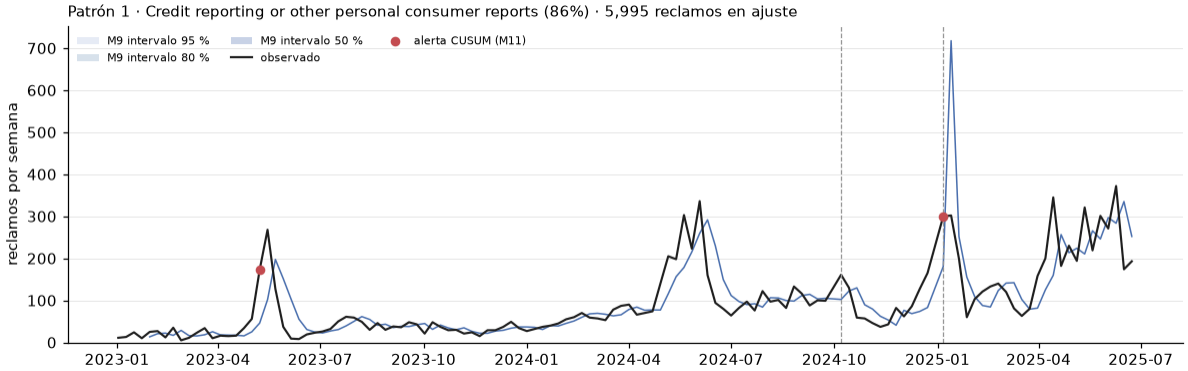


Figura 18: Serie semanal del patrón 01

Patrón 02

Producto principal: Credit reporting or other personal consumer reports (98 % de sus reclamos). **Reclamos en ajuste:** 8,520 (93.1 por semana, 0.70 % del total). **Texto único:** 9 %. **Alertas de M11:** ajuste: 2023-07-10, 2024-01-22; validación: 2025-03-17.

Términos: section, information, consumer, 15, reporting, items, agency, reporting agency, 1681, states.

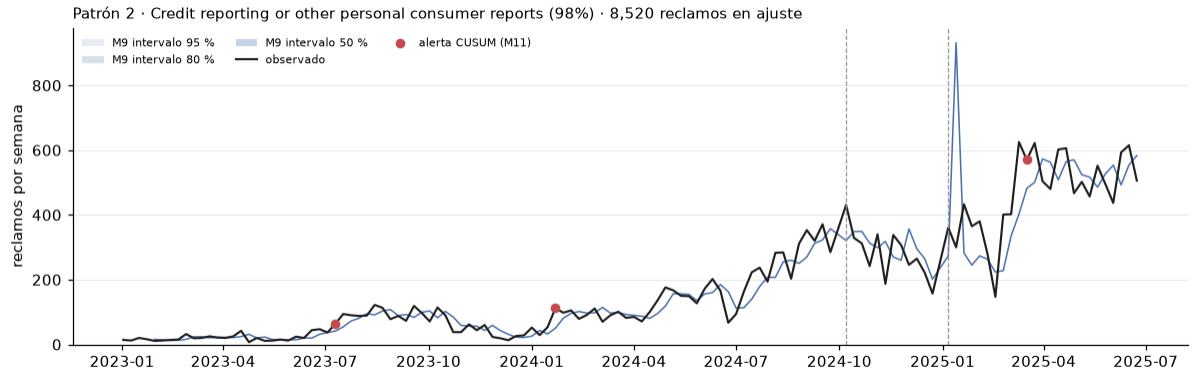


Figura 19: Serie semanal del patrón 02

Patrón 03

Producto principal: Credit reporting or other personal consumer reports (89 % de sus reclamos). **Reclamos en ajuste:** 35,532 (388.5 por semana, 3.17 % del total). **Texto único:** 53 %. **Alertas de M11:** validación: 2025-01-27, 2025-02-10, 2025-03-03.

Términos: redacted, redacted redacted, account, credit, information, consumer, reporting, report, fcra, credit report.

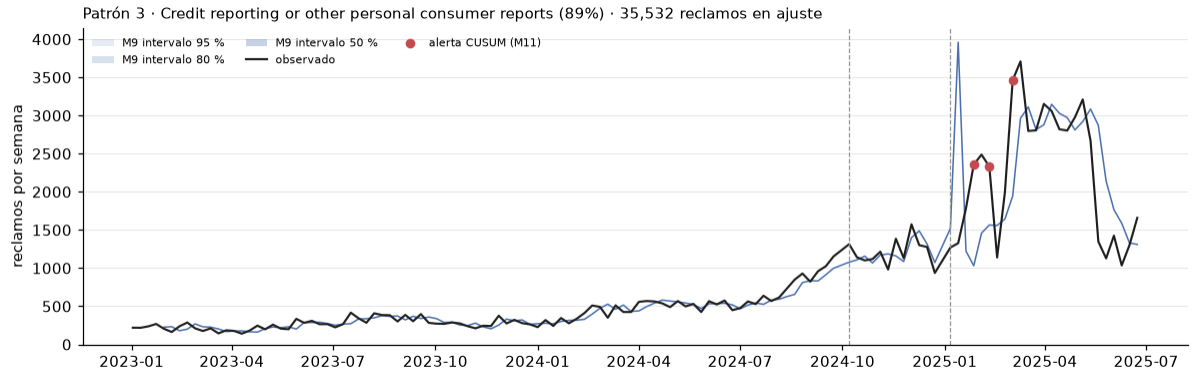


Figura 20: Serie semanal del patrón 03

Patrón 04

Producto principal: Credit reporting or other personal consumer reports (98 % de sus reclamos). **Reclamos en ajuste:** 13,290 (145.7 por semana, 1.24 % del total). **Texto único:** 31 %. **Alertas de M11:** ajuste: 2024-03-11; validación: 2025-02-03.

Términos: redacted redacted, redacted, validate, erroneous, credit, authorized fail, proof period, period allowed, allowed law, file listed.

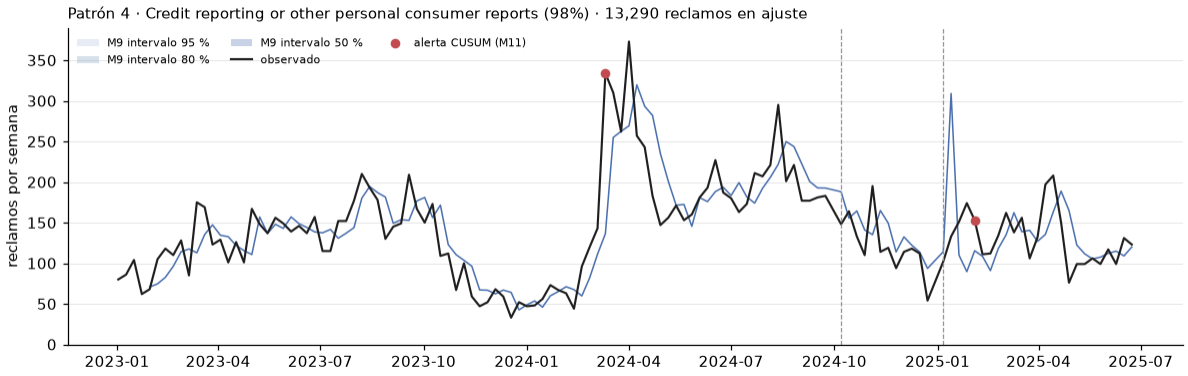


Figura 21: Serie semanal del patrón 04

Patrón 05

Producto principal: Credit reporting or other personal consumer reports (85 % de sus reclamos). **Reclamos en ajuste:** 9,474 (103.8 por semana, 0.83 % del total). **Texto único:** 6 %. **Alertas de M11:** ajuste: 2023-04-17, 2023-05-22.

Términos: consumer, 15, section, states, reporting, report, reporting agency, 1681, consumer reporting, credit.

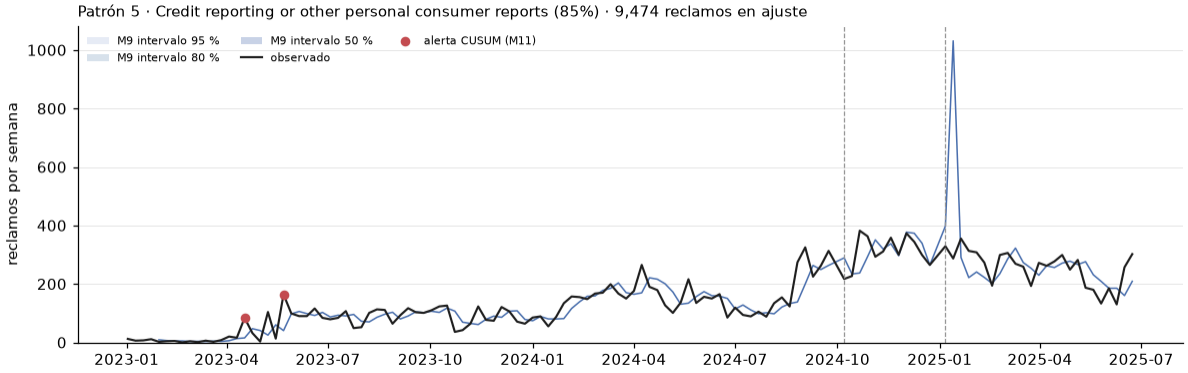


Figura 22: Serie semanal del patrón 05

Patrón 06

Producto principal: Credit reporting or other personal consumer reports (100 % de sus reclamos). **Reclamos en ajuste:** 13,745 (150.8 por semana, 1.37 % del total). **Texto único:** 41 %. **Alertas de M11:** validación: 2025-02-24.

Términos: redacted redacted, redacted, redacted balance, 00 redacted, balance, 00, records, complain question, question specific, coming wrongdoing.

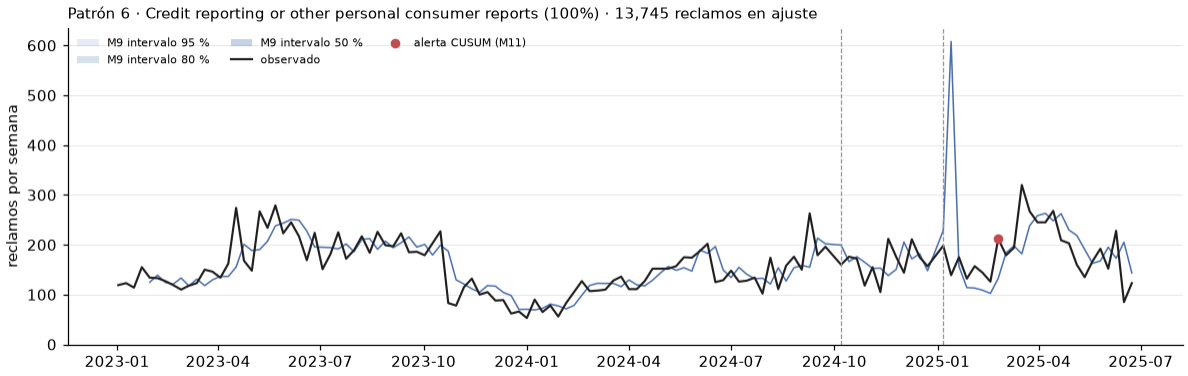


Figura 23: Serie semanal del patrón 06

Patrón 07

Producto principal: Credit reporting or other personal consumer reports (93 % de sus reclamos). **Reclamos en ajuste:** 11,531 (126.4 por semana, 1.06 % del total). **Texto único:** 15 %. **Alertas de M11:** ajuste: 2023-03-20, 2023-04-03; validación: 2025-02-17.

Términos: redacted redacted, redacted, report, credit, disputes, accounts, credit report, verify, 3rd party, information.

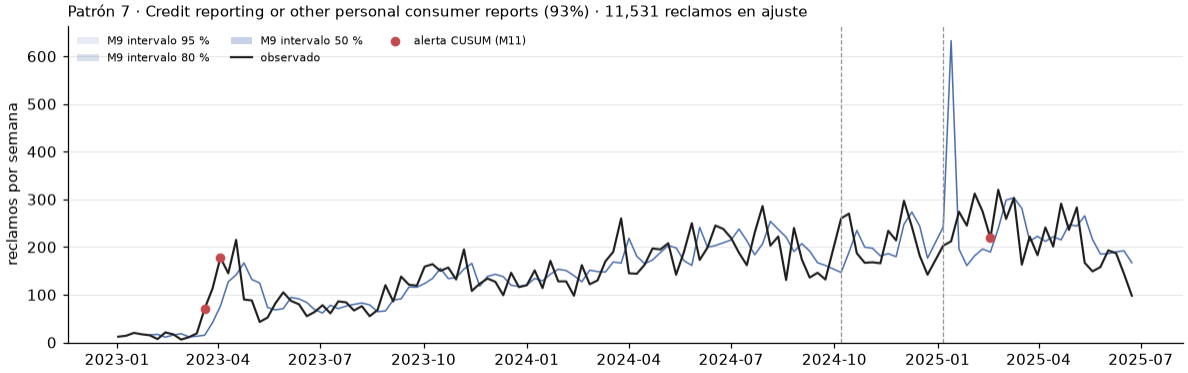


Figura 24: Serie semanal del patrón 07

Patrón 08

Producto principal: Checking or savings account (39 % de sus reclamos). **Reclamos en ajuste:** 119,770 (1,313.3 por semana, 11.77 % del total). **Texto único:** 95 %. **Alertas de M11:** validación: 2025-01-13.

Términos: bank, card, account, redacted, 00, told, money, called, funds, check.

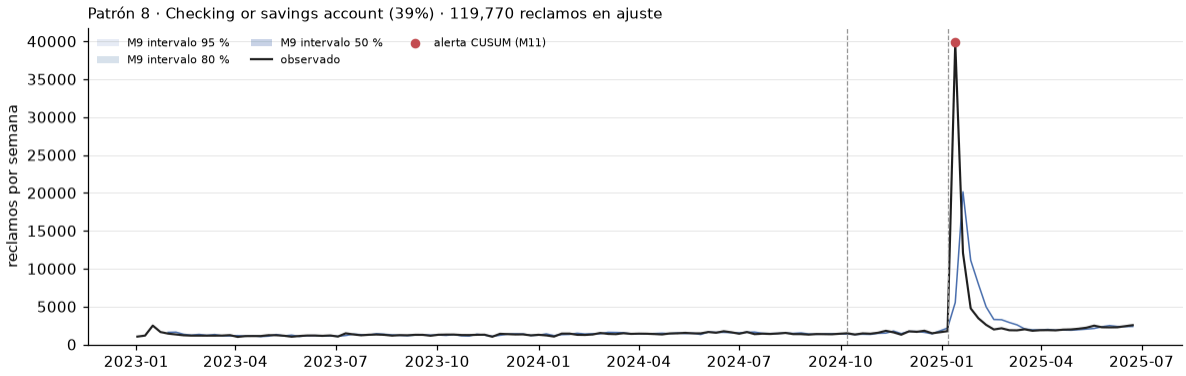


Figura 25: Serie semanal del patrón 08

Patrón 09

Producto principal: Credit reporting or other personal consumer reports (85 % de sus reclamos). **Reclamos en ajuste:** 2,670 (29.3 por semana, 0.24 % del total). **Texto único:** 5 %. **Alertas de M11:** sin alertas de M11.

Términos: complaint, party, complaint error, party involved, involved, reported, error, involved filing, complaint complaint, redacted party.

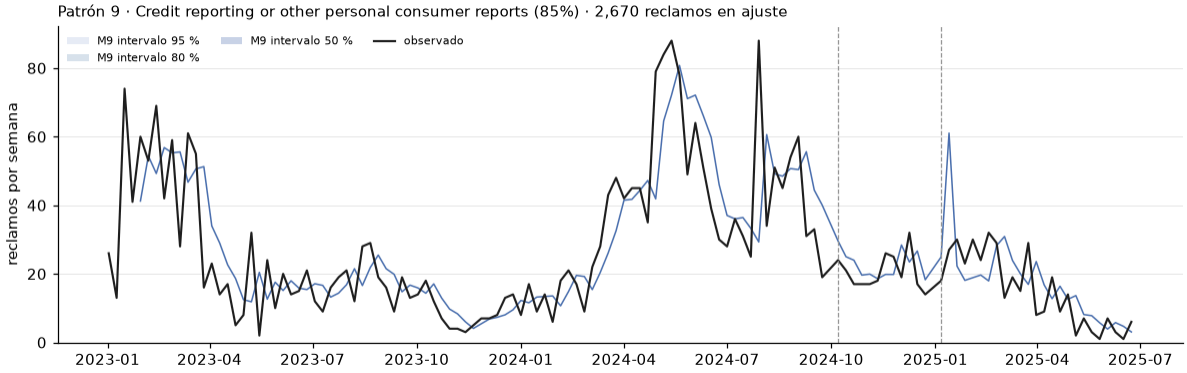


Figura 26: Serie semanal del patrón 09

Patrón 10

Producto principal: Credit reporting or other personal consumer reports (97 % de sus reclamos). **Reclamos en ajuste:** 9,158 (100.5 por semana, 0.84 % del total). **Texto único:** 19 %. **Alertas de M11:** ajuste: 2023-02-13; calibración: 2024-12-02.

Términos: redacted redacted, redacted, report, credit, credit report, consent, complaint, erroneous information, reports, written consent.

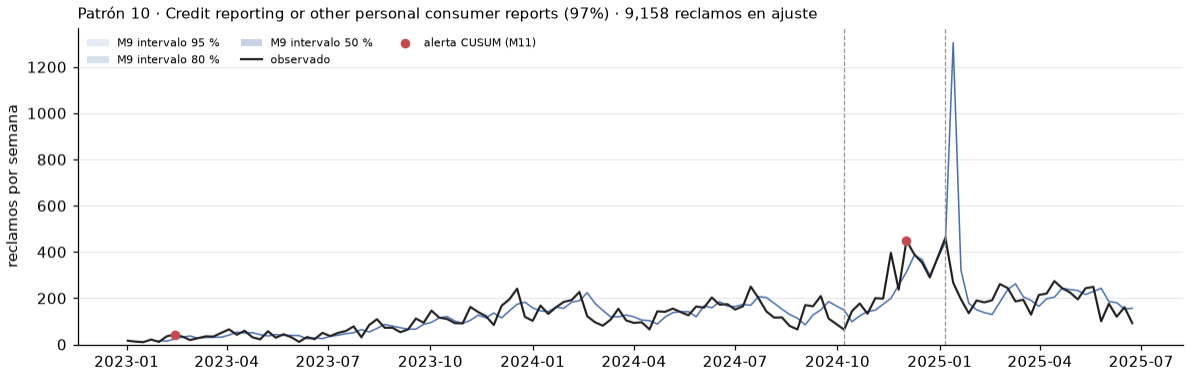


Figura 27: Serie semanal del patrón 10

Patrón 11

Producto principal: Credit reporting or other personal consumer reports (97 % de sus reclamos). **Reclamos en ajuste:** 97,126 (1,065.3 por semana, 9.38 % del total). **Texto único:** 67 %. **Alertas de M11:** ajuste: 2023-02-27; validación: 2025-01-27, 2025-02-17, 2025-06-02.

Términos: redacted redacted, redacted, 00, 00 redacted, redacted balance, balance, credit, inquiries, items, remove.

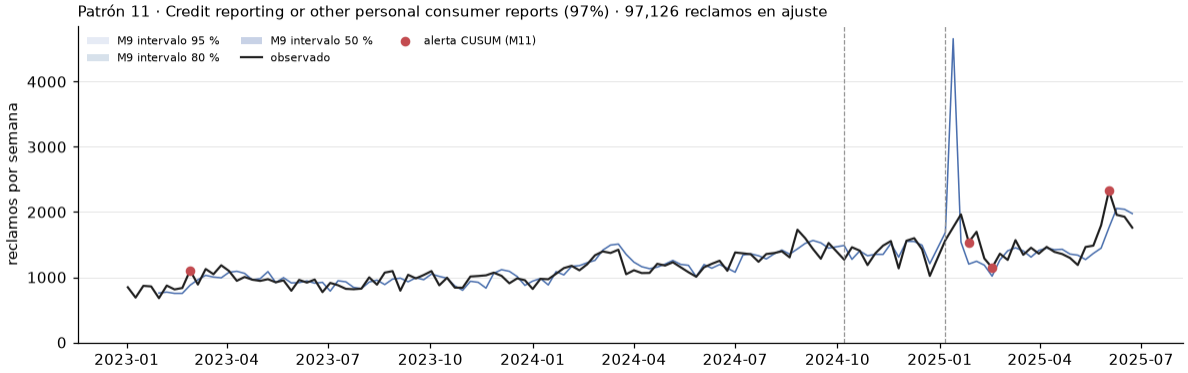


Figura 28: Serie semanal del patrón 11

Patrón 12

Producto principal: Debt collection (55 % de sus reclamos). **Reclamos en ajuste:** 86,363 (946.5 por semana, 8.30 % del total). **Texto único:** 88 %. **Alertas de M11:** validación: 2025-01-27.

Términos: debt, collection, redacted, redacted redacted, account, company, alleged, credit, collect, validation.

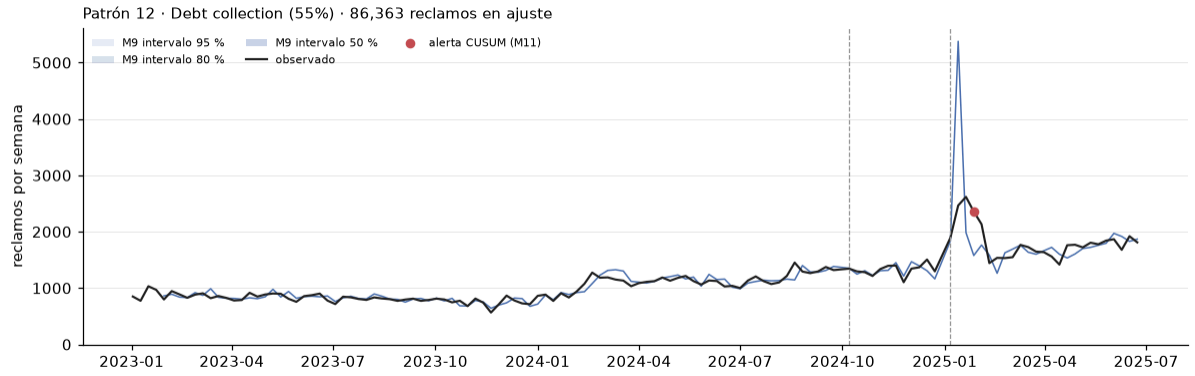


Figura 29: Serie semanal del patrón 12

Patrón 13

Producto principal: Credit reporting or other personal consumer reports (37 % de sus reclamos). **Reclamos en ajuste:** 97,382 (1,067.1 por semana, 9.56 % del total). **Texto único:** 88 %. **Alertas de M11:** validación: 2025-01-27, 2025-02-10.

Términos: loan, redacted, mortgage, payment, redacted redacted, told, payments, 00, paid, account.

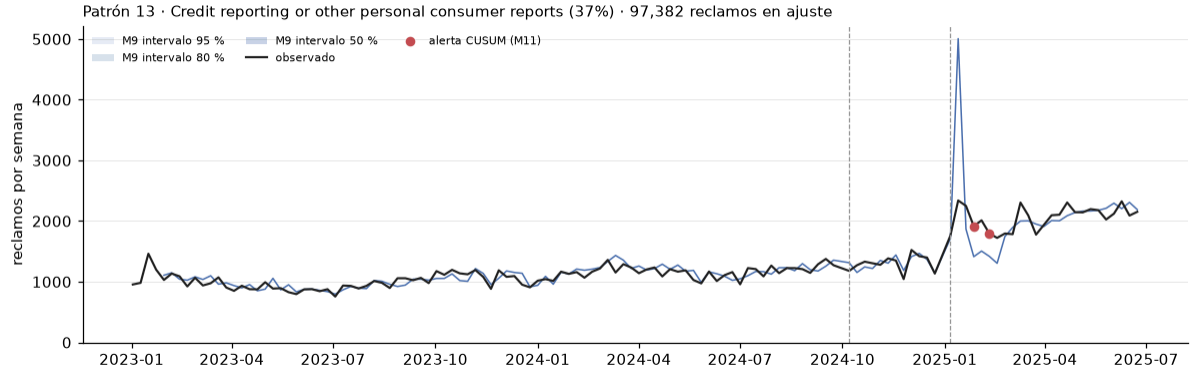


Figura 30: Serie semanal del patrón 13

Patrón 14

Producto principal: Credit reporting or other personal consumer reports (94 % de sus reclamos). **Reclamos en ajuste:** 176,716 (1,936.1 por semana, 16.70 % del total). **Texto único:** 80 %. **Alertas de M11:** calibración: 2024-11-11; validación: 2025-01-20, 2025-02-03, 2025-05-26.

Términos: redacted, redacted redacted, account, credit, report, information, credit report, reporting, fcra, consumer.

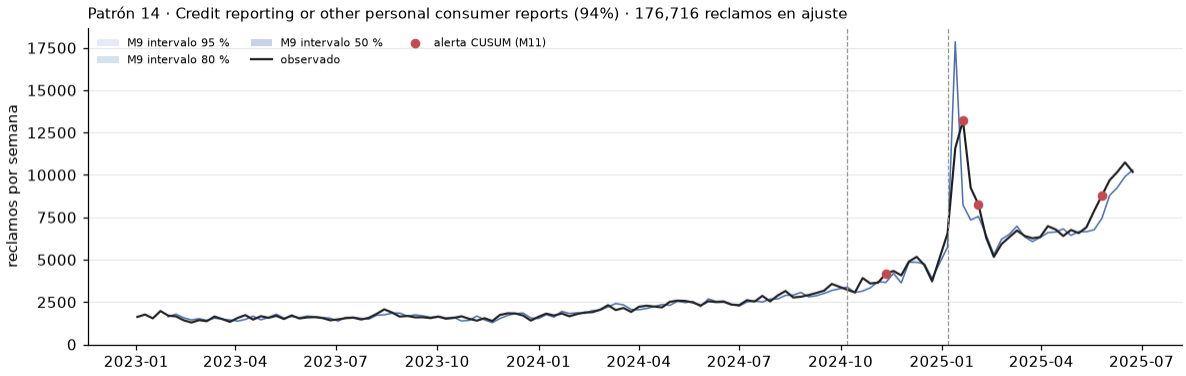


Figura 31: Serie semanal del patrón 14

Patrón 15

Producto principal: Credit reporting or other personal consumer reports (98 % de sus reclamos). **Reclamos en ajuste:** 7,597 (83.2 por semana, 0.74 % del total). **Texto único:** 1 %. **Alertas de M11:** ajuste: 2023-05-08.

Términos: letters, bureaus continuously, far gotten, happened mailed, continuously far, really sure, sure happened, involved review, gotten response, mailed letters.

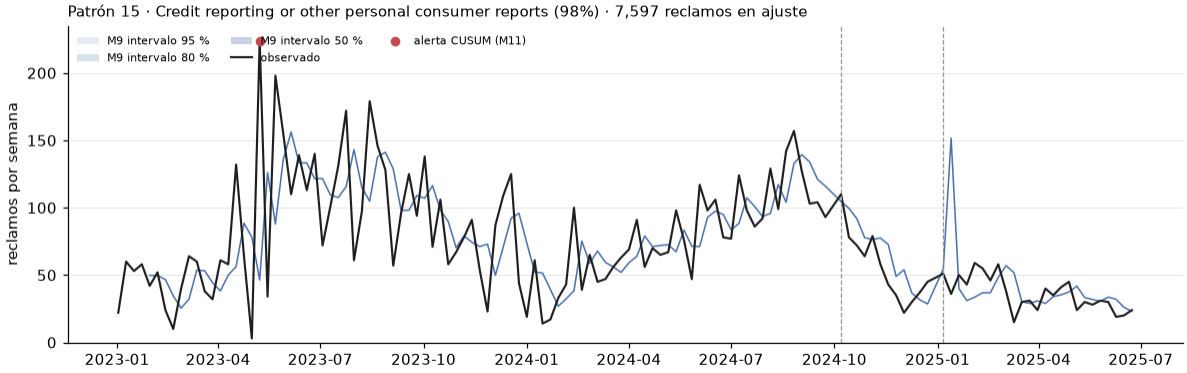


Figura 32: Serie semanal del patrón 15

Patrón 16

Producto principal: Credit reporting or other personal consumer reports (96 % de sus reclamos). **Reclamos en ajuste:** 9,342 (101.7 por semana, 0.74 % del total). **Texto único:** 3 %. **Alertas de M11:** ajuste: 2023-02-20, 2023-07-03, 2024-02-05.

Términos: consumer, 15, section, reporting agency, 1681, reporting, states, consumer reporting, agency, information.

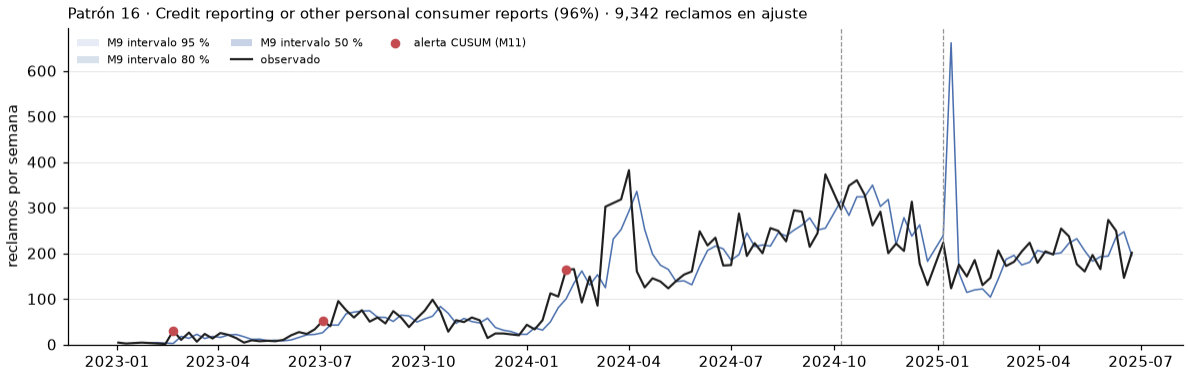


Figura 33: Serie semanal del patrón 16

Patrón 17

Producto principal: Credit reporting or other personal consumer reports (94 % de sus reclamos). **Reclamos en ajuste:** 71,113 (779.1 por semana, 7.12 % del total). **Texto único:** 56 %. **Alertas de M11:** ajuste: 2023-02-27; validación: 2025-02-03.

Términos: redacted account, account, account redacted, section, redacted, redacted redacted, 15, 1681, states, consumer.

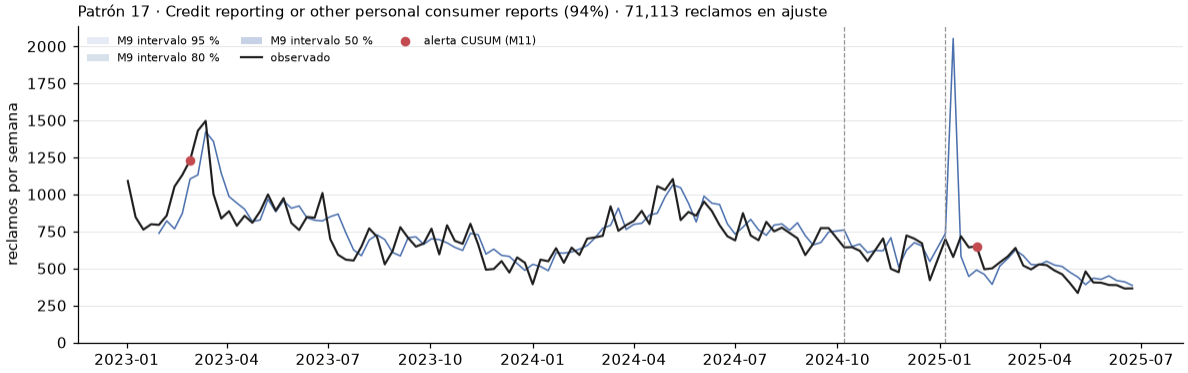


Figura 34: Serie semanal del patrón 17

Patrón 18

Producto principal: Credit reporting or other personal consumer reports (88 % de sus reclamos). **Reclamos en ajuste:** 10,792 (118.2 por semana, 0.97 % del total). **Texto único:** 24 %. **Alertas de M11:** ajuste: 2023-02-20, 2024-05-20.

Términos: redacted redacted, redacted, permitted, legitimate activity, report, legitimate, activity, credit report, credit, redacted balance.

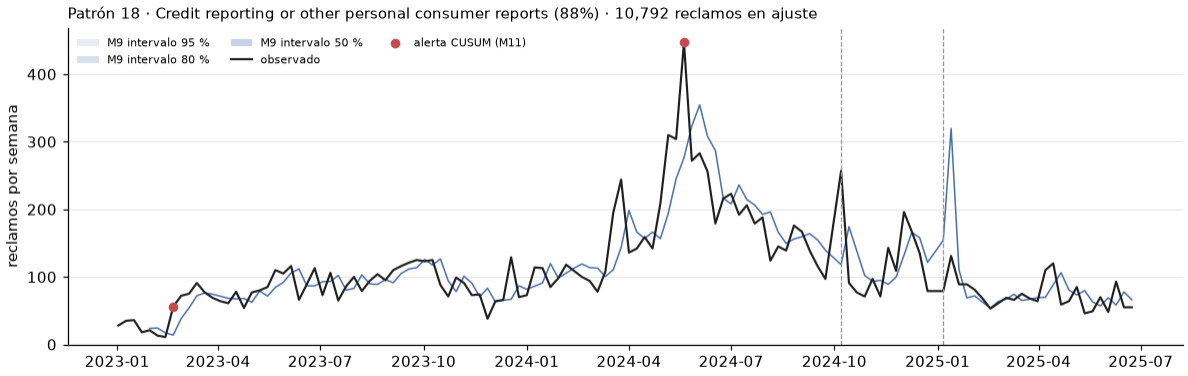


Figura 35: Serie semanal del patrón 18

Patrón 19

Producto principal: Credit reporting or other personal consumer reports (91 % de sus reclamos). **Reclamos en ajuste:** 63,214 (692.8 por semana, 5.62 % del total). **Texto único:** 37 %. **Alertas de M11:** ajuste: 2024-01-01; validación: 2025-01-27.

Términos: credit, credit report, report, redacted redacted, redacted, identity, accounts, inquiries, theft, identity theft.

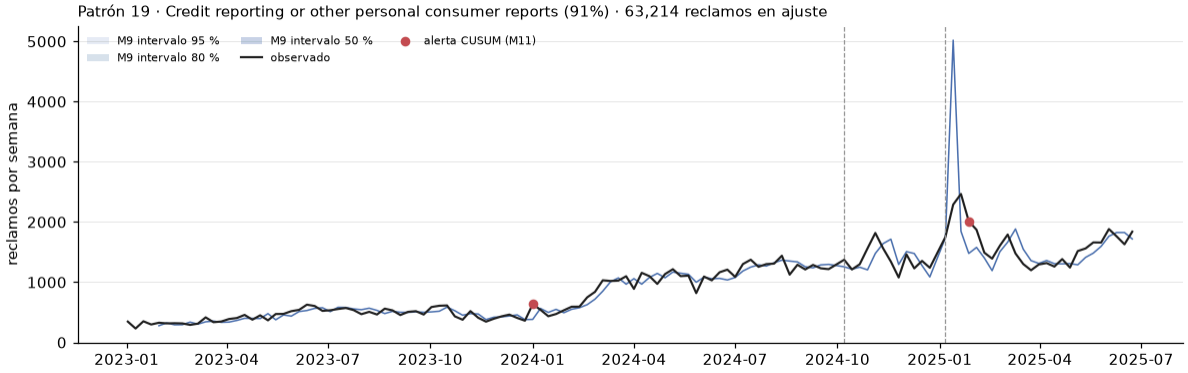


Figura 36: Serie semanal del patrón 19

Patrón 20

Producto principal: Credit reporting or other personal consumer reports (99 % de sus reclamos). **Reclamos en ajuste:** 3,371 (36.9 por semana, 0.29 % del total). **Texto único:** 3 %. **Alertas de M11:** ajuste: 2023-03-27, 2024-01-29.

Términos: consumer reports, consent, reports, consumer, consent fraud, reports consent, reports gave, gave written, consent report, purposes consumer.

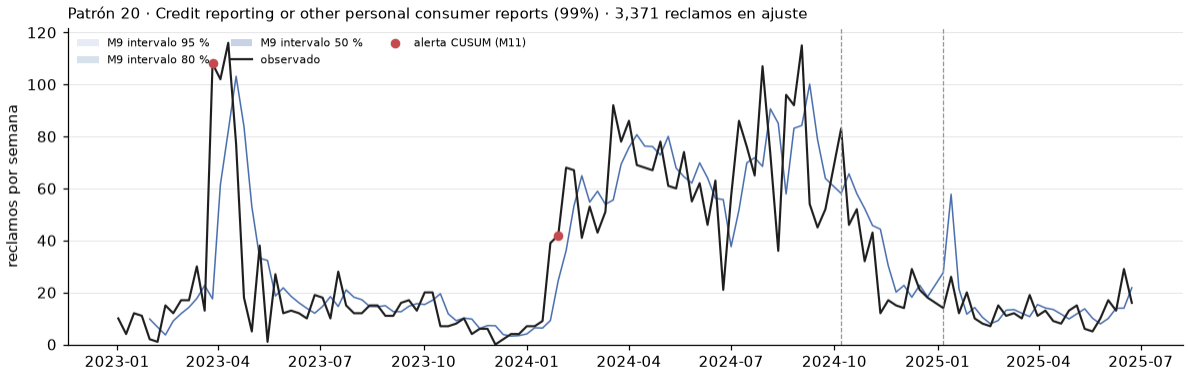


Figura 37: Serie semanal del patrón 20

Patrón 21

Producto principal: Credit reporting or other personal consumer reports (57 % de sus reclamos). **Reclamos en ajuste:** 4,109 (45.0 por semana, 0.42 % del total). **Texto único:** 2 %. **Alertas de M11:** ajuste: 2023-02-20; validación: 2025-02-17.

Términos: start investigation, bureau start, documents want, want bureau, start, investigation accounts, accounts late, reporting late, late, attached documents.

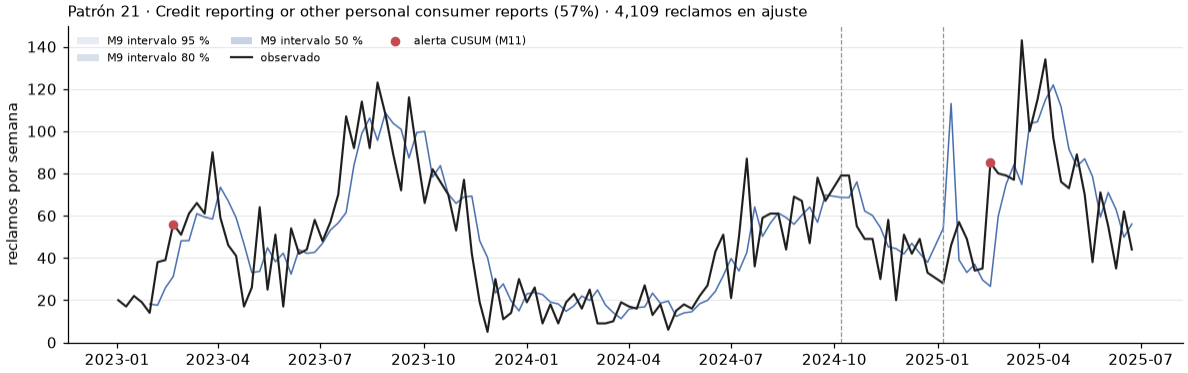


Figura 38: Serie semanal del patrón 21

Patrón 22

Producto principal: Credit reporting or other personal consumer reports (96 % de sus reclamos). **Reclamos en ajuste:** 12,879 (141.1 por semana, 1.17 % del total). **Texto único:** 21 %. **Alertas de M11:** validación: 2025-02-10.

Términos: redacted redacted, redacted, law, written requests, violation federal, requests, items, federal law, consumer, accounts.

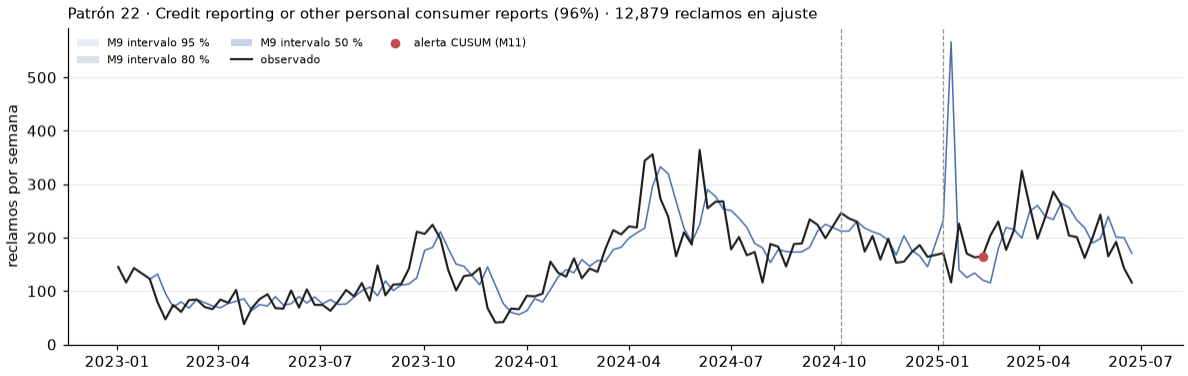


Figura 39: Serie semanal del patrón 22

Patrón 23

Producto principal: Credit reporting or other personal consumer reports (96 % de sus reclamos). **Reclamos en ajuste:** 6,407 (70.2 por semana, 0.55 % del total). **Texto único:** 5 %. **Alertas de M11:** ajuste: 2023-05-29.

Términos: 15, consumer, agency, section, reporting, reporting agency, 1681, states, consumer reporting, information.

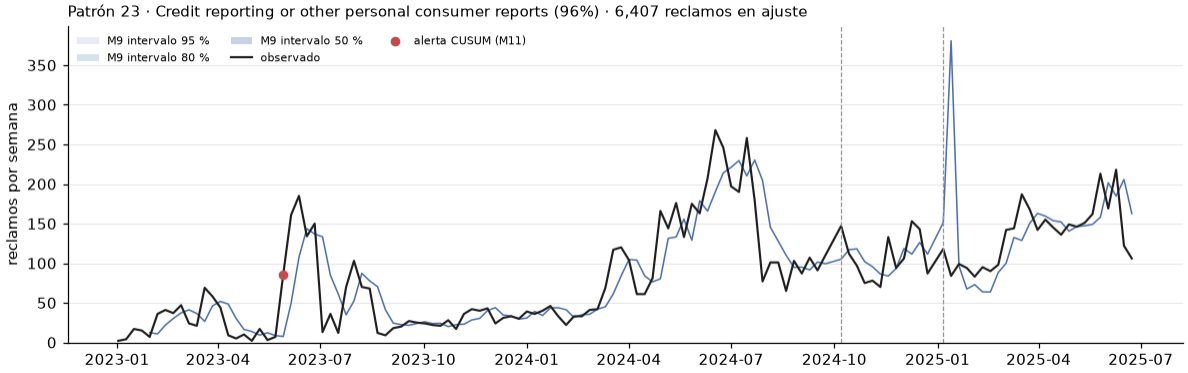


Figura 40: Serie semanal del patrón 23

Patrón 24

Producto principal: Credit reporting or other personal consumer reports (84 % de sus reclamos). **Reclamos en ajuste:** 9,733 (106.2 por semana, 0.80 % del total). **Texto único:** 14 %. **Alertas de M11:** ajuste: 2024-04-22.

Términos: redacted redacted, items, redacted, stress, accounts, unseen, identity, disputed items, remove, stolen.

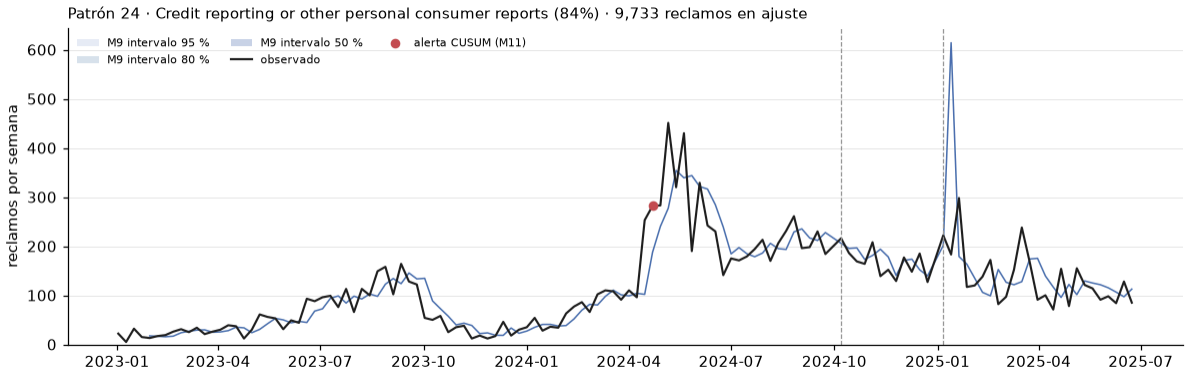


Figura 41: Serie semanal del patrón 24

Patrón 25

Producto principal: Credit reporting or other personal consumer reports (97 % de sus reclamos). **Reclamos en ajuste:** 14,204 (155.8 por semana, 1.37 % del total). **Texto único:** 33 %. **Alertas de M11:** ajuste: 2024-05-20; validación: 2025-02-03.

Términos: sections 609, sections, 609 611, 609, redacted, 611, redacted redacted, redacted balance, balance, 00.

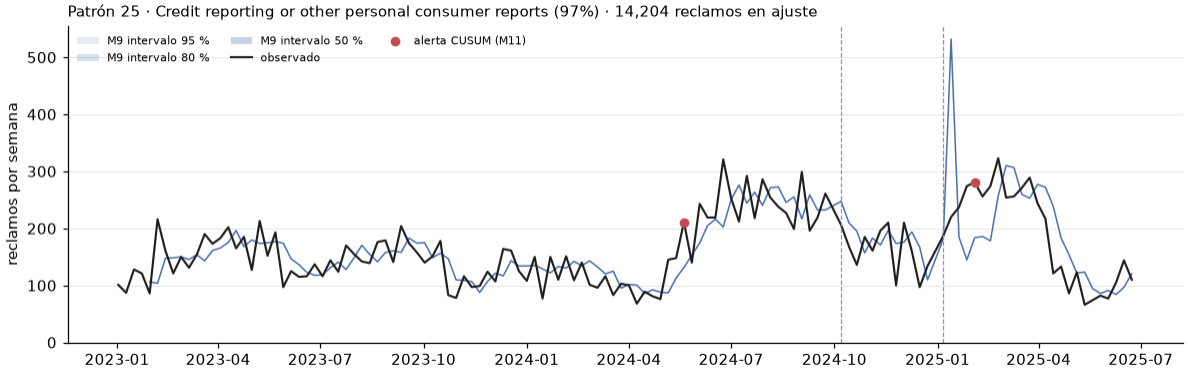


Figura 42: Serie semanal del patrón 25

Patrón 26

Producto principal: Credit reporting or other personal consumer reports (91 % de sus reclamos). **Reclamos en ajuste:** 11,256 (123.5 por semana, 0.95 % del total). **Texto único:** 16 %. **Alertas de M11:** ajuste: 2023-12-18.

Términos: accounts, credit, report, credit report, information, 15, consumer, accounts credit, reporting, fcra 605b.

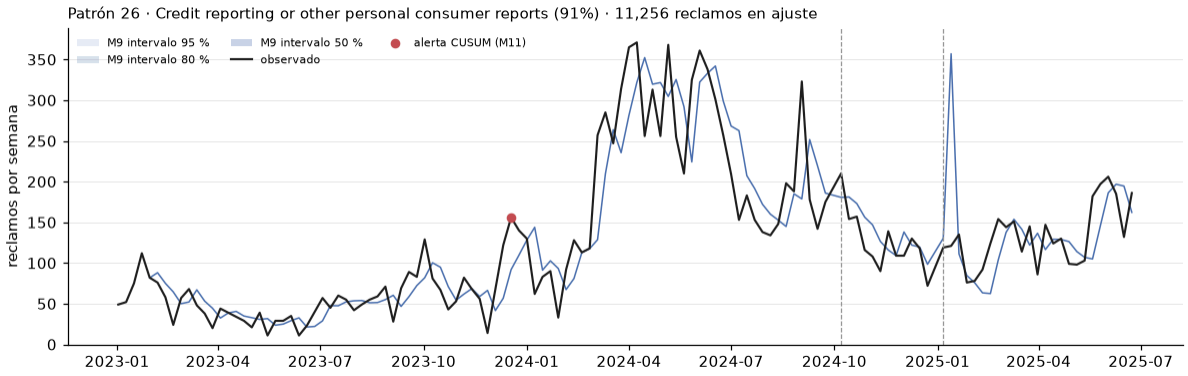


Figura 43: Serie semanal del patrón 26

Patrón 27

Producto principal: Credit reporting or other personal consumer reports (99 % de sus reclamos). **Reclamos en ajuste:** 8,018 (87.8 por semana, 0.71 % del total). **Texto único:** 13 %. **Alertas de M11:** ajuste: 2023-02-06.

Términos: redacted redacted, redacted, report, credit report, inquiry credit, fraud inquiry, remove fraud, theft remove, theft, information.

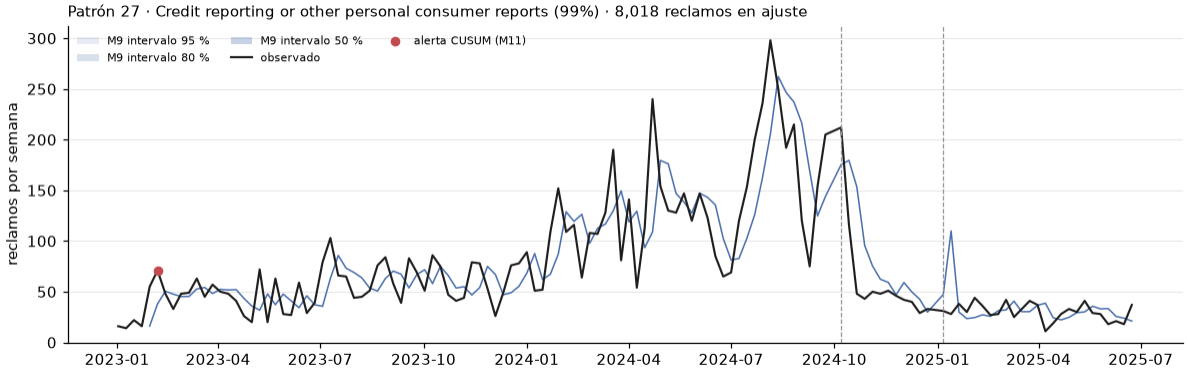


Figura 44: Serie semanal del patrón 27

Patrón 28

Producto principal: Credit reporting or other personal consumer reports (80 % de sus reclamos). **Reclamos en ajuste:** 6,960 (76.1 por semana, 0.55 % del total). **Texto único:** 10 %. **Alertas de M11:** ajuste: 2024-04-15.

Términos: accounts, report, debt, credit, 15, code, credit report, consumer, 15 code, inaccurate.

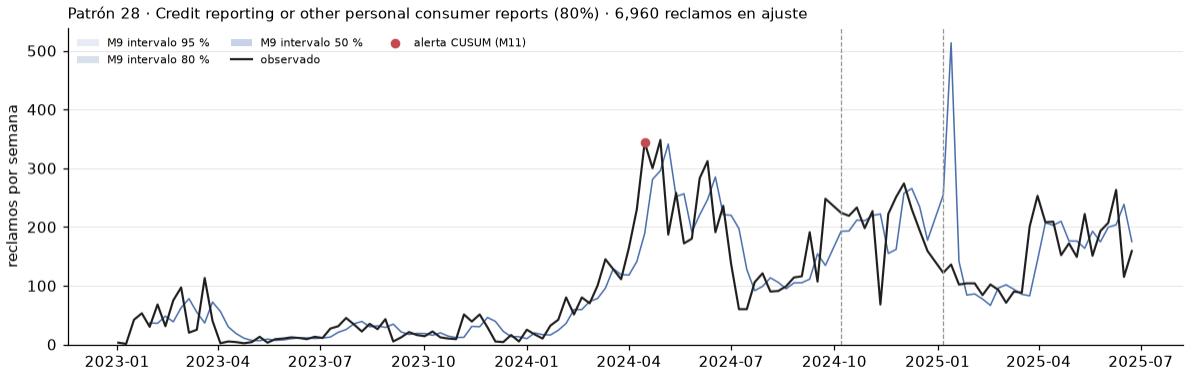


Figura 45: Serie semanal del patrón 28

Patrón 29

Producto principal: Credit reporting or other personal consumer reports (98 % de sus reclamos). **Reclamos en ajuste:** 9,166 (100.0 por semana, 0.77 % del total). **Texto único:** 19 %. **Alertas de M11:** ajuste: 2023-07-31; calibración: 2024-12-09; validación: 2025-02-24.

Términos: identity, theft, identity theft, redacted redacted, redacted, items, federal, federal trade, trade, report.

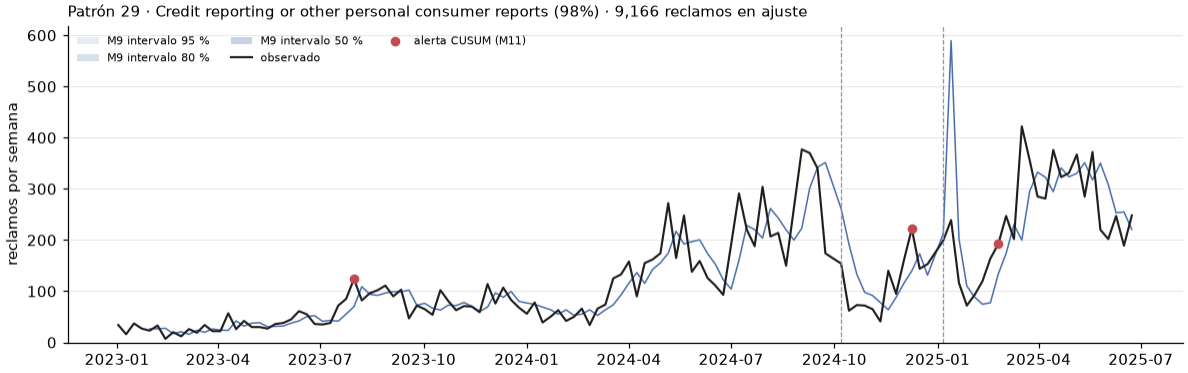


Figura 46: Serie semanal del patrón 29

Patrón 30

Producto principal: Credit reporting or other personal consumer reports (87 % de sus reclamos). **Reclamos en ajuste:** 21,597 (236.3 por semana, 1.76 % del total). **Texto único:** 32 %. **Alertas de M11:** ajuste: 2023-05-29, 2024-01-22, 2024-06-17; validación: 2025-02-24.

Términos: payment, late, payments, creditor, mailed delivered, periodic, delivered, periodic statement, 1637, 21 days.

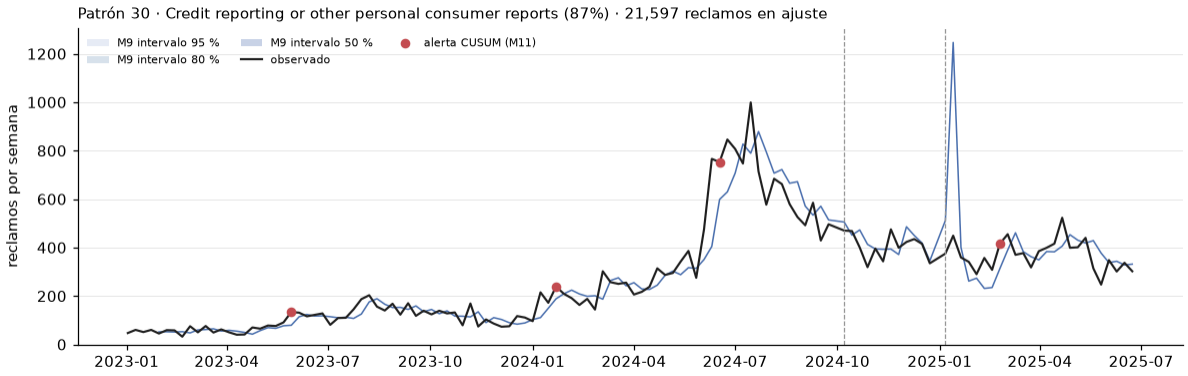


Figura 47: Serie semanal del patrón 30

Patrón 31

Producto principal: Credit reporting or other personal consumer reports (78 % de sus reclamos). **Reclamos en ajuste:** 8,060 (88.0 por semana, 0.59 % del total). **Texto único:** 3 %. **Alertas de M11:** ajuste: 2023-03-27, 2024-03-04.

Términos: need reporting, reporting correction, correction company, identified inaccurate, inaccurate accounts, reviewing credit, report identified, accounts need, reviewing, identified.

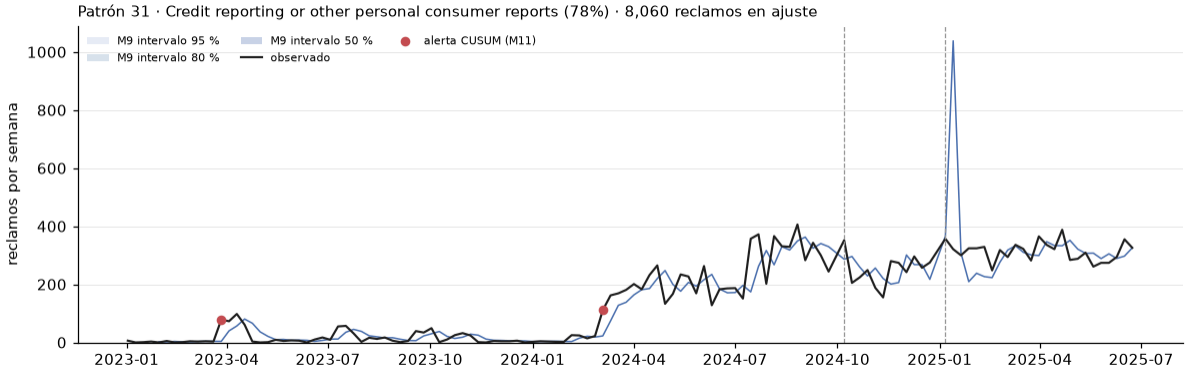


Figura 48: Serie semanal del patrón 31

Patrón 32

Producto principal: Credit reporting or other personal consumer reports (95 % de sus reclamos). **Reclamos en ajuste:** 9,040 (99.2 por semana, 0.75 % del total). **Texto único:** 16 %. **Alertas de M11:** ajuste: 2023-06-05, 2024-03-18; calibración: 2024-12-23; validación: 2025-06-23.

Términos: redacted redacted, redacted, credit, late payment, section, consumer, 15, verify, information, 1681.

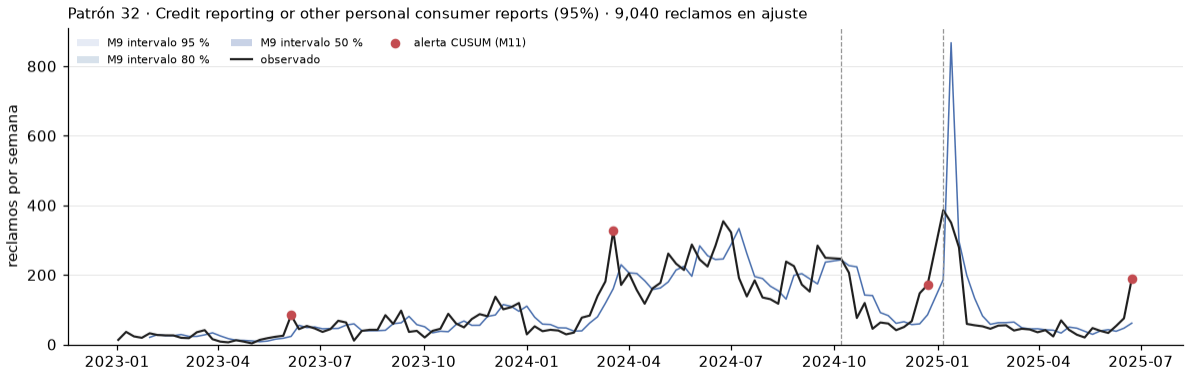


Figura 49: Serie semanal del patrón 32

Patrón 33

Producto principal: Credit reporting or other personal consumer reports (88 % de sus reclamos). **Reclamos en ajuste:** 7,051 (77.4 por semana, 0.63 % del total). **Texto único:** 2 %. **Alertas de M11:** ajuste: 2023-06-05, 2024-03-11.

Términos: payments, updated records, consistently maintained, precise updated, seeking precise, reflect timely, perplexing discover, maintained time, records accurately, payments perplexing.

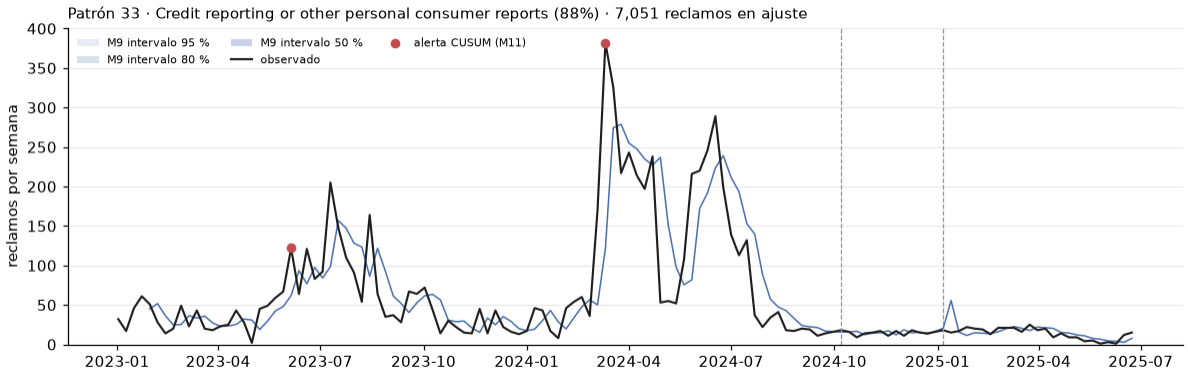


Figura 50: Serie semanal del patrón 33

Patrón 34

Producto principal: Credit reporting or other personal consumer reports (99 % de sus reclamos). **Reclamos en ajuste:** 6,530 (71.5 por semana, 0.63 % del total). **Texto único:** 0 %. **Alertas de M11:** validación: 2025-06-16.

Términos: letters, bureaus continuously, happened mailed, really sure, far gotten, continuously far, sure happened, involved review, gotten response, mailed letters.

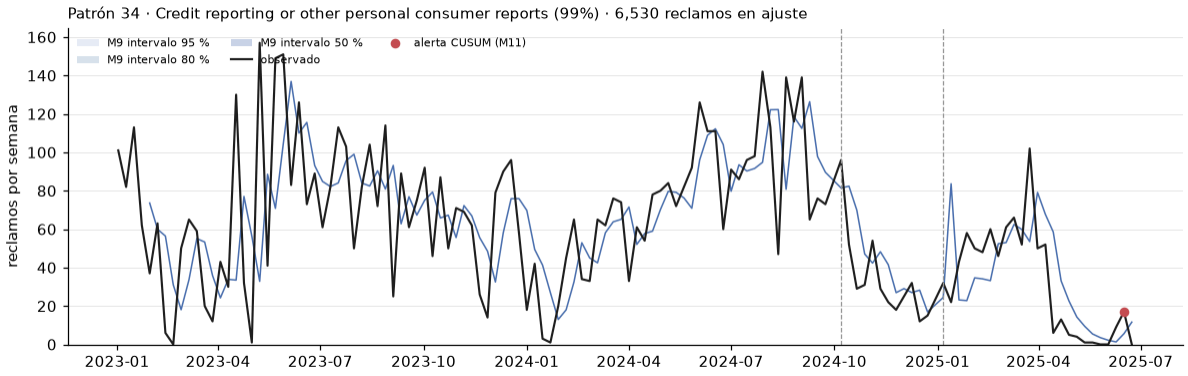


Figura 51: Serie semanal del patrón 34

Patrón 35

Producto principal: Credit reporting or other personal consumer reports (100 % de sus reclamos). **Reclamos en ajuste:** 2,888 (31.7 por semana, 0.26 % del total). **Texto único:** 0 %. **Alertas de M11:** ajuste: 2023-02-13, 2023-06-26, 2023-07-31.

Términos: dispute incorrect, invalid items, referenced issues, incorrect invalid, letter referenced, assistance creditors, gotten assistance, report gotten, documents letter, matter attached.

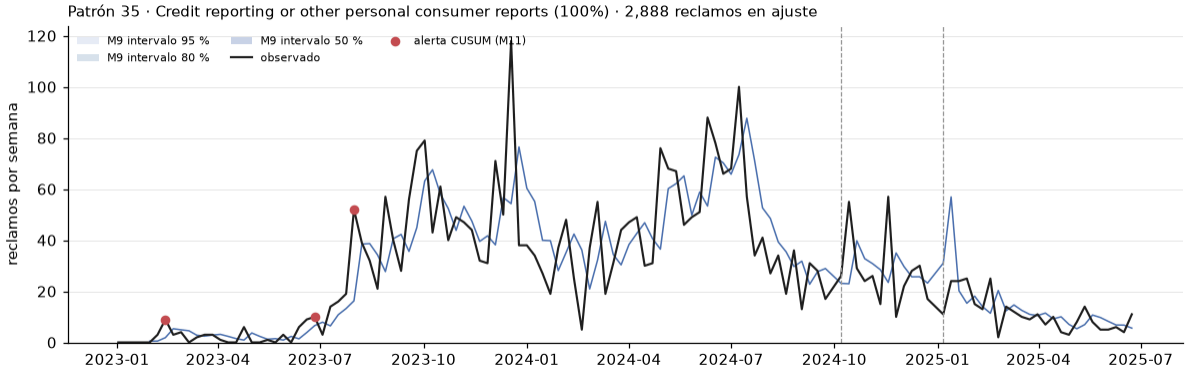


Figura 52: Serie semanal del patrón 35

Patrón 36

Producto principal: Credit reporting or other personal consumer reports (96 % de sus reclamos). **Reclamos en ajuste:** 53,587 (587.1 por semana, 5.02 % del total). **Texto único:** 73 %. **Alertas de M11:** ajuste: 2023-12-18; validación: 2025-02-03.

Términos: consumer, information, redacted, reporting, 15, redacted redacted, usc, 15 usc, consumer reporting, account.

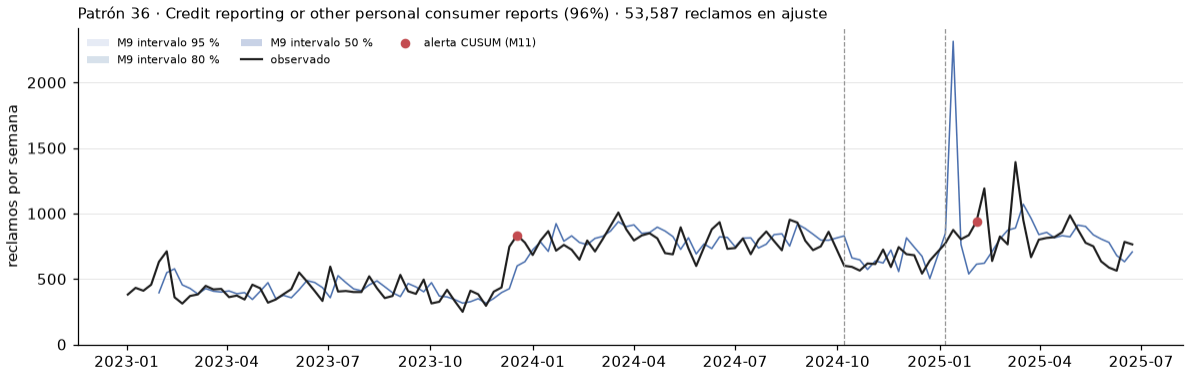


Figura 53: Serie semanal del patrón 36

Patrón 37

Producto principal: Credit reporting or other personal consumer reports (85 % de sus reclamos). **Reclamos en ajuste:** 6,255 (68.6 por semana, 0.48 % del total). **Texto único:** 5 %. **Alertas de M11:** ajuste: 2024-01-08; validación: 2025-01-06.

Términos: letters, reporting, inaccurate date, date, written, 15, credit, report, section, 1681.

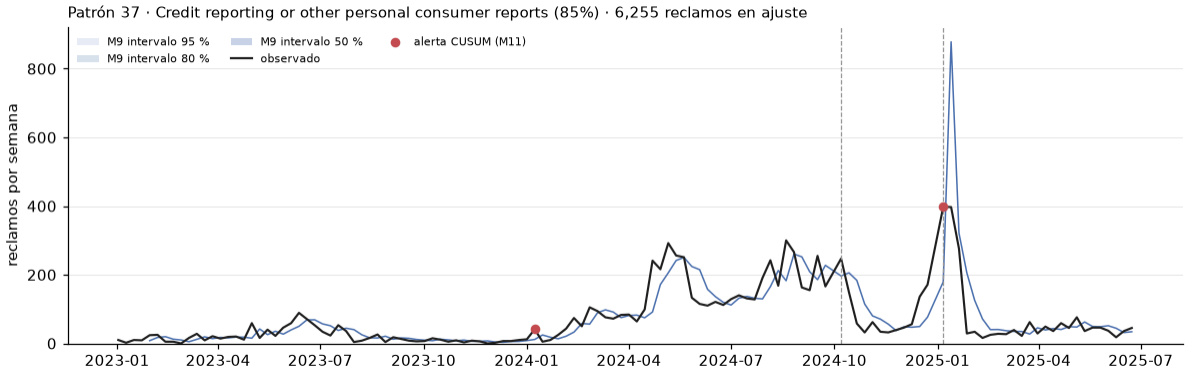


Figura 54: Serie semanal del patrón 37

Patrón 38

Producto principal: Credit reporting or other personal consumer reports (97 % de sus reclamos). **Reclamos en ajuste:** 6,321 (69.2 por semana, 0.51 % del total). **Texto único:** 8 %. **Alertas de M11:** sin alertas de M11.

Términos: payment, late, complaint, error, creditor, complaint bureaus, payment late, days payment, mailed delivered, payment date.

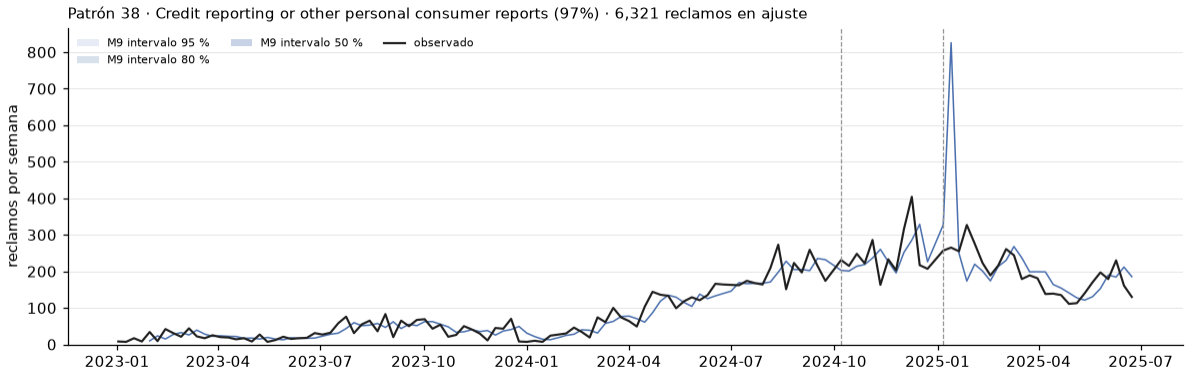


Figura 55: Serie semanal del patrón 38

Patrón 39

Producto principal: Credit reporting or other personal consumer reports (95 % de sus reclamos). **Reclamos en ajuste:** 8,485 (92.9 por semana, 0.72 % del total). **Texto único:** 12 %. **Alertas de M11:** ajuste: 2023-07-03, 2024-04-29.

Términos: section, consumer, 15, information, 1681, states, reporting agency, consumer reporting, agency, reporting.

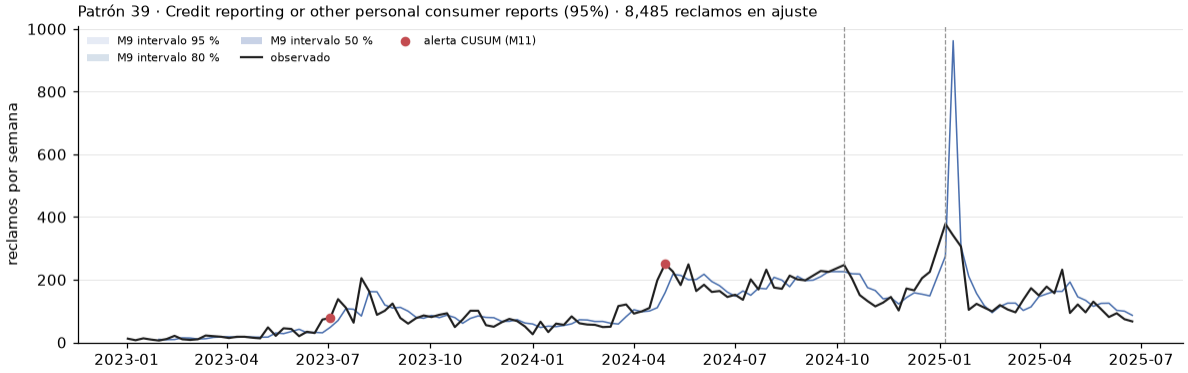


Figura 56: Serie semanal del patrón 39

Anexo B. Tabla completa de candidatos

Reproducción de `etapa_4_5_modelado_evaluacion/resultados/comparacion_modelos.csv`: cada candidato con su métrica principal, su referencia, la ganancia relativa con el intervalo del bootstrap y la decisión. Las filas sin decisión son referencias o cifras informativas.

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
M3	T1	baseline_global_frequency	baseline	calibracion 2024q4	macro_f1	0.006	—	—	—
M5B	T1	product_nb	baseline	calibracion	macro_f1	0.076	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
				2024 q4					
M5B	T1	tfidf_product	candidato	calibracion 2024 q4	macro_f1	0.214	+52.4 %	[+0.071, +0.078]	reemplaza
M5B	T1	bge_product_n5_sample	candidato	calibracion 2024 q4	macro_f1	0.240	—	—	—
M5B	T1	tfidf_text	candidato	calibracion 2024 q4	macro_f1	0.141	+84.6 %	[+0.061, +0.069]	reemplaza
M5B	T1	bge_text	candidato	calibracion 2024 q4	macro_f1	0.158	−26.2 %	[−0.061, −0.053]	—
M5B	T1	bge_product	ganador M5B	calibracion 2024 q4	macro_f1	0.240	+11.9 %	[+0.023, +0.029]	reemplaza
M3	T2	baseline_global_frequency	baseline	calibracion 2024 q4	average_precision	0.391	—	—	—
M5B	T2	product_rules	baseline	calibracion 2024 q4	average_precision	0.454	—	—	—
M5B	T2	tfidf_product	candidato	calibracion	average_precision	0.612	+0.4 %	[+0.002, +0.003]	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
				2024 q4					
M5B	T2	tfidf_text	ganador M5B	calibracion 2024 q4	average_precision	0.609	+34.4 %	[+0.148, +0.164]	reemplaza
M5B	T2	bge_text	candidato	calibracion 2024 q4	average_precision	0.606	−0.6 %	[−0.008, +0.001]	—
M5B	T2	bge_product	candidato	calibracion 2024 q4	average_precision	0.610	+0.2 %	[−0.003, +0.006]	—
M3	T3	baseline	baseline_global_frequency	calibracion 2024 q4	average_precision	0.022	—	—	—
M5B	T3	product_rules	baseline	calibracion 2024 q4	average_precision	0.134	—	—	—
M5B	T3	tfidf_product	candidato	calibracion 2024 q4	average_precision	0.370	+1.6 %	[+0.001, +0.012]	—
M5B	T3	tfidf_text	ganador M5B	calibracion 2024 q4	average_precision	0.364	+109.3 %	[+0.177, +0.203]	reemplaza
M5B	T3	bge_text	candidato	calibracion	average_precision	0.335	−8.0 %	[−0.039, −0.017]	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
				2024q4					
M5B	T3	bge_product	candidato	calibracion 2024q4	average_precision	0.351	−3.5 %	[−0.025, +0.002]	—
M3	T4	baseline_global_frequency	baseline	calibracion 2024q4	average_precision	0.036	—	—	—
M5B	T4	product_rules	baseline	calibracion 2024q4	average_precision	0.031	—	—	—
M5B	T4	tfidf_product	ganador M5B	calibracion 2024q4	average_precision	0.055	+16.8 %	[+0.003, +0.015]	reemplaza
M5B	T4	tfidf_text	candidato	calibracion 2024q4	average_precision	0.047	+50.7 %	[+0.004, +0.025]	reemplaza
M5B	T4	bge_text	candidato	calibracion 2024q4	average_precision	0.031	−44.5 %	[−0.031, −0.019]	—
M5B	T4	bge_product	candidato	calibracion 2024q4	average_precision	0.042	−24.3 %	[−0.019, −0.008]	—
M5F bloque B	T1	bge_product	ganador M5B (refe-	calibracion	macro_f1	0.240	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
			rencia)	2024 q4					
M5F bloque B	T1	TabPFN-3.5 (PCA 100 + producto)	ganador bloque B	calibracion 2024 q4	macro_f1	0.271	+12.9 %	[+0.027, +0.035]	reemplaza
M5F bloque B	T1	bge_product	ganador M5B (referencia)	validacion 2025 h1 (ya consultada)	macro_f1	0.227	—	—	—
M5F bloque B	T1	TabPFN-3.5 (PCA 100 + producto)	candidato	validacion 2025 h1 (ya consultada)	macro_f1	0.270	+19.0 %	[+0.039, +0.046]	—
M5F ablación §26	T1	TabPFN-3.5 (PCA 100 + producto)	referencia (bloque B)	calibracion 2024 q4	macro_f1	0.271	—	—	—
M5F ablación §26	T1	TabPFN-3.5 (PCA 256 + producto)	candidato	calibracion 2024 q4	macro_f1	0.268	−1.0 %	[−0.006, +0.001]	no reemplaza
M5F ablación §26	T1	TabPFN-3.5 (BGE 1,024 + producto)	candidato	calibracion 2024 q4	macro_f1	0.192	−29.0 %	[−0.085, −0.073]	no reemplaza
M5B §22	T1	product_text	baseline	validacion 2025 h1 (ya con-	macro_f1	0.068	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
				sultada)					
M5B §22	T1	bge_product	ganador M5B	validacion 2025 h1 (ya consultada)	macro_f1	0.227	—	[+0.156, +0.163]	confirmado
M5B §22	T2	product_rules	baseline	validacion 2025 h1 (ya consultada)	average_precision	0.451	—	—	—
M5B §22	T2	tfidf_text	ganador M5B	validacion 2025 h1 (ya consultada)	average_precision	0.570	—	[+0.104, +0.138]	confirmado
M5B §22	T3	product_rules	baseline	validacion 2025 h1 (ya consultada)	average_precision	0.127	—	—	—
M5B §22	T3	tfidf_text	ganador M5B	validacion 2025 h1 (ya consultada)	average_precision	0.270	—	[+0.116, +0.175]	confirmado
M5B §22	T4	product_rules	baseline	validacion 2025 h1 (ya con-	average_precision	0.121	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
				sulta-da)					
M5B §22	T4	tfidf_prod	ganador M5B	validacion 2025 h1 (ya consulta-da)	average_precision	0.078	—	[−0.073, −0.018]	no confirmado
M9	conteo semanal por patrón	b1_rolling_13	baseline	calibracion 2024 q4	wis	64.883	—	—	—
M9	conteo semanal por patrón	b1_rolling_4	baseline	calibracion 2024 q4	wis	43.056	—	—	—
M9	conteo semanal por patrón	baseline	baseline	calibracion 2024 q4	wis	138.950	—	—	—
M9	conteo semanal por patrón	Binomial negativa jerárquica con memoria que decae (C-A)	candidato	calibracion 2024 q4	wis	30.296	+29.6 %	[−15.993, −9.503]	accepted
M9	conteo semanal por patrón	b1_rolling_13	baseline	calibracion 2024 q4	wis	64.883	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
M9	conteo semanal por patrón	b1_rolling_4	baseline	calibracion 2024 q4	wis	43.056	—	—	—
M9	conteo semanal por patrón	baseline	baseline	calibracion 2024 q4	wis	138.950	—	—	—
M9	conteo semanal por patrón	Binomial negativa, participaciones de 4 semanas, global	candidato	calibracion 2024 q4	wis	47.719	−10.8 %	[−0.093, +9.445]	rejected_no_practical_
M9	conteo semanal por patrón	b1_rolling_13	baseline	calibracion 2024 q4	wis	64.883	—	—	—
M9	conteo semanal por patrón	b1_rolling_4	baseline	calibracion 2024 q4	wis	43.056	—	—	—
M9	conteo semanal por patrón	baseline	baseline	calibracion 2024 q4	wis	138.950	—	—	—
M9	conteo semanal por patrón	Binomial negativa, 4 semanas,	candidato	calibracion 2024 q4	wis	32.418	+24.7 %	[−13.649, −7.624]	accepted

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
		jerárquica v3							
M9 §25.5	conteo semanal por patrón	Chronos-2 zero-shot	candidato	calibracion 2024 q4	wis	36.017	−11.1 %	[−0.995, +9.032]	no reemplaza
M9 §25.5	conteo semanal por patrón	Binomial negativa jerárquica con memoria que decae (C-A)	candidato	calibracion 2024 q4	wis	30.296	+6.5 %	[−3.361, −0.845]	reemplaza
M9 §25.5	conteo semanal por patrón	Binomial negativa jerárquica con memoria que decae (C-A)	candidato	validacion 2025 h1 (ya consultada)	wis	129.609	+3.0 %	[−21.066, +15.051]	—
M9 §25.5	conteo semanal por patrón	Espacio de estados, paseo aleatorio (C-B)	candidato	calibracion 2024 q4	wis	31.951	+1.4 %	[−2.580, +1.570]	no reemplaza
M9 §25.5	conteo semanal por patrón	TimesFM 3.0 zero-shot	candidato	calibracion	wis	40.702	+1.6 %	[−4.774, +3.550]	no reemplaza

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
				2024 q4					
M9 §22	conteo semanal por patrón	Binomial negativa, 4 semanas, jerárquica v3	ganador M9	validacion 2025 h1 (ya consultada)	wis	133.632	—	[−49.943, −17.068]	confirmado
M9 §22	conteo semanal por patrón	b1_rolling_4	baseline	validacion 2025 h1 (ya consultada)	wis	164.225	—	—	—
M10	composición semanal	b2_rolling_4	baseline	calibracion 2024 q4	log_score	−460.931	—	—	—
M10	composición semanal	b2_static	baseline	calibracion 2024 q4	log_score	−1,770.235	—	—	—
M10	composición semanal	dirichlet_multinomial_rolling_4_v2	candidato	calibracion 2024 q4	log_score	−210.144	—	[+205.134, +295.845]	aceptado
M10	composición semanal	b2_rolling_4	baseline	calibracion 2024 q4	log_score	−460.931	—	—	—
M10	composición	b2_static	baseline	calibracion	log_score	−1,770.235	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
	semanal			2024 q4					
M10	composición semanal	dirichlet_multinomial_static_v1	candidato	calibracion 2024 q4	log_score	−246.038	—	[+166.609, +263.190]	rejected_predictive
M10 §22	composición semanal	dirichlet_multinomial_rolling_v1	guardián M10	validacion 2025 h1 (ya consultada)	log_score	−251.688	—	—	confirmado
M10 §22	composición semanal	b2_rolling_4	baseline	validacion 2025 h1 (ya consultada)	log_score	−3,387.898	—	—	—
M9D	composición diaria	dm_static	baseline	calibracion 2024 q4	log_score	−424.804	—	—	—
M9D	composición diaria	mn_rolling_7	baseline	calibracion 2024 q4	log_score	−229.647	—	—	—
M9D	composición diaria	D-E: Dirichlet-multinomial diaria	candidato	calibracion 2024 q4	log_score	−151.614	—	[+69.082, +87.043]	accepted
M9D	conteo diario	b1_rolling_7	baseline	calibracion	wis	9.263	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
				2024 q4					
M9D	conteo diario	baseline	baseline	calibracion 2024 q4	wis	19.617	—	—	—
M9D	conteo diario	D-C: binomial negativa diaria, Fourier y tendencia	candidato	calibracion 2024 q4	wis	7.173	+22.6 %	[−2.505, −1.673]	accepted
M9D	conteo diario	b1_rolling_7	baseline	calibracion 2024 q4	wis	9.263	—	—	—
M9D	conteo diario	baseline	baseline	calibracion 2024 q4	wis	19.617	—	—	—
M9D	conteo diario	D-A: binomial negativa diaria con día de semana	candidato	calibracion 2024 q4	wis	6.959	+24.9 %	[−2.689, −1.919]	accepted
M9D	conteo diario	b1_rolling_7	baseline	calibracion 2024 q4	wis	9.263	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
M9D	conteo diario	baseline	baseline	calibracion 2024 q4	wis	19.617	—	—	—
M9D	conteo diario	D-B2: binomial negativa diaria sin día de semana	candidato	calibracion 2024 q4	wis	7.696	+16.9 %	[−1.870, −1.245]	accepted
M9D	conteo diario	b1_rolling_7	baseline	calibracion 2024 q4	wis	9.263	—	—	—
M9D	conteo diario	baseline	baseline	calibracion 2024 q4	wis	19.617	—	—	—
M9D	conteo diario	D-D: binomial negativa diaria, inflación de ceros	candidato	calibracion 2024 q4	wis	6.946	+25.0 %	[−2.702, −1.936]	accepted
M9D §28.2	conteo diario	D-D: binomial negativa diaria, inflación	ganador M9D	calibracion 2024 q4	wis	6.946	+25.0 %	[−2.702, −1.936]	elegido

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
		de ceros							
M9D §28.2	conteo diario	D-D: binomial negativa diaria, inflación de ceros	ganador M9D	validacion 2025 h1 (ya consultada)	wis	14.556	+24.6 %	[−6.745, −3.057]	—
M11D	alertas diarias, escenario burst_x2_3d	cusum	candidato	calibracion simulada	tasa_de_deteccion	0.282	—	—	no adoptada
M11D	alertas diarias, escenario burst_x2_3d	daily	candidato	calibracion simulada	tasa_de_deteccion	0.352	—	—	no adoptada
M11D	alertas diarias, escenario burst_x2_3d	weekly_cusum	referencia M11	calibracion simulada	tasa_de_deteccion	0.304	—	—	—
M11D	alertas diarias, escenario burst_x3_1d	cusum	candidato	calibracion simulada	tasa_de_deteccion	0.248	—	—	no adoptada
M11D	alertas diarias, escenario burst_x3_1d	daily	candidato	calibracion simulada	tasa_de_deteccion	0.442	—	—	no adoptada
M11D	alertas diarias,	weekly_cusum	referencia M11	calibracion	tasa_de_deteccion	0.291	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
	escenario	burst_x3_1d		simulada					
M11D	alertas diarias, escenario	cusum rise_x1_5_7d	candidato	calibracion simulada	tasa_de_deteccion	0.1240	—	—	no adoptada
M11D	alertas diarias, escenario	daily rise_x1_5_7d	candidato	calibracion simulada	tasa_de_deteccion	0.1267	—	—	no adoptada
M11D	alertas diarias, escenario	weekly_cusum rise_x1_5_7d	referencia M11	calibracion simulada	tasa_de_deteccion	0.1307	—	—	—
M11D	alertas diarias, escenario	cusum none	candidato	calibracion simulada	tasa_de_deteccion	0.1065	—	—	no adoptada
M11D	alertas diarias, escenario	daily none	candidato	calibracion simulada	tasa_de_deteccion	0.1406	—	—	no adoptada
M11D	alertas diarias, escenario	weekly_cusum none	referencia M11	calibracion simulada	tasa_de_deteccion	0.1000	—	—	—
M11D	alertas diarias reales	cusum	candidato	ajuste	alertas_por_mes	3.091	—	—	no adoptada
M11D	alertas diarias reales	daily	candidato	ajuste	alertas_por_mes	18.244	—	—	no adoptada

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
M11D	alertas diarias reales	cusum	candidato	calibracion 2024 q4	alertas_por_mes	8.271	—	—	no adoptada
M11D	alertas diarias reales	daily	candidato	calibracion 2024 q4	alertas_por_mes	12.903	—	—	no adoptada
M11D-V2	alertas diarias, escenario	daily burst_x2_3d	candidato	calibracion simulada	tasa_de_deteccion	0.206	—	—	no adoptada
M11D-V2	alertas diarias, escenario	scan burst_x2_3d	candidato	calibracion simulada	tasa_de_deteccion	0.241	—	—	no adoptada
M11D-V2	alertas diarias, escenario	cusum burst_x2_3d	candidato	calibracion simulada	tasa_de_deteccion	0.216	—	—	no adoptada
M11D-V2	alertas diarias, escenario	weekly_cusum burst_x2_3d	referencia M11	calibracion simulada	tasa_de_deteccion	0.204	—	—	—
M11D-V2	alertas diarias, escenario	daily burst_x3_1d	candidato	calibracion simulada	tasa_de_deteccion	0.287	—	—	no adoptada
M11D-V2	alertas diarias, escenario	scan burst_x3_1d	candidato	calibracion simulada	tasa_de_deteccion	0.400	—	—	no adoptada

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
M11D-V2	alertas diarias, escenario burst_x3_1d	cusum	candidato	calibracion simulada	tasa_de_deteccion	0.1020	—	—	no adoptada
M11D-V2	alertas diarias, escenario burst_x3_1d	weekly_cusum_referencia_M11	candidato	calibracion simulada	tasa_de_deteccion	0.1291	—	—	—
M11D-V2	alertas diarias, escenario rise_x1_5_7d	daily	candidato	calibracion simulada	tasa_de_deteccion	0.1402	—	—	—
M11D-V2	alertas diarias, escenario rise_x1_5_7d	scan	candidato	calibracion simulada	tasa_de_deteccion	0.1466	—	—	—
M11D-V2	alertas diarias, escenario rise_x1_5_7d	cusum	candidato	calibracion simulada	tasa_de_deteccion	0.1486	—	—	—
M11D-V2	alertas diarias, escenario rise_x1_5_7d	weekly_cusum_referencia_M11	candidato	calibracion simulada	tasa_de_deteccion	0.1907	—	—	—
M11D-V2	alertas diarias, escenario burst_x3_3d	daily	candidato	calibracion simulada	tasa_de_deteccion	0.2446	—	—	—
M11D-V2	alertas diarias, escenario burst_x3_3d	scan	candidato	calibracion simulada	tasa_de_deteccion	0.2883	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
M11D-V2	alertas diarias, escenario burst_x3_3d	cusum	candidato	calibracion simulada	tasa_de_deteccion	0.352	—	—	—
M11D-V2	alertas diarias, escenario burst_x3_3d	weekly_cusum_referencia_M11	candidato	calibracion simulada	tasa_de_deteccion	0.369	—	—	—
M11D-V2	alertas diarias, escenario none	daily	candidato	calibracion simulada	tasa_de_deteccion	0.033	—	—	—
M11D-V2	alertas diarias, escenario none	scan	candidato	calibracion simulada	tasa_de_deteccion	0.025	—	—	—
M11D-V2	alertas diarias, escenario none	cusum	candidato	calibracion simulada	tasa_de_deteccion	0.026	—	—	—
M11D-V2	alertas diarias, escenario none	weekly_cusum_referencia_M11	candidato	calibracion simulada	tasa_de_deteccion	0.000	—	—	—
M11D-V2	alertas diarias reales	daily	candidato	ajuste	alertas_por_mes	4.045	—	—	—
M11D-V2	alertas diarias reales	scan	candidato	ajuste	alertas_por_mes	3.997	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
M11D-V2	alertas diarias reales	cusum	candidato	ajuste	alertas_por_mes	3.997	—	—	—
M11D-V2	alertas diarias reales	daily	candidato	calibracion 2024 q4	alertas_por_mes	3.970	—	—	—
M11D-V2	alertas diarias reales	scan	candidato	calibracion 2024 q4	alertas_por_mes	2.978	—	—	—
M11D-V2	alertas diarias reales	cusum	candidato	calibracion 2024 q4	alertas_por_mes	3.970	—	—	—
M11	alertas, escenario	cusum	ganador M11	calibracion simulada	tasa_de_deteccion	0.4263	—	—	elegido
M11	alertas, escenario	weekly	candidato	calibracion simulada	tasa_de_deteccion	0.3220	—	—	—
M11	alertas, escenario	cusum	ganador M11	calibracion simulada	tasa_de_deteccion	0.7009	—	—	elegido
M11	alertas, escenario	weekly	candidato	calibracion simulada	tasa_de_deteccion	0.5460	—	—	—
M11	alertas,	cusum	ganador M11	calibracion	tasa_de_deteccion	0.3416	—	—	elegido

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
	escenario	step_50		simulada					
M11	alertas, escenario	weekly step_50	candidato	calibracion simulada	tasa_de_deteccion	0.361	—	—	—
M11	alertas, escenario	cusum step_100	ganador M11	calibracion simulada	tasa_de_deteccion	0.516	—	—	elegido
M11	alertas, escenario	weekly step_100	candidato	calibracion simulada	tasa_de_deteccion	0.560	—	—	—
M11	alertas, escenario	cusum none	ganador M11	calibracion simulada	tasa_de_deteccion	0.965	—	—	elegido
M11	alertas, escenario	weekly none	candidato	calibracion simulada	tasa_de_deteccion	0.405	—	—	—
M11	alertas reales	cusum	ganador M11	calibracion 2024 q4	alertas_por_mes	1.449	—	—	—
M11	alertas reales	weekly	candidato	calibracion 2024 q4	alertas_por_mes	1.087	—	—	—
M11	alertas reales	cusum	ganador M11	validacion 2025 h1 (ya	alertas_por_mes	5.218	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
				consultada)					
M11	alertas reales	weekly	candidato	validacion 2025 h1 (ya consultada)	alertas_por_mes	5.566	—	—	—
C-M11-FARR	alertas, escenario growth	memoria ponderada, z0 = 2.58	candidato	calibracion simulada	tasa_de_detección	0.1220	—	—	—
C-M11-FARR	alertas, escenario growth	memoria ponderada, z0 = 2.58	candidato	calibracion simulada	tasa_de_detección	0.1560	—	—	—
C-M11-FARR	alertas, escenario stepdeg	memoria ponderada, z0 = 2.58	candidato	calibracion simulada	tasa_de_detección	0.1220	—	—	—
C-M11-FARR	alertas, escenario stepdeg	memoria ponderada, z0 = 2.58	candidato	calibracion simulada	tasa_de_detección	0.1436	—	—	—
C-M11-FARR	alertas, escenario none	memoria ponderada, z0 = 2.58	candidato	calibracion simulada	tasa_de_detección	0.1067	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
C-M11-FARR	alertas reales	memoria ponderada, z0 = 2.58	candidato	ajuste	alertas_por_mes	6.197	—	—	—
C-M11-FARR	alertas reales	memoria ponderada, z0 = 2.58	candidato	calibracion 2024 q4	alertas_por_mes	4.348	—	—	—
C-M11-FARR	expectativa semanal (secundaria)	memoria ponderada, z0 = 2.58	candidato	calibracion 2024 q4	wis_plug_56	16.739	—	—	—
C-M11-FARR	alertas, escenario growth_10	memoria ponderada, z0 = 2.0	sensibilidad	calibracion simulada	tasa_de_detección	0.250	—	—	—
C-M11-FARR	alertas, escenario growth_20	memoria ponderada, z0 = 2.0	sensibilidad	calibracion simulada	tasa_de_detección	0.557	—	—	—
C-M11-FARR	alertas, escenario step_50	memoria ponderada, z0 = 2.0	sensibilidad	calibracion simulada	tasa_de_detección	0.276	—	—	—
C-M11-FARR	alertas, escenario step_100	memoria ponderada, z0 = 2.0	sensibilidad	calibracion simulada	tasa_de_detección	0.495	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
		da, z0 = 2.0							
C-M11-FARR	alertas, escenario none	memoria ponderada, z0 = 2.0	sensibilidad	calibracion simulada	tasa_de_detección	0.1406	—	—	—
C-M11-FARR	alertas reales	memoria ponderada, z0 = 2.0	sensibilidad	ajuste	alertas_por_mes	11.795	—	—	—
C-M11-FARR	alertas reales	memoria ponderada, z0 = 2.0	sensibilidad	calibracion 2024 q4	alertas_por_mes	12.320	—	—	—
C-M11-FARR	expectativa semanal (secundaria)	memoria ponderada, z0 = 2.0	sensibilidad	calibracion 2024 q4	wis_plug_in	66.845	—	—	—
C-M11-FARR	alertas, escenario growth_10	memoria ponderada, z0 = 3.0	sensibilidad	calibracion simulada	tasa_de_detección	0.1250	—	—	—
C-M11-FARR	alertas, escenario growth_20	memoria ponderada, z0 = 3.0	sensibilidad	calibracion simulada	tasa_de_detección	0.1582	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
C-M11-FARR	alertas, escenario step_50	memoria ponderada, z0 = 3.0	sensibilidad	calibracion simulada	tasa_de_detencion	0.1216	—	—	—
C-M11-FARR	alertas, escenario step_100	memoria ponderada, z0 = 3.0	sensibilidad	calibracion simulada	tasa_de_detencion	0.1426	—	—	—
C-M11-FARR	alertas, escenario none	memoria ponderada, z0 = 3.0	sensibilidad	calibracion simulada	tasa_de_detencion	0.1063	—	—	—
C-M11-FARR	alertas reales	memoria ponderada, z0 = 3.0	sensibilidad	ajuste	alertas_por_mes	5.848	—	—	—
C-M11-FARR	alertas reales	memoria ponderada, z0 = 3.0	sensibilidad	calibracion 2024 q4	alertas_por_mes	4.348	—	—	—
C-M11-FARR	expectativa semanal (secundaria)	memoria ponderada, z0 = 3.0	sensibilidad	calibracion 2024 q4	wis_plug_in	51.818	—	—	—
C-M11-FARR	alertas, escenario growth_110	CUSUM de M11 sobre	referencia M11	calibracion simulada	tasa_de_detencion	0.1426	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
		C-A (referencia)							
C-M11-FARR	alertas, escenario growth	CUSUM de M11 sobre C-A (referencia)	referencia M11	calibracion simulada	tasa_de_detección	0.7000	—	—	—
C-M11-FARR	alertas, escenario step_50	CUSUM de M11 sobre C-A (referencia)	referencia M11	calibracion simulada	tasa_de_detección	0.3167	—	—	—
C-M11-FARR	alertas, escenario step_100	CUSUM de M11 sobre C-A (referencia)	referencia M11	calibracion simulada	tasa_de_detección	0.5167	—	—	—
C-M11-FARR	alertas, escenario none	CUSUM de M11 sobre C-A (referencia)	referencia M11	calibracion simulada	tasa_de_detección	0.0667	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
C-M11-FARR	expectativa semanal (secundaria)	C-A (referencia)	referencia M9	calibracion 2024 q4	wis_plug_30	10.328	—	—	—
C-PAT-INC	patron de reclamos nuevos	proyeccion UMAP permutada (referencia)	referencia M8B	calibracion 2024 q4	acuerdo_con_etiquetas_congeladas	0.906	—	—	—
C-PAT-INC	patron de reclamos nuevos	voto de 1 vecinos FAISS	sensibilidad	calibracion 2024 q4	acuerdo_con_etiquetas_congeladas	0.795	—	—	—
C-PAT-INC	patron de reclamos nuevos	voto de 5 vecinos FAISS	candidato	calibracion 2024 q4	acuerdo_con_etiquetas_congeladas	0.832	—	—	no adoptado
C-PAT-INC	patron de reclamos nuevos	voto de 10 vecinos FAISS	sensibilidad	calibracion 2024 q4	acuerdo_con_etiquetas_congeladas	0.843	—	—	—
C-PAT-INC	patron de reclamos nuevos	voto de 20 vecinos FAISS	sensibilidad	calibracion 2024 q4	acuerdo_con_etiquetas_congeladas	0.851	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
C-PAT-INC	patron de reclamos nuevos	proyeccion UMAP permutada (referencia)	referencia M8B	validacion 2025 h1 (ya consultada)	acuerdo_con_etiquetas_congeladas	0.938	—	—	—
C-PAT-INC	patron de reclamos nuevos	voto de 1 vecinos FAISS	sensibilidad	validacion 2025 h1 (ya consultada)	acuerdo_con_etiquetas_congeladas	0.783	—	—	—
C-PAT-INC	patron de reclamos nuevos	voto de 5 vecinos FAISS	candidato	validacion 2025 h1 (ya consultada)	acuerdo_con_etiquetas_congeladas	0.851	—	—	—
C-PAT-INC	patron de reclamos nuevos	voto de 10 vecinos FAISS	sensibilidad	validacion 2025 h1 (ya consultada)	acuerdo_con_etiquetas_congeladas	0.864	—	—	—
C-PAT-INC	patron de reclamos nuevos	voto de 20 vecinos FAISS	sensibilidad	validacion 2025 h1 (ya consultada)	acuerdo_con_etiquetas_congeladas	0.871	—	—	—
M7S bloque A	patrones semánticos	umap15_seed42_kmeans_k40	referencia M7	muestra de ajuste	neighbour_lift	0.837	—	—	—

Etapa	Tarea	Modelo	Rol	Conjunto	Métrica	Valor	Ganancia	IC 95 %	Decisión
M7S bloque A	patrones semánticos	umap5_seed42/kmeans_k40	candidato	muestra de ajuste	neighbour_lift	0.827	−1.7 %	[−0.014, −0.007]	no reemplaza
M7S bloque A	patrones semánticos	umap5_seed42/gmm_k80_full	candidato	muestra de ajuste	neighbour_lift	0.814	−3.7 %	[−0.027, −0.020]	no reemplaza
M7S bloque A	patrones semánticos	umap10_seed42/gmm_k80_full	candidato	muestra de ajuste	neighbour_lift	0.837	−0.0 %	[−0.003, +0.003]	no reemplaza
M7S bloque A	patrones semánticos	umap30_seed42/gmm_k80_full	candidato	muestra de ajuste	neighbour_lift	0.790	−7.5 %	[−0.053, −0.043]	no reemplaza
M7S bloque A	patrones semánticos	umap15_seed42/gmm_k80_full	candidato	muestra de ajuste	neighbour_lift	0.827	−1.7 %	[−0.015, −0.007]	no reemplaza

Anexo C. Reglas pre-registradas

Resumen de las reglas escritas en `docs/registro/models_plan.md` antes de correr cada etapa. El registro completo, con fechas y la evidencia de cada decisión, es un documento de bitácora del repositorio.

Ámbito	Regla	Parámetros
Protocolo	Tres ventanas por fecha; se decide en calibración; validación se abre una vez con todo congelado	ajuste 2023-01-01 a 2025-07-01
Protocolo	La vista sin texto compartido decide; la completa se reporta	42.8 % de filas comparten texto
Reemplazo	Un candidato reemplaza al vigente solo con ≥ 5 % de	2,000 remuestreos, semilla 42

Ámbito	Regla	Parámetros
	mejora relativa y el IC 95 % del bootstrap pareado por semanas entero a su favor	
Orden	Los candidatos compiten del más simple al más complejo	T1–T4: regla → TF-IDF texto → TF-IDF + producto → BGE texto → BGE + producto
Patrones	Criterios de aceptación de la partición fijados antes de correr	ARI ≥ 0.6, cobertura futura ≥ 70 %, grupo mayor ≤ 50 %, ruido ≤ 40 %
Novedad	Reclamo novedoso si su distancia al centro supera el percentil fijado de las distancias de ajuste	percentil 99
Bayesianos	Prior predictive, piloto y full; R-hat ≤ 1.01, sin divergencias; cobertura 80 % en 70–90 % y 95 % en 88–99 %	aplica a M9, M10 y al bloque diario
M9	WIS en calibración contra el mejor baseline Poisson; la misma regla del 5 % con bootstrap	referencia B1-R4, WIS 43.11
M9 bloque C	δ y el recorte de semanas atípicas se eligen solo en ajuste	ganó δ = 0.5 sin recorte
M10	Log score conjunto contra la multinomial de cuatro semanas; p-valor de mezcla rara con umbral fijado	aviso si $p < 0.01$
M11	Presupuesto de falsas alarmas fijado; umbrales por simulación; CUSUM se adopta si detecta ≥ 5 puntos más que la regla semanal en los dos crecimientos	1 al mes; h = 3.37, $z^* = 2.53$
Diario	Prueba aparte; el bloque semanal sigue vigente; si varios candidatos aceptan la regla, gana el de menor WIS	δ = 0.8 elegido en ajuste; ganador D-D, D-A con inflación de ceros
Diario	D-B queda fuera del full si el piloto no converge o el full	R-hat del piloto 1.68

Ámbito	Regla	Parámetros
	proyectado supera 8 h (fijado antes de ver el piloto)	
D-11	Se adopta si detecta ≥ 50 % de las ráfagas ×2/3 días y ×3/1 día con mediana de retraso ≤ 2 días	4 falsas alarmas al mes; no adoptada
Cierre: patrón	El voto de vecinos sustituye a la proyección UMAP solo si acuerda con las etiquetas congeladas al menos tanto como la proyección consigo misma	83.2 % frente a 90.6 %; no adoptado
Cierre: M11	La memoria reponderada se adopta si la detección del CUSUM no baja más de 5 puntos en los crecimientos y las alarmas reales bajan	detección −19 y −15 puntos; no adoptada
Cierre: D-11 v2	Misma regla de D-11 con umbrales empíricos y ventana de 3 días; además las alarmas de calibración no superan 1.5 × el presupuesto	ventana 24 % en ×2/3 días; no adoptada
Validación	Todo lo decidido después del 2026-10-01 reporta 2025-H1 como ya consultado; 2026 queda sellado	sin excepciones

ANEXO D. Mapa de la rúbrica del informe de cierre (P4)

La rúbrica del bloque B del P4 define 21 evidencias observables ubicadas en cinco secciones. Este documento sigue la plantilla de la Escuela de Posgrado, así que la tabla dice dónde está cada evidencia.

Tabla 26: Dónde está cada evidencia de la rúbrica del bloque B dentro de este documento, y qué queda pendiente de los Product Lead.

Evidencia	Qué pide	Dónde está	Pendiente
B1.1	La decisión que hoy sale mal: quién decide, con qué información, frecuencia y costo del error	1.1 y 1.2	Costo del error y frecuencia: PENDIENTE PL (bloque 2 del one-pager)
B1.2	Objetivo de negocio y específicos con métrica, umbral, baseline, KPI, criterio de éxito y plazo	1.3, 1.4 y 1.5	KPI de negocio: PENDIENTE PL
B1.3	Alcance y no-alcance, con lo que se difiere a Capstone II	4.4 y 6.3	—
B1.4	Por qué este proyecto de la cartera	1.1	Criterio de elección: PENDIENTE PL (anexo A del P4)
B1.5	Qué cambió y qué se mantuvo desde el pitch y el informe preliminar	1.1 (último párrafo)	Retroalimentación del pitch: PENDIENTE PL
B2.1	Mapa de stakeholders: dueño, usuario, pagador y afectado	1.2	Poder e interés y participación: PENDIENTE PL
B2.2	Hallazgos de la evidencia primaria con fuente y citas anonimizadas	4.3	Sin entrevistas: evidencia documental declarada
B2.3	Qué cambió en la formulación por la evidencia	1.1 y 5.5.2	—
B2.4	Mapa de alternativas y estado del arte	2.1 y 2.4	—
B2.5	Propuesta de valor del pitch	1.5 y 3.1	User story y one-liner del pitch: PENDIENTE PL
B2.6	Dimensionamiento con cada número etiquetado	2.3 y 6.2	PENDIENTE PL
B3.1	Inventario de datos con acceso y permiso	2.5 (tabla)	—
B3.2	Calidad y fuga variable por variable	4.5.1 y 2.6; detalle en docs/decisiones/0001-lineamientos del pro-	[illegible]
B3.4	[illegible]	[illegible]	[illegible]

ANEXO E. Declaración de uso de inteligencia artificial

Este proyecto usó un asistente de programación basado en modelos de lenguaje (Claude Code, Anthropic) como herramienta de trabajo, de acuerdo con la política de uso aceptable de herramientas de IA de la institución del autor principal. El asistente ayudó a escribir código, pruebas, scripts de clúster y borradores de documentación, incluido este informe, siempre bajo la dirección del equipo y a partir de un registro de pre-registro escrito antes de cada corrida.

Las decisiones de modelado, las reglas de aceptación y la lectura de los resultados fueron revisadas por el equipo; las cifras de este documento se leen de los archivos de resultados del repositorio al renderizarlo, con el commit y el hash de datos de cada corrida registrados en MLflow. Los datos son públicos y no contienen información personal identificable más allá de lo que la CFPB publica con autorización del consumidor. La interpretación de las licencias de los modelos de terceros (TabPFN-3.5, TimesFM 3.0) debe ser validada por una persona experta antes de cualquier uso fuera de este contexto académico.

ANEXO F. Repositorio, trazabilidad e historial de versiones

Tabla 27: Dónde está el código, los datos y los resultados, y con qué versión se renderizó este documento.

Elemento	Dónde
Repositorio del curso	`https://github.com/utec-dsia/pi1-262-g1`, rama `modeling` (código, documentación, informes); rama `entrega` (prototipo del observatorio)
Repositorio de desarrollo	`https://github.com/Codenid/capstone-claims-triage`, rama `Modeling/pipaber`, con el historial completo de commits
Commit de este render	`efb2926` (2026-10-31)
Etiqueta congelada	PENDIENTE: etiqueta del 15 de noviembre de 2026 (code freeze) y su SHA
Datos y artefactos	DVC con remoto en DagsHub (`WinzCode/capstone-claims-triage`); 119 punteros; tabla preparada `datos-v1`, md5 d189a3ae6ea7…
Experimentos	MLflow en DagsHub, experimento `claims-triage-modeling`, 87 corridas; exportación en `reports/modeling/mlflow_runs.json` y página interactiva en `reports/experimentos/`
Registro de decisiones	`docs/registro/models_plan.md` (pre-registro, §1–§32) y `docs/decisiones/0001–0008`
Entorno y semillas	`pyproject.toml` y `uv.lock`; semilla 42 en `configs/modeling.yaml`; jobs de clúster en `scripts/hpc/`
Instrucciones de ejecución	`README.md`, `etapa_6_despliegue/README.md` y `docs/pipeline.md`
Historial de versiones del informe	Git: `reports/informe/` (informe de cierre, P2–P4) y `reports/trabajo_investigacion/` (este documento); cada render deja su commit en esta tabla
Estilo de citado	IEEE, según los lineamientos de estilo de citado del programa para la Maestría en Ciencia de Datos e Inteligencia Artificial; el informe de cierre de `reports/informe/` conserva APA 7 como pide la rúbrica del P4

Cómo regenerar este documento desde un clon limpio:

```
uv sync --frozen
uv run dvc pull
```

```
cd reports/trabajo_investigacion
QUARTO_PYTHON=../../.venv/Scripts/python.exe quarto render
```

Bibliografía

[1] Consumer Financial Protection Bureau, «Consumer Complaint Database». 2026.

[2] K. Bastani, H. Namavari, y J. Shaffer, «Latent Dirichlet allocation (LDA) for topic modeling of the CFPB consumer complaints», *Expert Systems with Applications*, vol. 127, pp. 256-271, 2019, doi: 10.1016/j.eswa.2019.03.001.

[3] K. I. Roumeliotis, N. D. Tselikas, y D. K. Nasiopoulos, «Think Before You Classify: The Rise of Reasoning Large Language Models for Consumer Complaint Detection and Classification», *Electronics*, vol. 14, n.º 6, p. 1070, 2025, doi: 10.3390/electronics14061070.

[4] Z. Wang, S. Zhu, y X. Chen, «From Complaint Narratives to Monetary Relief: A Hybrid Machine Learning Framework for CFPB Consumer Complaints». 2026.

[5] J. Zhang, L.-J. Zhong, Z. Zhu, y S. Huang, «TabPFN beyond Tabular Data: Calibration and Accuracy on Multimodal Embeddings». 2026.

[6] S. Takeshita, Y. Takeshita, D. Ruffinelli, y S. P. Ponzetto, «Randomly Removing 50% of Dimensions in Text Embeddings has Minimal Impact on Retrieval and Classification», en *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, 2025.

[7] H. Bergström, A. Mehrotra, y R. G. Krishnan, «Modular multimodal classification without fine-tuning: a simple compositional approach». 2026.

[8] A. Tanna, P. Seth, M. Bouadi, y V. K. Sankarapu, «Exploring fine-tuning for tabular foundation models», en *Proceedings of the ACM Web Conference*, 2026. doi: 10.1145/3774904.3792923.

[9] J. Qu, D. Holzmüller, G. Varoquaux, y M. Le Morvan, «TabICL: a tabular foundation model for in-context learning on large data», en *Proceedings of the 42nd International Conference on Machine Learning*, 2025.

[10] M. Grootendorst, «BERTopic: Neural topic modeling with a class-based TF-IDF procedure». 2022.

[11] L. McInnes, J. Healy, N. Saul, y L. Großberger, «UMAP: Uniform Manifold Approximation and Projection», *Journal of Open Source Software*, vol. 3, n.º 29, p. 861, 2018, doi: 10.21105/joss.00861.

[12] T. Sainburg, L. McInnes, y T. Q. Gentner, «Parametric UMAP embeddings for representation and semisupervised learning», *Neural Computation*, vol. 33, n.º 11, pp. 2881-2907, 2021, doi: 10.1162/neco_a_01434.

[13] L. R. Berry y M. West, «Bayesian forecasting of many count-valued time series», *Journal of Business & Economic Statistics*, vol. 38, n.º 4, pp. 872-887, 2020, doi: 10.1080/07350015.2019.1604372.

[14] N. Chapados, «Effective Bayesian modeling of groups of related count time series», en *Proceedings of the 31st International Conference on Machine Learning*, 2014.

[15] S. W. Linderman, M. J. Johnson, y R. P. Adams, «Dependent multinomial models made easy: stick-breaking with the Pólya-gamma augmentation», en *Advances in Neural Information Processing Systems*, 2015.

[16] J. D. Silverman, K. Roche, Z. C. Holmes, L. A. David, y S. Mukherjee, «Bayesian multinomial logistic normal models through marginally latent matrix-T processes», *Journal of Machine Learning Research*, vol. 23, 2022.

[17] M. Saxena, T. Chen, y J. D. Silverman, «Scalable inference for Bayesian multinomial logistic-normal dynamic linear models», en *International Conference on Artificial Intelligence and Statistics*, 2025.

[18] A. Nigri, L.-Z. Han, y F. Ungolo, «A Dirichlet-Multinomial-Poisson framework for the coherent analysis and forecast of cause-specific mortality». 2026.

[19] A. F. Ansari *et al.*, «Chronos: Learning the Language of Time Series». 2024.

[20] A. Das, W. Kong, R. Sen, y Y. Zhou, «A decoder-only foundation model for time-series forecasting», en *Proceedings of the 41st International Conference on Machine Learning*, 2024.

[21] S. D. Gupta, «Evaluating Time Series Foundation Models on Noisy Periodic Time Series». 2025.

[22] J. Bracher, E. L. Ray, T. Gneiting, y N. G. Reich, «Evaluating epidemic forecasts in an interval format», *PLOS Computational Biology*, vol. 17, n.º 2, p. e1008618, 2021, doi: 10.1371/journal.pcbi.1008618.

[23] E. Y. Cramer, E. L. Ray, V. K. Lopez, J. Bracher, y others, «Evaluation of individual and ensemble probabilistic forecasts of COVID-19 mortality in the United States», *Proceedings of the National Academy of Sciences*, vol. 119, n.º 15, p. e2113561119, 2022, doi: 10.1073/pnas.2113561119.

[24] E. S. Page, «Continuous inspection schemes», *Biometrika*, vol. 41, n.º 1–2, pp. 100-115, 1954, doi: 10.1093/biomet/41.1-2.100.

[25] M. Salmon, D. Schumacher, y M. Höhle, «Monitoring count time series in R: Aberration detection in public health surveillance», *Journal of Statistical Software*, vol. 70, n.º 10, pp. 1-35, 2016, doi: 10.18637/jss.v070.i10.

[26] C. Robertson y L. Yee, «Avian influenza risk surveillance in North America with online media», *PLOS ONE*, vol. 11, n.º 11, p. e165688, 2016, doi: 10.1371/journal.pone.0165688.

[27] C. P. Farrington, N. J. Andrews, A. D. Beale, y M. A. Catchpole, «A statistical algorithm for the early detection of outbreaks of infectious disease», *Journal of the Royal Statistical Society: Series A*, vol. 159, n.º 3, pp. 547-563, 1996, doi: 10.2307/2983331.

[28] A. Noufaily, D. G. Enki, P. Farrington, P. Garthwaite, N. Andrews, y A. Charlett, «An improved algorithm for outbreak detection in multiple surveillance systems», *Statistics in Medicine*, vol. 32, n.º 7, pp. 1206-1222, 2013, doi: 10.1002/sim.5595.

[29] F. Dórea, B. McEwen, W. Mcnab, J. Sánchez, y C. Revie, «Syndromic surveillance using veterinary laboratory data: algorithm combination and customization of alerts», *PLoS ONE*, vol. 8, n.º 10, p. e82183, 2013, doi: 10.1371/journal.pone.0082183.

[30] A. Gopaluni, N. B. Link, E. Boley, I. R. Fulcher, M. Semakula, y B. Hedt-Gauthier, «Evaluation of rolling surveillance methods in context of prior aberrations: a simulation study», *Statistics in Medicine*, 2025, doi: 10.1002/sim.70075.

[31] G. Bédubourg y Y. Le Strat, «Evaluation and comparison of statistical methods for early temporal detection of outbreaks: a simulation-based study», *PLoS ONE*, vol. 12, n.º 7, p. e181227, 2017, doi: 10.1371/journal.pone.0181227.

[32] P. Chapman *et al.*, «CRISP-DM 1.0: Step-by-step data mining guide», 2000.

[33] S. Kapoor y A. Narayanan, «Leakage and the reproducibility crisis in machine-learning-based science», *Patterns*, vol. 4, n.º 9, p. 100804, 2023, doi: 10.1016/j.patter.2023.100804.

[34] R. D. Peng, «Reproducible research in computational science», *Science*, vol. 334, n.º 6060, pp. 1226-1227, 2011, doi: 10.1126/science.1213847.

[35] D. Sculley *et al.*, «Hidden technical debt in machine learning systems», en *Advances in Neural Information Processing Systems*, 2015.

[36] N. Hollmann *et al.*, «Accurate predictions on small data with a tabular foundation model», *Nature*, vol. 637, pp. 319-326, 2025, doi: 10.1038/s41586-024-08328-6.

[37] S. Xiao, Z. Liu, P. Zhang, y N. Muennighoff, «C-Pack: Packaged Resources To Advance General Chinese Embedding». 2023.

[38] M. Douze *et al.*, «The Faiss library». 2024.

[39] O. Abril-Pla *et al.*, «PyMC: a modern, and comprehensive probabilistic programming framework in Python», *PeerJ Computer Science*, vol. 9, p. e1516, 2023, doi: 10.7717/peerj-cs.1516.

[40] Congreso de la República del Perú, «Ley N.º 29733, Ley de Protección de Datos Personales». 2011.

[41] Ministerio de Justicia y Derechos Humanos del Perú, «Decreto Supremo N.º 016-2024-JUS, Reglamento de la Ley N.º 29733». 2024.

[42] National Institute of Standards and Technology, «Artificial Intelligence Risk Management Framework (AI RMF 1.0)», 2023. doi: 10.6028/NIST.AI.100-1.

[43] T. Britton y F. Giardina, «Introduction to statistical inference for infectious diseases». 2014.

[44] A. T. Craig, R. Leong, M. Donoghoe, D. Muscatello, V. J. C. Mojica, y C. J. M. Octavo, «Comparison of statistical methods for the early detection of disease outbreaks in small population settings», *IJID Regions*, 2023, doi: 10.1016/j.ijregi.2023.08.007.

[45] D. Enki, P. Garthwaite, C. P. Farrington, A. Noufaily, N. Andrews, y A. Charlett, «Comparison of Statistical Algorithms for the Detection of Infectious Disease Outbreaks in Large Multiple Surveillance Systems», *PLoS ONE*, 2016, doi: 10.1371/journal.pone.0160759.

[46] L. Hutwagner, T. Browne, G. Seeman, y A. Fleischauer, «Comparing Aberration Detection Methods with Simulated Data», *Emerging Infectious Diseases*, 2005, doi: 10.3201/eid1102.040587.

[47] D. M. Nekorchuk, T. Gebrehiwot, M. Lake, W. Awoke, A. Mihretie, y M. Wimberly, «Malaria Early Detection in a Declining Transmission Setting in the Amhara Region of Ethiopia». 2020. doi: 10.21203/rs.3.rs-116290/v1.

[48] D. M. Nekorchuk, T. Gebrehiwot, M. Lake, W. Awoke, A. Mihretie, y M. Wimberly, «Comparing malaria early detection methods in a declining transmission setting in northwestern Ethiopia», *BMC Public Health*, 2021, doi: 10.1186/s12889-021-10850-5.

[49] A. Noufaily *et al.*, «Comparison of statistical algorithms for daily syndromic surveillance aberration detection», *Bioinform.*, 2018, doi: 10.1093/bioinformatics/bty997.

[50] A. P. S. P. Silva *et al.*, «Monitoring emerging pathogens using negative nucleic acid test results from endemic pathogens in pig populations: Application to porcine enteric coronaviruses», *PLoS ONE*, 2024, doi: 10.1371/journal.pone.0306532.

[51] A. Stewart *et al.*, «Why is it Difficult to Detect Sudden and Unexpected Epidemic Outbreaks in Twitter?». 2016.

[52] M.-A. Widdowson *et al.*, «Automated, Laboratory-based System Using the Internet for Disease Outbreak Detection, the Netherlands», *Emerging Infectious Diseases*, 2003, doi: 10.3201/eid0909.020450.

[53] B. Zacher y I. Czogiel, «Supervised learning improves disease outbreak detection». 2019.

[54] B. Zacher y I. Czogiel, «Supervised learning using routine surveillance data improves outbreak detection of Salmonella and Campylobacter infections in Germany», *PLoS ONE*, 2022, doi: 10.1371/journal.pone.0267510.

[55] B. Zareie, J. Poorolajal, A. Roshani, y M. Karami, «Outbreak detection algorithms based on generalized linear model: a review with new practical examples», *BMC Medical Research Methodology*, 2023, doi: 10.1186/s12874-023-02050-z.

[56] D. Angelov, «Top2Vec: Distributed Representations of Topics». 2020.

[57] M. Bahri, B. Pfahringer, A. Bifet, y S. Maniu, «Efficient Batch-Incremental Classification Using UMAP for Evolving Data Streams», *International Symposium on Intelligent Data Analysis*, 2020, doi: 10.1007/978-3-030-44584-3_4.

[58] A. C. Bryant y K. J. Cios, «SOTXTSTREAM: Density-based self-organizing clustering of text streams», *PLoS ONE*, 2017, doi: 10.1371/journal.pone.0180543.

[59] M. Chavooshi y A. Mamonov, «Autoencoded UMAP-Enhanced Clustering for Unsupervised Learning». 2025. doi: 10.48550/arXiv.2501.07729.

[60] E. Feito-Casares, F. Melgarejo-Meseguer, E. Casiraghi, G. Valentini, y J. R. Álvarez, «Interpreting Manifolds and Graph Neural Embeddings from Internet of Things Traffic Flows». 2026. doi: 10.48550/arXiv.2602.05817.

[61] B. Ghojogh, A. Ghodsi, F. Karray, y M. Crowley, «Uniform Manifold Approximation and Projection (UMAP) and its Variants: Tutorial and Survey». 2021.

[62] G. Gupta, B. Rastegarpanah, A. Iyer, J. Rubin, y K. Kenthapadi, «Measuring Distributional Shifts in Text: The Advantage of Language Model-Based Embeddings». 2023. doi: 10.48550/arXiv.2312.02337.

[63] M. Herrmann, D. Kazempour, F. Scheipl, y P. Kröger, «Enhancing cluster analysis via topological manifold learning», *Data mining and knowledge discovery*, 2022, doi: 10.1007/s10618-023-00980-2.

[64] R. Hodgson, J. Wang, A. I. Cristea, y J. Graham, «Partially-Supervised Metric Learning via Dimensionality Reduction of Text Embeddings Using Transformer Encoders and Attention Mechanisms», *IEEE Access*, 2024, doi: 10.1109/ACCESS.2024.3403991.

[65] A. Liu, J. Lu, y G.-Q. Zhang, «Concept Drift Detection via Equal Intensity k-Means Space Partitioning», *IEEE Transactions on Cybernetics*, 2020, doi: 10.1109/TCYB.2020.2983962.

[66] A. W. Long y A. L. Ferguson, «Landmark diffusion maps (L-dMaps): Accelerated manifold learning out-of-sample extension», *Applied and Computational Harmonic Analysis*, 2017, doi: 10.1016/j.acha.2017.08.004.

[67] F. Periti, A. Ferrara, S. Montanelli, y M. Ruskov, «What is Done is Done: an Incremental Approach to Semantic Shift Detection», *Workshop on Computational Approaches to Historical Language Change*, 2022, doi: 10.18653/v1/2022.lchange-1.4.

[68] F. Periti y S. Montanelli, «Lexical Semantic Change through Large Language Models: a Survey», *ACM Computing Surveys*, 2023, doi: 10.1145/3672393.

[69] A. H. Saleknia y M. Sabokrou, «What are we really measuring? Rethinking dataset bias in web-scale natural image collections via unsupervised semantic clustering», *Neurocomputing*, 2026, doi: 10.1016/j.neucom.2026.133679.

[70] A. O. B. Şapcı, H. Kemik, R. Yeniterzi, y O. Tastan, «Focusing on potential named entities during active label acquisition», *Natural Language Engineering*, 2021, doi: 10.1017/S1351324923000165.

[71] K. Saravanakumar, M. Ballesteros, M. K. Chandrasekaran, y K. McKeown, «Event-Driven News Stream Clustering using Entity-Aware Contextual Embeddings», *Conference of the European Chapter of the Association for Computational Linguistics*, 2021, doi: 10.18653/v1/2021.eacl-main.198.

[72] D. A. Senanayake, W. Wang, S. Naik, y S. Halgamuge, «Self-Organizing Nebulous Growths for Robust and Incremental Data Visualization», *IEEE Transactions on Neural Networks and Learning Systems*, 2019, doi: 10.1109/TNNLS.2020.3023941.

[73] A. Tarekegn, «Large Language Model Enhanced Clustering for News Event Detection». 2024. doi: 10.48550/arXiv.2406.10552.

[74] O. Vykhopen, V. Skorik, M. Tereschenko, y V. Solopova, «Online Density-Based Clustering for Real-Time Narrative Evolution Monitorin». 2026. doi: 10.48550/arXiv.2601.20680.

[75] P. Wassenaar, P. Guetschel, y M. Tangermann, «Approximate UMAP allows for high-rate online visualization of high-dimensional data streams». 2024. doi: 10.3217/978-3-99161-014-4-061.

[76] E. Berta, D. Holzmüller, F. R. Bach, y M. I. Jordan, «CalArena: A Large-Scale Post-Hoc Calibration Benchmark». 2026. doi: 10.48550/arXiv.2605.30188.

[77] N. Erickson *et al.*, «TabArena: A Living Benchmark for Machine Learning on Tabular Data», *Neural Information Processing Systems*, 2025, doi: 10.48550/arXiv.2506.16791.

[78] J. Gardner, J. C. Perdomo, y L. Schmidt, «Large Scale Transfer Learning for Tabular Data via Language Modeling», *Neural Information Processing Systems*, 2024, doi: 10.48550/arXiv.2406.12031.

[79] N. Hollmann, S. Müller, K. Eggensperger, y F. Hutter, «TabPFN: A Transformer That Solves Small Tabular Classification Problems in a Second», *International Conference on Learning Representations*, 2022.

[80] J.-P. Jiang, S.-Y. Liu, H.-R. Cai, Q.-L. Zhou, y H.-J. Ye, «Representation Learning for Tabular Data: A Comprehensive Survey», *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2025, doi: 10.1109/TPAMI.2026.3657217.

[81] I. Kang, P. Ram, Y. Zhou, H. Samulowitz, y O. Seneviratne, «Language Model Representations for Efficient Few-Shot Tabular Classification», *The Web Conference*, 2026, doi: 10.1145/3774904.3792477.

[82] J. Ma *et al.*, «TabDPT: Scaling Tabular Foundation Models on Real Data», *Neural Information Processing Systems*, 2024, doi: 10.52202/085713-5748.

[83] V. Manokhin y D. Grønhaug, «Classifier Calibration at Scale: An Empirical Study of Model-Agnostic Post-Hoc Methods». 2026. doi: 10.48550/arXiv.2601.19944.

[84] M. Spinaci, M. Polewczyk, M. Schambach, y S. Thelin, «ConTextTab: A Semantics-Aware Tabular In-Context Learner», *Neural Information Processing Systems*, 2025, doi: 10.48550/arXiv.2506.10707.

[85] T. Äijö, C. L. Müller, y R. Bonneau, «Temporal probabilistic modeling of bacterial compositions derived from 16S rRNA sequencing», *bioRxiv*, 2016, doi: 10.1093/bioinformatics/btx549.

[86] T. Aktekin, N. G. Polson, y R. Soyer, «Sequential Bayesian Analysis of Multivariate Count Data», *Bayesian Analysis*, 2016, doi: 10.1214/17-BA1054.

[87] J. Bakdash *et al.*, «Malware in the future? Forecasting of analyst detection of cyber events», *Journal of Cybersecurity*, 2017, doi: 10.1093/cybsec/tyy007.

[88] A. Das, W. Kong, B. Paria, y R. Sen, «Dirichlet Proportions Model for Hierarchically Coherent Probabilistic Forecasting», *Conference on Uncertainty in Artificial Intelligence*, 2022.

[89] C. Fong y D.-Y. Yeung, «Deep COVID-19 Forecasting for Multiple States with Data Augmentation». 2023. doi: 10.48550/arXiv.2302.01155.

[90] H.-H. Huang, Y.-H. Chen, y M. Scott, «Bayesian Deep Count Regression and Anomaly Detection: Evidence from GDELT Event Panels». 2026.

[91] X.-Y. Long, D. F. Schmidt, C. Bergmeir, y S. Smyl, «Fast Gibbs sampling for the local and global trend Bayesian exponential smoothing model». 2024. doi: 10.48550/arXiv.2407.00492.

[92] D. Randahl y J. Vegelius, «Forecasting Densities of Fatalities from State-based Conflicts using Observed Markov Models». 2024.

[93] A. K. Yanchenko, D. Deng, J. Li, A. Cron, y M. West, «Hierarchical dynamic modelling for individualized Bayesian forecasting», *Journal of the Royal Statistical Society, Series C: Applied Statistics*, 2021, doi: 10.1093/jrsssc/qlad002.

[94] B. Zhang, A. Panagiotelis, y Y.-F. Kang, «Discrete forecast reconciliation», *European Journal of Operational Research*, 2023, doi: 10.1016/j.ejor.2024.05.024.